REVUE DE LITTÉRATURE

Revue de la littérature académique

Interopérabilité et Orchestration Agentiques

André-Guy Bruneau, M.Sc. IT · 15 août 2026

Auteur	André-Guy Bruneau, M.Sc. IT · agbruneau@gmail.com
Faits gelés au	15 août 2026
Révision	29 octobre 2026 : reprise datée et errata en annexe.
Actualisation	1er novembre 2026, en annexe

Table des matières

Résumé 3
Abstract 3
1 Introduction 4
2 Méthode 5
3 Physionomie du corpus 6
4 Les protocoles d'interopérabilité 8
5 La sécurité des agents et de leurs protocoles 10
6 L'identité, la délégation et la révocation 12
7 Les systèmes multi-agents : orchestration et défaillance 14
8 L'évaluation, les bancs d'essai et l'observabilité 15
9 La couche transactionnelle : paiements, marchés, réputation 18
10 Les processus d'affaires et l'exécution durable 19
11 La gouvernance, le risque et la responsabilité 21
12 Le Web agentique et l'horizon 23
13 La chorégraphie et l'essaim 24
14 Ce que la littérature établit, et où elle se contredit 26
15 Trois énoncés de la veille mis à l'épreuve 27
16 Lacunes et programme de recherche 29
17 Limites de cette revue 29
18 Conclusion 31
Annexe : le corpus arbitré, et ce qu'il ne couvre pas 31
Références 32
Annexe : reprise du 29 octobre 2026 45
Annexe : actualisation de novembre 2026 49

Résumé

Cette revue examine la littérature académique sur l'interopérabilité et l'orchestration des agents fondés sur les grands modèles de langue en entreprise, arrêtée au 15 août 2026. Elle prend pour corpus 192 pièces, dont 189 déposées sur arXiv, chacune ouverte sur sa notice et confrontée aux métadonnées canoniques du dépôt.

Le premier résultat tient à la forme du corpus retenu, non à son contenu. Douze pièces sur 189 — 6 % — portent une attestation de publication dans leur notice. Trente-deux autres annoncent une acceptation dans le seul champ de commentaire libre, que personne ne vérifie. Les 145 restantes, soit 77 % de ce corpus arXiv, ne présentent aucun signe de revue par les pairs à leur notice. La proportion mesure un dépôt de prépublications lu au seul critère de la notice ; elle ne s'étend pas au champ, et une passe de contrôle sur les bases de littérature arbitrée en borne l'écart dans les deux sens. Soixante-trois pour cent du corpus a été déposé en 2026 et plus de la moitié n'a jamais été révisée. *Un corpus dont les trois quarts ne déclarent aucun comité ne peut pas fonder à lui seul une décision d'architecture au même titre qu'une littérature établie, et cette revue le déclare avant d'en rapporter le contenu.*

Dix fronts sont examinés — protocoles, sécurité, identité et délégation, systèmes multi-agents, évaluation, couche transactionnelle, processus d'affaires, gouvernance, Web agentique, chorégraphie et essaim. Pour chacun, la revue distingue ce que la littérature établit, où elle se contredit réellement, et ce qu'elle ne traite pas. Quatre désaccords méritent d'être nommés : la validité même des instruments qui mesurent le risque protocolaire, l'utilité du multi-agent comparé à l'agent unique, le choix entre suspendre l'effet jusqu'à confirmation ou l'émettre et organiser sa révision, et la place de la vérification dans un collectif sans chef d'orchestre.

La revue confronte enfin trois énoncés de la veille technologique du même auteur à ce que la littérature en dit. Deux en ressortent modifiés : le déficit de délégation au-delà de deux sauts est un déficit d'adoption et non d'invention, et la dissymétrie entre agents et formalismes de processus est industrielle, non scientifique. Le troisième — l'absence de vocabulaire de trace décrivant une chaîne de mandat — est confirmé par une seconde voie, plus sévère que la première.

Abstract

This review examines the academic literature on the interoperability and orchestration of agents built on large language models in the enterprise, as of 15 August 2026. Its corpus comprises 192 items, 189 of them deposited on arXiv, each opened at its record and checked against the repository's canonical metadata.

The first result concerns the form of the retained corpus, not its content. Twelve items out of 189 — 6% — carry an attestation of publication in their record. Thirty-two others announce an acceptance only in the free-text comment field, which no one verifies. The remaining 145, or 77% of this arXiv corpus, show no sign of peer review in their record. The proportion measures a preprint repository read solely by the criterion of the record; it does not extend to the field, and a control pass over the databases of refereed literature bounds the gap in both directions. Sixty-three percent of the corpus was deposited in 2026, and more than half has never been revised. *A corpus three quarters of which declare no review committee cannot on its own ground an architectural decision on the same footing as an established literature, and this review says so before reporting its content.*

Ten fronts are examined — protocols, security, identity and delegation, multi-agent systems, evaluation, the transaction layer, business processes, governance, the agentic Web, choreography and swarm. For each, the review distinguishes what the literature establishes, where it genuinely contradicts itself, and what

it does not address. Four disagreements deserve to be named: the very validity of the instruments that measure protocol risk, the usefulness of the multi-agent approach compared with a single agent, the choice between suspending the effect until confirmation or emitting it and organizing its revision, and the place of verification in a collective without a conductor.

Finally, the review sets three statements from the same author's technology watch against what the literature says about them. Two come out modified: the delegation deficit beyond two hops is a deficit of adoption, not of invention, and the asymmetry between agents and process formalisms is industrial, not scientific. The third — the absence of a trace vocabulary describing a chain of mandate — is confirmed by a second route, more severe than the first.

Mots-clés — revue de littérature ; interopérabilité des agents ; IA agentique ; Model Context Protocol ; Agent2Agent ; systèmes multi-agents ; chorégraphie agentique ; essaim multiagents ; coordination décentralisée ; identité non humaine ; chaîne de délégation ; révocation ; sécurité des agents ; injection d'invite indirecte ; bancs d'essai d'agents ; observabilité agentique ; provenance ; paiements agentiques ; collusion algorithmique ; gestion des processus d'affaires ; exécution durable ; conformité ; responsabilité ; Web agentique ; régime de preuve ; prépublication.

1 Introduction

L'interopérabilité des agents fondés sur les grands modèles de langue est passée, en moins de trois ans, du statut de curiosité de laboratoire à celui de question d'architecture d'entreprise. Des protocoles de composition ont été publiés, des registres montés, des mécanismes de paiement et de délégation proposés, des textes réglementaires adoptés qui s'appliquent à ces systèmes sans les nommer. La production académique a suivi le même rythme. C'est précisément ce rythme qui pose problème : une littérature qui double de volume en douze mois n'a pas eu le temps d'être filtrée par les procédures qui, ailleurs, séparent le résultat de la revendication.

1.1 Question de revue

Cette revue pose une question en deux parties : que la littérature académique établit-elle réellement sur l'interopérabilité et l'orchestration agentiques en entreprise, et à quel régime de preuve ? La seconde partie commande la première. Un énoncé de la forme « tel protocole présente telle vulnérabilité dans tel pourcentage des serveurs observés » n'a pas la même portée selon qu'il provient d'une mesure sur un parc réel, d'une simulation, ou d'un raisonnement sur la spécification ; et il n'a pas la même autorité selon qu'un comité de lecture l'a examiné ou que son auteur l'a déposé la semaine dernière.

Trois termes sont pris au sens suivant. L'*interopérabilité* désigne la capacité de composer des agents, des outils et des services hétérogènes sous un vocabulaire commun, qu'il s'agisse d'accès aux outils, de communication entre agents ou de découverte. L'*orchestration* désigne la conduite d'un travail à plusieurs étapes, avec ses garanties d'exécution, sa trace et sa reprise sur défaillance. La restriction *en entreprise* écarte les travaux qui n'envisagent que l'agent isolé ou le banc d'essai jouet, et retient ceux qui portent sur des systèmes soumis à une contrainte d'exploitation, d'audit ou de droit.

1.2 Rapport à la veille technologique

Cette revue prolonge une veille technologique du même auteur, qui dresse l'état du champ sur sources primaires : spécifications, dépôts de code, communiqués de fondations, textes réglementaires. L'autocitation est déclarée ici et signalée à chaque renvoi. Les deux exercices ne répondent pas à la même question et ne se valident pas l'un l'autre.

La veille dit ce que le monde déployé fait ; la présente revue dit ce que la littérature sait, et l'intérêt tient à ce qu'elles ne coïncident pas. La veille observe des protocoles adoptés à grande échelle sans démonstration de sécurité publiée ; la littérature, elle, mesure des vulnérabilités sur des parcs que personne n'a mandat de corriger. La veille constate des couches comblées hors de la couche commune ; la littérature les traite parfois abondamment, parfois pas du tout. Trois de ses énoncés sont mis à l'épreuve en fin de revue.

2 Méthode

2.1 Constitution du corpus

Le corpus compte 192 entrées et a trois origines. La première est le socle hérité de la veille : ses 50 pièces académiques **[1-50]**, reprises telles quelles puis re-vérifiées pièce à pièce contre leur notice courante, plusieurs ayant été révisées depuis leur lecture initiale. La deuxième est une passe de recherche neuve conduite sur dix fronts thématiques : protocoles **[51-63]**, sécurité **[64-74]**, identité et délégation **[75-87]**, systèmes multi-agents **[88-101]**, évaluation et observabilité **[102-113]**, couche transactionnelle **[114-125]**, processus d'affaires **[126-137]**, gouvernance **[138-148]**, Web agentique et horizon **[149-158]**, chorégraphie et essaim **[159-173]**. Trois pièces à DOI **[174-176]** complètent l'ensemble : textes normatifs et littérature d'ingénierie antérieure au dépôt, sans laquelle le front transactionnel n'aurait pas de point d'appui. La troisième origine est la reprise du 15 août elle-même : seize pièces déposées entre le 9 et le 13 août 2026 [177-192], retenues au même critère que la passe neuve et rattachées chacune au front où sa mesure porte.

Les trois origines ne portent pas le même régime de citation, et le contrôle de publication de cette revue l'exige : chacune des 142 entrées hors socle — les 123 de la passe neuve, les seize de la reprise du 15 août et les trois à DOI — est discutée nommément dans le corps, tandis que le socle hérité est repris en bloc — vingt-trois de ses cinquante pièces y sont engagées une à une, vingt-sept ne le sont pas et ne valent ici que comme arrière-plan. *Une plage citée en prose couvre une référence sans la discuter ; le distinguer est ce qui empêche une bibliographie de grossir sans que le texte y gagne.*

Le découpage en dix fronts n'est pas une taxinomie du champ mais un plan de couverture : il sépare ce que la veille avait identifié comme des couches distinctes de la pile. Un même travail peut relever de deux fronts ; il est alors rattaché à celui où sa mesure porte, et non à celui que son titre annonce.

La passe neuve a été conduite par des agents indépendants, à consigne de source primaire exclusive : aucun ne pouvait retenir une pièce sur la foi d'un résumé secondaire, chacun devait ouvrir la notice de chaque pièce et en rapporter les métadonnées. Le critère de rétention est la conséquence : les pièces les plus conséquentes de chaque front, la conséquence se jugeant à la mesure produite et non à la citation reçue. Sur un corpus dont 119 pièces sur 189 ont été déposées en 2026, le compte de citations ne mesure rien d'autre que l'antériorité de dépôt.

2.2 Régime de vérification

Toutes les notices arXiv ont été reprises à l'API d'exportation du dépôt le 9 août 2026, puis reprises une seconde fois, intégralement, le 15 août 2026 : 189 notices demandées, 189 obtenues, aucune retirée ni devenue introuvable — les 173 du premier relevé et les seize entrées depuis, interrogées le même jour à la même interface. Chaque reprise donne, pour chacune des pièces : titre exact, auteurs, version courante, date de dépôt initial, date de dernière révision, champ `journal_ref`, champ DOI et champ `comment`. La première a corrigé plusieurs statuts que les agents avaient rapportés comme « à comité de lecture » sur la seule foi du champ de commentaire — correction qui a motivé la section suivante et, plus largement, la construction de toute la revue. La seconde n'a trouvé, sur les 173 pièces du premier relevé, que deux notices révisées dans

l'intervalle : [113], passée en v2 le 13 août, et [146], passée en v2 le 10 août ; l'une et l'autre sont instruites plus bas.

La règle appliquée est stricte : seule une attestation portée à la notice elle-même — champ `journal_ref` ou champ DOI — vaut publication établie. *Le premier relevé de cette revue ne retenait que le premier des deux champs et comptait sept pièces là où il y en a douze ; l'écart a été trouvé en confrontant les notices aux entrées, et il est rapporté ici plutôt que corrigé en silence.* Une acceptation annoncée ailleurs est enregistrée comme telle, comme déclaration de l'auteur, et comptée séparément. Ce second partage a été refait notice par notice le 15 août, sur la règle suivante : une acceptation ou une présentation annoncée compte, une soumission annoncée ne compte pas — [163], dont le commentaire porte « submitted to OOPSLA 2026 », reste donc hors du compte, et un dépôt d'archive ouverte sans arbitrage aussi, tel le Zenodo de [86].

2.3 Ce que cette revue ne peut pas établir

Ni protocole enregistré au sens PRISMA, ni double codage, ni recherche multi-bases : un seul jugement décide de chaque rétention, et l'interrogation porte sur arXiv complété de trois références à DOI. Surtout, il n'y a **aucune réplication** : aucune expérience n'a été refaite, aucun banc réexécuté, et la revue rapporte ce que les pièces revendiquent en distinguant ce qui est mesuré de ce qui est avancé. Les décomptes qui suivent sont donc un recensement du corpus retenu, non une estimation du champ.

3 Physionomie du corpus

3.1 Ce que la forme du corpus dit avant son contenu

Avant tout énoncé de contenu, la forme du corpus le qualifie. Sur les 189 pièces déposées sur arXiv, **douze** portent une attestation de publication dans leur notice — les mêmes douze qu'au relevé du 9 août : sept au champ `journal_ref` — [15], [37], [38], [46], [59], [136], [143] — et cinq au seul champ DOI — [4], [44], [142], [144], [158] ; l'annexe donne pour chacune sa publication et son apport. Trente-deux pièces annoncent une acceptation ou une présentation dans le seul champ de commentaire libre. Les 145 restantes ne présentent aucun signe de revue par les pairs à leur notice — part de ce corpus arXiv relevée au seul critère de la notice, non estimation du champ, et les limites en mesurent l'écart.

Ces trente-deux ne sont pas les vingt-huit du 9 août, et l'écart tient à quatre entrées. Trois viennent du partage refait sur les 173 notices du premier relevé. [113] a gagné son annonce de lieu en révisant sa notice le 13 août : sa v1 ne portait aucun commentaire, sa v2 déclare qu'une version condensée paraît dans les actes d'un sommet. [137] et [145] portent au 15 août l'annonce d'une présentation en atelier et un nom de conférence, dans la forme exacte de pièces qui étaient comptées ; le premier relevé les rangeait en prépublication. *Depuis quand ces deux commentaires sont-ils là, on ne peut pas le dire : une édition de métadonnées seule ne change ni la version ni la date de révision, et arXiv ne publie aucun historique de ces champs. Ce qui est établi, c'est qu'ils y sont aujourd'hui et qu'ils n'étaient pas comptés.* La quatrième entrée est une arrivante : des seize pièces versées le 15 août, [183] est la seule à annoncer un lieu — une acceptation en atelier au seul champ de commentaire —, et aucune des seize ne porte d'attestation en notice.

Trois régimes de preuve se distinguent donc, et la distinction n'est pas formelle : le champ de commentaire est rempli par l'auteur et n'est vérifié par personne. La plupart de ces trente-deux annonces sont vraisemblablement exactes ; l'objection ne porte pas sur leur véracité individuelle mais sur la nature de la garantie — un contrôle que nul n'exerce ne devient pas un contrôle parce que les déclarants sont honnêtes.

Tableau 1 — Régimes de preuve des 189 pièces déposées sur arXiv, d'après les notices reprises à l'API du dépôt le 15 août 2026. Les parts portent sur ce corpus et sur ce que la notice déclare, non sur le champ.

Régime	Pièces	Part
Publication attestée en notice (`journal_ref` ou DOI)	12	6 %
Acceptation auto-déclarée (champ de commentaire)	32	17 %
Aucun signe de revue par les pairs	145	77 %
Total	189	100 %

L'âge du corpus va dans le même sens. Le dépôt initial se répartit ainsi : 2023, cinq pièces ; 2024, treize ; 2025, cinquante-deux ; 2026, cent dix-neuf — soit 63 % des pièces déposées sur arXiv, dans les huit premiers mois de 2026. La révision suit : 136 pièces sur 189, soit 72 %, ont été révisées pour la dernière fois en 2026, dont vingt-huit en juin, vingt et une en juillet et vingt-deux dans les quinze premiers jours d'août. Quant à la stabilité des textes, 103 pièces en sont encore à leur version initiale, 52 à la deuxième, 24 à la troisième et 10 au-delà : plus de la moitié du corpus — 103 sur 189, soit 54 % — n'a jamais été révisée.

Deux de ces chiffres sont en partie fabriqués par l'instrument, et il faut le dire avant d'en tirer quoi que ce soit. Les vingt-deux révisions d'août comptent les seize pièces que la reprise vient d'ajouter, retenues précisément parce qu'elles étaient neuves : on n'y lira donc pas une accélération du champ. Et la part des textes jamais révisés monte de deux points et demi depuis le 9 août pour la même raison — quinze des seize arrivantes sont en v1. La reprise rajeunit le corpus qu'elle mesure.

Vingt-huit révisions en juin sur un corpus de 189 pièces : 15 % des textes ont bougé en un mois. Une pièce lue en avril et citée en août peut avoir changé de résultat, de jeu de données ou de conclusion entre-temps ; c'est ce qui a imposé la re-vérification du socle. Le risque n'est pas théorique et la reprise du 15 août en donne le cas : [146] a doublé de volume le 10 août — 21 pages en v1, 44 en v2 — et a réétiqueté ses propres démonstrations, requalifiant en illustrations synthétiques calibrées ce que sa v1 donnait pour des instanciations calculables ; le front de la gouvernance en instruit le détail. *La pièce n'a pas corrigé un résultat ; elle a rendu explicite le régime de preuve que ce résultat avait déjà, et c'est une semaine après son dépôt, sans qu'aucun avis parte vers qui la citait.* L'autre révision, [113], laisse son résumé inchangé mot pour mot et ne déplace que son régime de publication déclaré — de prépublication sans signe de revue à acceptation autodéclarée. Le corpus est ici gelé au 15 août 2026, et chaque énoncé rapporté vaut pour la version courante à cette date.

Le constat commande la lecture de tout ce qui suit : 77 % des énoncés retenus ici ne déclarent aucun comité à leur notice, 63 % ont été déposés en 2026, plus de la moitié n'a jamais été révisée. Le chiffre est celui du corpus, pris sur le dépôt où va le travail non arbitré ; le lire comme une part du champ serait circulaire, et le tenir pour un compte exact de l'arbitrage subi serait faux dans l'autre sens — la passe de contrôle rapportée aux limites trouve de la littérature arbitrée hors arXiv sur quatre fronts, et des pièces de ce corpus publiées sans que leur notice le dise. Cela n'interdit pas de s'y appuyer, mais interdit de les traiter comme un acquis, et impose de rapporter chaque résultat avec le régime qui le porte.

3.2 Répartition par front et par régime de preuve

Tableau 2 — Répartition des 192 entrées par front, avec la plage de références de la passe neuve et, à sa suite, les pièces versées à la reprise du 15 août.

Front	Références	Pièces
Socle hérité de la veille	[1-50]	50
Protocoles	[51-63], [177], [183]	15
Sécurité	[64-74], [178], [184], [185]	14

Front	Références	Pièces
Identité et délégation	[75-87], [179], [186]	15
Systèmes multi-agents	[88-101], [187]	15
Évaluation et observabilité	[102-113], [181], [182], [188], [189], [190]	17
Couche transactionnelle	[114-125]	12
Processus d'affaires	[126-137]	12
Gouvernance	[138-148], [191], [192]	13
Web agentique et horizon	[149-158]	10
Chorégraphie et essaim	[159-173], [180]	16
Pièces à DOI	[174-176]	3

Les dix fronts neufs comptent 139 pièces, de dix à dix-sept chacun. Cet équilibre est un artefact de méthode : le critère de rétention est comparatif à l'intérieur de chaque front, non proportionnel au volume produit. Le tableau mesure l'attention de cette revue, pas l'activité de la littérature. Les seize entrées du 15 août sont numérotées à la suite plutôt qu'insérées dans les plages, mais rattachées chacune au front où sa mesure est discutée : les tenir en fin de colonne garde visible ce qu'une semaine de dépôts a suffi à ajouter, et où elle n'a rien ajouté — cinq pièces à l'évaluation, aucune à la couche transactionnelle, aux processus d'affaires ni au Web agentique.

Le régime de preuve, lui, ne se distribue pas uniformément. Six des douze publications attestées appartiennent au socle hérité — [4], [15], [37], [38], [44] et [46], dont deux antérieures à 2025 — et les six autres se répartissent entre protocoles [59], processus d'affaires [136], gouvernance [142], [143], [144] et horizon [158] : quatre fronts neufs sur dix. L'attestation en notice se produit là où des communautés établies existent depuis longtemps : gestion des processus d'affaires, systèmes d'information, droit. Elle est absente de ce corpus là où le champ se construit, c'est-à-dire là où portent les questions d'interopérabilité elles-mêmes — mais elle n'est pas absente du champ, et la passe de contrôle sur DBLP et Crossref rapportée aux limites trouve de la littérature arbitrée sur quatre des fronts que ce corpus donne pour vides.

4 Les protocoles d'interopérabilité

4.1 Ce que la littérature établit

La sous-spécification de la couche sémantique est passée du statut de « défi ouvert » des surveys [1], [2] à celui de résultat mesuré, par quatre chemins indépendants. Empiriquement : sur 856 outils de 103 serveurs MCP, 97,1 % des descriptions portent au moins un défaut et 56 % n'énoncent pas clairement leur objet ; les enrichir ne gagne que 5,85 points médians de succès, allonge l'exécution de 67,46 % et régresse dans 16,67 % des cas [53]. Sur 19 200 paires description/code issues de 2 214 serveurs réels, 9,93 % sont incohérentes, sans qu'aucun mécanisme du protocole ne vérifie que la description reflète l'implémentation [55]. Formellement : MCP et Schema-Guided Dialogue sont bisimilaires sous une application dont l'inverse est partielle et à perte, ce qui démontre au lieu de conjecturer les manques d'expressivité de MCP [56]. Analytiquement : sur 18 protocoles, transport, schéma et cycle de vie sont mûrs, mais clarification, alignement de contexte et vérification restent hors protocole [62].

Deuxième acquis, l'écosystème déployé ne se conforme pas aux hypothèses de la littérature de protocole. Sur 1 723 applications consommatrices, seules 37,2 % imposent une approbation bloquante avant exécution d'outil, le protocole ne spécifiant pas le côté client [54]. Le registre officiel n'est pas stable : sur 88,6 jours, 8,6 % de serveurs réécrivent une description, la moitié des changements atterrissant sur des arrivants qu'un

classement par dérive ne peut atteindre, d'où un ré-audit ciblé couvrant environ 10 % des changements [58]. Enfin, sur 2 297 projets validés (précision 83 %), une strate purement pédagogique doit être exclue sous peine de gonfler toute mesure d'écosystème [59].

Le côté client ne consomme même pas ce que le serveur lui remet. Sur 54 000 essais et 24 modèles interrogeant un serveur MCP juridique en production, retirer l'outil de recherche concurrent porte à 98 % au moins la lecture des données embarquées dans les instructions du serveur chez 23 modèles sur 24 ; la seule présence de cet outil la fait retomber sous 15 % chez neuf d'entre eux. L'échec relève donc de la préférence comportementale et non d'une incapacité, et aucune ingénierie d'invite par serveur n'y remédie de façon portable, certaines interventions se retournant contre des familles de modèles précises [183]. *Quatre pages, acceptation annoncée au seul champ de commentaire, pour un atelier que ce champ déclare lui-même non archival.*

Troisième acquis, aucun protocole ne s'impose et la question s'est déplacée vers la composition : l'analyse séparée de MCP et A2A crée un fossé sémantique, que le premier cadre unifiant les deux formalise en 30 propriétés temporelles [60] ; la seule comparaison adossée à deux implémentations de la même tâche conclut que la répartition des responsabilités de coordination, non les fonctionnalités, sépare les deux protocoles, ses auteurs qualifiant ce résultat d'observations de conception [57] ; la seule interopération hétérogène publiée superpose une spécification déclarative à un protocole industriel au lieu de le remplacer [61]. Une position minoritaire récuse l'unité d'échange : l'intention représentée comme programme typé par effets réduit la latence jusqu'à 53,4 % et le trafic client jusqu'à 96,1 % [63].

4.2 Le désaccord : prévalence mesurée ou prévalence héritée

Une ligne de travaux mesure l'écosystème MCP et alarme ; un travail mesure l'instrument et l'invalide. Sur 64 611 serveurs uniques dont 37 288 analysables dynamiquement — extension du jeu de données [52] —, les scanners qui déclarent 96,89 % des serveurs « à risque » présentent moins de 50 % de vrais positifs à la validation manuelle et se contredisent entre eux [51]. Le désaccord n'est pas de vocabulaire : deux corpus réels, une divergence sur la validité de l'outil, aucune réplication par un tiers. Deux traits l'aggravent, documentés par les pièces elles-mêmes. Monoculture méthodologique : les études de sécurité MCP partagent un même dispositif, l'audit d'un registre à un instant unique, et aucune n'a mesuré la durée de validité du texte qu'elle juge [58]. Chiffre hérité : le taux de 96,89 % provient de scanners appliqués à peu de cas et se propage par citation — repris, non reproduit [51].

Le même vice se retrouve là où le champ a voulu chiffrer non plus le danger de MCP mais son coût. Les estimations publiées de l'écart entre appel d'outil par MCP et par ligne de commande divergent de plus d'un ordre de grandeur et reposent sur des rapports de praticiens irreproductibles. La première mesure contrôlée à les départager — une tâche logicielle unique de six opérations contre un dépôt git privé, sept échafaudages d'agent, cinq modèles, achèvement vérifié par inspection de l'état du dépôt et non par l'auto-rapport de l'agent — conclut que la comparaison elle-même ne tient pas : treize rapports MCP/CLI strictement appariés s'étalent de 0,43× à 29× [177]. L'effet dominant est l'échafaudage, non l'interface : deux des sept échafaudages n'offrent aucun support MCP, achèvent pourtant chaque exécution en ligne de commande seule, et reviennent de 5,0 à 28 fois moins cher que les cinq qui en offrent — comparaison faite entre exécutions en ligne de commande de part et d'autre, sans serveur MCP attaché nulle part. Et les agents ignorent fréquemment l'interface qui leur est assignée, de sorte qu'une comparaison qui ne vérifie pas le comportement effectif mesure un mélange inconnu [177]. *Prépublication de quatre auteurs ; harnais, tâche, validateur et jeu de données publiés sous licence libre.*

4.3 Ce qu'elle ne traite pas

Manque vérifiable : aucune publication ne rapporte un taux mesuré d'échec, de latence ou de perte sémantique pour une tâche traversant deux protocoles distincts dans un système déployé, sur corpus reproductible. Toutes les mesures d'écosystème portent sur MCP seul [51], [53], [54], [55], [58], [59], [183] ; la seule comparaison implémentée entre deux protocoles est un scénario unique dont les auteurs récusent la généralisation [57] ; la seule interopération hétérogène démontrée ne rapporte aucun taux d'échec [61]. [177] fournit le premier dispositif contrôlé et reproductible du front, mais il oppose MCP à une ligne de commande, non à un second protocole d'agent. Corollaires : aucune mesure longitudinale pour A2A, ACP ou ANP [58] ; aucune propriété formelle vérifiée sur un déploiement réel — 30 propriétés définies sans vérification [60], une équivalence prouvée sans évaluation sur agents [56].

5 La sécurité des agents et de leurs protocoles

5.1 Ce que la littérature établit

Le défaut de fond n'est pas dans le modèle : c'est l'absence d'isolation entre contenu de confiance et contenu non fiable. Quatre pièces y aboutissent par des voies distinctes. La famille des injections de *donnée* — charge déguisée en identifiant de ressource, en origine de données ou en format de réponse d'outil, échappant donc aux défenses conçues contre l'injection d'instruction — est démontrée sur six agents commerciaux nommés, et le diagnostic y est posé comme tel [64]. L'analyse de cause racine des chaînes d'outils parasites, sur 12 230 outils de 1 360 serveurs, l'identifie sous sa forme jumelle : MCP n'offre ni isolation contexte–outil, ni moindre privilège [66]. Le banc de 202 paires injection–tâche sur les fichiers de compétences conclut que ni l'échelle des modèles ni le filtrage d'entrée n'y suffiront [68]. La seule proposition constructive du lot en tire la conséquence : convertir la donnée non fiable en types de portée et de contenu bornés [74].

Deuxième acquis, mesuré sur un même banc : la capacité aggrave l'exposition et l'alignement ne protège pas. Sur 45 serveurs vivants, 353 outils authentiques et 1 312 cas de test évalués sur 20 agents, l'empoisonnement de métadonnées atteint 72,8 % de succès sur le modèle le plus vulnérable du lot, o1-mini ; la susceptibilité croît avec la capacité du modèle, et le taux de refus le plus élevé reste inférieur à 3 %, l'attaque n'employant que des outils légitimes [67]. Un second banc atteint 80 % sur les modèles de pointe [68].

Troisième acquis, décisif pour la lecture de tout le front : les scores de défense obtenus sur bancs statiques ne survivent pas à l'adaptatif. Une défense mesurée à 0 % de succès d'attaque en statique remonte à 28 % au global et 64 % sur les tâches où l'action elle-même est déléguée à du contenu contrôlé par l'attaquant, dès qu'une optimisation en boîte noire et à bas coût la cible — trois suites de tâches, cinq modèles cibles [71]. L'audit de dix défenses sur 60 tâches ouvertes et 560 cas d'injection conclut que presque aucune n'est déployable, chacune étant soit insuffisamment sûre, soit sur-défensive au point d'entamer la fonctionnalité [72]. *Le gel du 9 août écrivait « aucune » : la pièce conclut sur « presque toutes », et la correction est faite ici plutôt qu'en silence.* Sur six systèmes multi-agents et 1 356 cas, les défenses mises au point en environnement simplifié ne transfèrent pas et peuvent créer de nouvelles vulnérabilités [69]. Trois mécanismes de contrôle d'accès publiés tombent à 86,3 % de contournement pour 4,4 % de dégradation d'utilité [73]. Deux attaques enfin sont opposables en production : 14 scénarios contre des assistants déployés, dont 73 % classés en risque élevé à critique avant mitigation par l'éditeur [65], et la famille précitée [64].

Un contre-exemple revendiqué est apparu le 13 août, et son régime décide de sa portée. Un filtrage des unités de réponse par provenance et par attente sémantique ramène le succès d'attaque moyen de 84,7 % à 2,3 % sur six découpages de deux bancs — dont AgentDyn [72] —, en préservant l'utilité bénigne, 92,5 % contre 90,6 % sans défense [185]. *Défense évaluée par ses propres auteurs, sur un seul agent cible, contre des attaques*

adaptatives de type PAIR. Ce n'est pas le régime qui a fait tomber les autres défenses : nulle optimisation en boîte noire ne vient ici cibler la défense elle-même, comme dans [71]. Le contre-exemple est à retenir, non à opposer.

5.2 Où elle se contredit

Premier désaccord, le coût d'utilité de la prévention par construction. Le typage de la donnée non fiable revendique une prévention systématique assortie d'une utilité « forte et non triviale » [74] — revendication adossée à des études de cas non dénombrées, donc auto-évaluation et non évaluation adverse. Deux mesures indépendantes disent l'inverse : l'audit de dix défenses trouve que celles qui tiennent le font par des mesures excessivement défensives dégradant la fonctionnalité [72] ; et le travail qui obtient pourtant le meilleur rabattement du front, de 85–100 % à 0–5 % sur quatre architectures de mémoire, qualifie le déploiement réel de problème ouvert à cause d'un coût d'utilité très variable [70].

Second désaccord, plus lourd. L'écosystème MCP est déclaré criblé de *gadgets* exploitables en conditions réelles, sur 12 230 outils et 1 360 serveurs [66] ; sur un corpus cinquante fois plus grand, l'instrument qui produit ce type de constat est montré faux à plus de moitié [51]. Les deux ne peuvent décrire correctement le même parc, et ce désaccord entame la valeur probante de tous les pourcentages de prévalence du front, y compris ceux repris par les surveys [3], puisque soit la sévérité est sous-décrite, soit une part importante des taux publiés est un artefact d'outil.

Deux pièces de la mi-août tranchent dans le sens de l'artefact, chacune à sa portée. La première audite une campagne d'évaluation de sécurité MCP conservée et montre que le défaut était dans le correcteur : 10 200 lignes d'exécution ramenées à 180 requêtes liées au modèle, 45 requêtes sémantiques et 15 stimuli observables ; la métadonnée de traitement conditionnait la classe ATTACK_SUCCESS, si bien qu'un comportement inchangé changeait de classe sous simple réétiquetage. Une reconstruction aveugle au traitement reclasse 58 étiquettes ATTACK_SUCCESS ou HIJACK_ATTEMPT en achèvements bénins autorisés, tout en préservant trois transferts de données protégées vérifiés et un cas distinct de réacheminement non autorisé ; le recensement verrouillé ne contient plus aucun ATTACK_SUCCESS [178]. *Prépublication de deux auteurs, qui bornent eux-mêmes le résultat à un audit circonscrit à une campagne — ni taux d'attaque de population, ni classement de modèles, ni efficacité de défense. La notice ne nomme pas la campagne auditée, ne la rattache à aucune pièce du présent corpus, et ne dit pas si les auteurs auditent leur propre travail.*

La seconde rend le constat systématique. Réduire la sécurité d'un agent à un taux de succès d'attaque unique confond exposition, exécution, observation et adjudication, et confond une violation réelle avec la visibilité de sa preuve. Sur 1 661 cas répartis sur cinq surfaces de service, six modèles et trois harnais, le taux moyen s'établit à 65,69 % — mais le taux rapporté varie avec le harnais retenu et avec la vue de preuve, et divulguer le contexte d'évaluation change le comportement d'exécution [184]. La pièce vérifie les effets nuisibles sur les reçus de service et l'état final plutôt que sur la sortie de l'agent, et relève un écart reconnaissance–exécution : près d'une violation confirmée sur cinq survient après que l'agent a énoncé la contrainte qu'il enfreint. *Prépublication de neuf auteurs.*

5.3 Ce qu'elle ne traite pas

Aucune pièce ne mesure quoi que ce soit sur un parc d'entreprise en exploitation. Les tailles d'échantillon se comptent en serveurs (64 611 ; 1 360 ; 45), en outils (12 230 ; 353), en cas de test (1 661 ; 1 356 ; 1 312 ; 560 ; 202), en modèles ou agents (20 ; 6 implémentations), en produits (6 nommés ; 14 scénarios) — jamais en organisations, en déploiements ni en incidents observés, sans aucune télémétrie de production.

La lacune de second rang du gel s'est en revanche comblée. La fiabilité des scanners avait été auditée [51] ; celle des dispositifs qui notent les attaques l'est désormais aussi, par un audit de campagne [178] et par un cadre qui mesure l'écart entre taux rapporté et violation vérifiée sur l'état final [184]. Ce qui reste ouvert

n'est plus l'absence d'audit mais son absence de réplication : aucune de ces deux pièces n'a été reproduite par un tiers, et elles ne portent pas sur les mêmes bancs. Demeure enfin la lacune inter-organisationnelle : la seule pièce inter-agents reste intra-système [69], rien ne portant sur la chaîne d'appel entre organisations distinctes.

6 L'identité, la délégation et la révocation

6.1 Ce que la littérature établit

La convergence la plus forte du corpus porte sur l'atténuation : l'autorité doit décroître à chaque saut au lieu de se transmettre intacte, et le jeton porteur relayé tel quel est unanimement tenu pour le mauvais primitif. Elle est obtenue par des travaux qui ne partagent ni méthode ni objet : atténuation de portée de ressource comme opérateur compositionnel, avec preuves formelles et évaluation d'applicabilité [83] ; rétrécissement d'autorité mécaniquement vérifié en TLA+ sur 2,7 M d'états, aux côtés du confinement de cascade et de la reconstructibilité forensique [76] ; chaîne append-only où chaque saut est signé et vérifiable hors ligne, contre l'incapacité d'OAuth 2.0 et des JWT à porter une délégation multi-sauts autorisée par un humain [77] ; capacités bornées par époque se fermant à l'achèvement de la tâche [87]. Le socle proposait déjà des jetons de capacité liés à l'invocation [16].

Deuxième convergence : la validité doit être liée à un événement, non à une horloge. Trois travaux indépendants, qui ne se citent pas et ne partagent ni domaine d'application ni vocabulaire, obtiennent des gains d'ordre cent sur les baux temporels et sur OAuth 2.0. *Les trois ne les obtiennent pas au même régime, et la colonne de droite le dit : un facteur mesuré en simulation et un facteur mesuré sur essaim d'agents réels ne s'additionnent pas.*

Tableau 3 — Trois voies indépendantes vers une validité liée à un événement, chacune avec le régime où son gain a été obtenu.

Pièce	Événement liant la validité	Gain rapporté	Référentiel	Régime de mesure
[75]	compteur d'exécutions, cohérence dirigée	$D \leq n$, indépendant de la vitesse de l'agent ; 120–184×	baux temporels	simulation à événements discrets, 120 exécutions, 3 scénarios
[80]	preuve périodique de vivacité du parent	~90× sur la fenêtre d'agent zombie	OAuth 2.0	couche protocolaire et essaims d'agents réels (GPT-4o-mini)
[87]	achèvement de tâche, poignées bornées par époque	fermeture de l'accès futur, sans facteur chiffré	autorité résiduelle	moniteur de référence, tâches de codage contrôlées, dépôts réels figés

Troisième acquis : l'identité ne suffit pas, c'est l'action qu'il faut prouver. Le contexte de délégation doit être lié pendant l'exécution et non reconstitué après [84] ; la preuve d'action doit être ancrée plutôt que déclarée par l'opérateur [86] ; chez les identités non humaines, une modélisation à l'échelle d'une flotte infonuagique réelle montre que le sur-privilège est un régime temporel et non un état [82]. Le terrain ne tient pas le socle à un seul saut : sur 7 973 serveurs MCP distants, 40,55 % exposent des outils sans aucune authentification, les failles d'enregistrement dynamique de client touchent 96,6 % des serveurs testés [81] ; près de 100 000 enregistrements d'identité multi-chaînes confirment une infrastructure immature [42]. La vérification formelle des spécifications relève enfin 35 lacunes de spécification et 30 défaillances nées de la seule composition : un seul protocole applique effectivement un contrôle de sécurité, aucun n'assigne la responsabilité d'application au comportement inter-protocoles [85].

Le seul parc d'entreprise décrit dans le corpus est arrivé le 11 août. Un rapport de déploiement industriel — des dizaines de serveurs MCP internes montés en une année, chaque équipe ayant implémenté son authentification de son côté, certaines sans aucune, d'autres par clé d'API, d'autres par OAuth complet — place

devant chaque serveur en aval une passerelle unique d'agrégation, de gouvernance et d'authentification : modèle à deux axes croisant la personne, utilisateur interactif ou automate non humain, avec le type de justificatif ; trois octrois d'authentification unique d'entreprise ; trois modèles d'approvisionnement de jeton ; et délégation par échange de jetons RFC 8693 [179]. Le motif déclaré du chantier est ce que la littérature du front traite le moins : autoriser les appelants de façon cohérente, savoir qui a fait quoi, et retirer ses accès à un employé qui part, à l'échelle du parc. *Rapport d'expérience de trois auteurs : aucune mesure, aucun taux, aucun effectif au-delà de « des dizaines de serveurs ». Sa notice ne dit rien de l'atténuation d'autorité par saut, ni pour ni contre. Elle atteste d'une architecture en production, pas d'un résultat.*

6.2 Où elle se contredit

Premier désaccord, l'emplacement de la racine de confiance et son prix opérationnel. Une position soutient qu'aucune preuve d'action n'est opposable sans ancrage matériel — architecture IETF RATS composée avec des paquets de preuves d'action et une mesure d'intégrité TPM, l'objet vérifié étant la production effective de la sortie par la version de modèle annoncée sur du matériel non modifié [86]. Deux travaux revendiquent l'opposabilité sans matériel spécialisé ni vérificateur en ligne : vérification hors ligne à la seule clé publique Ed25519 de l'émetteur [77] ; fraîcheur appliquée avec les seules clés en cache et l'horloge locale du vérificateur [80]. Le désaccord est symétrique dans ses coûts : le premier camp exige une infrastructure d'attestation que la quasi-totalité des parcs d'entreprise n'a pas ; le second accepte structurellement qu'un agent compromis mais vivant signe des sauts parfaitement valides.

Second désaccord, un arbitrage de type CAP déguisé en question d'identité. Borner les opérations non autorisées indépendamment de la vitesse de l'agent suppose, par l'analogie même avec la cohérence mémoire qui fonde le résultat, un point de sérialisation partagé [75]. L'autre position refuse tout aller-retour réseau au moment de la vérification et assume en contrepartie une fenêtre résiduelle égale à l'intervalle de battement [80]. Aucune des deux pièces ne reconnaît la position adverse : le champ n'a pas nommé l'arbitrage qu'il pratique.

6.3 Ce qu'elle ne traite pas

Toutes ces pièces bornent la fenêtre pendant laquelle un agent révoqué agit encore ; aucune ne dit ce qu'il advient des effets et des sous-délégations déjà émis quand un saut amont est invalidé après coup. Il n'existe ni sémantique de compensation en cascade, ni critère décidant quels effets aval sont annulables. La lacune est vérifiable par lecture : un compte d'opérations non autorisées est borné [75], une fenêtre est bornée [80], un accès futur est fermé [87] — tous en régime purement préventif. Deux constats l'aggravent : des traces d'exécution identiques peuvent correspondre à plusieurs assignations de délégation mutuellement incompatibles, si bien que l'ensemble des effets à compenser n'est pas calculable a posteriori [84] ; et aucun des quatre régimes réglementaires européens examinés — règlement IA, RGPD, règlement Machines, directive Responsabilité du fait des produits — ne définit à qui incombe cette compensation, la dégradation de la chaîne de consentement restant non traitée dans ses dimensions centrales [79].

Une pièce du 12 août traite la moitié informationnelle du problème, et il faut resserrer la lacune d'autant. Un modèle bitemporel à admission liée à la source décide si un enregistrement contradictoire, remplacé, rétracté, supprimé ou périmé peut encore étayer une affirmation sortante, par cinq clauses exécutables dont la non-résurrection après rétractation ou suppression ; sur un banc de 3 600 cas figé par empreinte, la voie gouvernée reproduit tous les dénouements complets, quand la meilleure de trois politiques complètes simples n'en apparie que la moitié [186]. *Auteur unique ; la pièce borne elle-même sa portée à des résultats de contrat et d'implémentation, non à une exactitude en monde ouvert.* Ce qu'elle gouverne, ce sont les enregistrements et les affirmations qui en dérivent. Les effets déjà produits et les sous-délégations déjà consenties

restent sans sémantique de compensation : chaîner les droits de façon vérifiable, et même chaîner la validité des faits, ne dit rien du chaînage des conséquences.

7 Les systèmes multi-agents : orchestration et défaillance

7.1 Ce que la littérature établit

Sur les journaux de 127 systèmes multi-agents rassemblés par le jeu Who&When, la meilleure attribution automatique trouve l'agent fautif dans 53,5 % des cas et l'étape décisive dans 14,2 %, plusieurs méthodes faisant moins bien que le hasard [88]. Ce plafond est celui d'un banc, non celui de la tâche. Un modèle de contextualisation agent–étape déposé le 11 août rapporte 81,58 % sur l'agent fautif et 63,90 % sur l'étape fautive, contre 78,20 % et 56,33 % pour sa meilleure ligne de base — mais sur deux autres bancs, TracerTraj et Aegis-Bench, Who&When ne lui servant que d'épreuve hors domaine [187]. *Prépublication non révisée par les pairs : les auteurs y mesurent leur propre modèle.* Les traces complètes — entrées et contexte, non les seules sorties — améliorent quant à elles l'attribution jusqu'à 76 % contre une observation partielle [89], gain relatif sans effectif ni condition nommée. Trois mesures d'attribution, trois bancs, aucun dénominateur commun : sur ce front, le chiffre d'attribution est d'abord une propriété du banc. MAST impute ces échecs à la coordination plutôt qu'au modèle de base, sur plus de 1 600 traces annotées [48] ; sur six cadriciels, une erreur atomique unique fige un faux consensus [90]. La coordination s'isole comme couche, à modèle, outils et invite figés [91].

Le rendement du multi-agent est non monotone. Un agent unique bien invité égale presque la meilleure discussion multi-agents, qui ne l'emporte que sans démonstration dans l'invite [92] ; sur six bancs et 245 caractéristiques, l'agent unique gagne dans environ 43,3 % des cas [95] ; les architectures engendrées automatiquement restent sous la chaîne de pensée avec auto-cohérence, à coût jusqu'à dix fois supérieur [94]. Les favorables ne l'infirment pas : la loi d'échelle collaborative, établie jusqu'à plus d'un millier d'agents, est logistique donc saturante [96] ; l'optimisation entrelacée invites-topologie-invites fait dépendre la performance davantage du réglage des invites que du patron topologique [97]. Le surcoût de coordination va de 1,15× à 2,3× selon le patron sur 10 000 dépôts SEC rejoués [98] ; la supervision d'exécution en récupère −29,68 % de jetons sans perte de succès sur GAIA [99].

Une pièce du 13 août atteint le calcul qui justifie la redondance, en amont de toute architecture. Les bornes de fiabilité compositionnelle multiplient les fiabilités des composants, opération que seule autorise une hypothèse d'indépendance conditionnelle qu'on énonce couramment et qu'on ne teste jamais. Testée, elle tombe : deux instances d'un même modèle, en passage de main à deux agents, échouent ensemble sur 90,0 % des missions où l'une des deux échoue, et l'erreur a un signe qui joue contre l'exploitant — la redondance est sur-créditée exactement quand les composants partagent un modèle [180]. *Évaluation préenregistrée sur 18 000 missions, notées par du code déterministe et sans juge modèle : le régime de mesure le plus exigeant du front. La pièce est rattachée à la chorégraphie et à l'essaim, où son dispositif est instruit au complet.*

7.2 Où le désaccord est réel

Le clivage sur l'utilité du multi-agent suit la méthode, non l'objet ; la ligne de base dite forte s'entend comme invite riche, auto-cohérence et ensemblage. Une pièce tranche en partie : le débat multi-agents n'est pas intrinsèquement inférieur, il est hypersensible aux hyperparamètres et redevient compétitif après réglage [93]. Tout résultat mesure donc d'abord l'effort de réglage consenti à chaque bras, qu'aucune pièce du front n'égalise.

Tableau 4 — Les quatorze pièces du front retenues au gel du 9 août : onze évaluent une construction de leurs auteurs et quatre annoncent un comité de lecture ; les quatre évaluations indépendantes contre ligne de base forte concluent toutes au non-avantage.

Position	Système évalué	Ligne de base	Pièces
Avantage du multi-agent	architecture des auteurs	non optimisée	[96], [97]
Non-avantage	architecture de tiers	forte	[92], [93], [95], [94]

[180] ne prend pas parti dans ce clivage, et c'est ce qui lui donne son poids : il n'oppose pas une architecture à une autre, il éprouve une hypothèse dont les deux camps se servent. Tant que la dépendance entre composants n'est pas mesurée, une fiabilité annoncée par composition n'est pas une fiabilité mesurée — et l'échappatoire est fermée : ajuster un modèle de dépendance fait pire que s'en passer, la pièce prouvant qu'une borne bootstrap sur la fonctionnelle d'un modèle ajusté perd la couverture de la vérité à mesure que n croît, l'écart d'identification étant en O(1) quand la correction bootstrap n'est qu'en O(n^−1/2). *Plus de données rend alors le certificat plus faux, sans symptôme visible.*

Second désaccord : ce que résout la traçabilité. Levier de diagnostic principal pour [89], elle laisse échapper un canal d'état — un contexte toxique compressé en résumé passe sous le seuil des détecteurs en augmentant la toxicité en aval [100] : instrumenter davantage et gouverner l'écriture en mémoire sont deux corollaires opposés. Même partage sur la supervision : machine, elle réduit le coût sans perte [99] ; humaine et fatigable, elle suit un U inversé, la sécurité réalisée se dégradant au-delà d'un seuil d'escalade (125 actions étiquetées, kappa de Fleiss = 0,52, auteur unique) [101].

7.3 Ce qui n'est pas traité

Aucune pièce ne mesure un assemblage en exploitation d'entreprise, taux de défaillance observé sur durée et volume réels. Les mesures portent sur des bancs académiques, des corpus hors ligne (10 000 documents [98]), des marchés de prédiction (100 marchés [91]), des journaux a posteriori (127 systèmes [88]), des missions synthétiques en dispositif contrôlé (18 000 [180]) ; le 41 à 87 % d'échec « en production » est repris de la littérature par [91], non mesuré par son protocole. Manque également toute comparaison contrôlée des patrons d'orchestration — superviseur, transfert, graphe, marché — à modèle, invite, outils et budget figés sur plusieurs domaines. Deux pièces s'en approchent : [98] compare les patrons, sur un domaine unique et sans comité de lecture ; [91] fige modèle, invite et outils, sur cinq configurations d'un seul modèle. La seule normalisation multi-bancs du corpus porte sur des architectures, non sur ces patrons [159].

8 L'évaluation, les bancs d'essai et l'observabilité

8.1 Ce que la littérature établit

Le score publié n'est pas ce qui s'observe, et cinq voies indépendantes l'établissent. Défauts de conception : tests insuffisants, réponses vides comptées comme succès et récompenses mal spécifiées faussent les scores des bancs les plus utilisés [107]. Généralisation : une part substantielle de la performance sur SWE-bench Verified relève de la mémorisation du dépôt, les mêmes modèles chutant fortement sur des tâches hors distribution appariées [108]. Enchaînement en exploitation : sur une chaîne de construction de compilateur à dépendances sérielles, la réussite s'effondre de 100 % au premier étage à 20 % au dernier, aucun des 15 modèles n'achevant le pipeline [105]. Les bancs d'entreprise donnent la même pente : environ 30 % de tâches professionnelles achevées en autonomie dans une entreprise logicielle simulée [102], 58 % en tour unique contre 35 % en multi-tours sur des scénarios d'affaires [104].

Transport d'exécution, quatrième voie. Un banc de 56 tâches en un coup, tirées de 14 familles dérivées d'incidents réels, croise le contrat de génération avec le chemin d'exécution autour d'un analyseur

syntaxique délibérément ajouté et non échappé. Rejouer la même réponse à travers cet analyseur fait chuter la réussite de 55,4 à 73,2 points selon huit configurations comparables ; divulguer la frontière au modèle en récupère 30,4 à 60,7 points pour six d'entre elles, zéro ou légèrement négatif pour les deux autres. Un modèle dont l'écart de score apparié n'est que de −3,6 points cache ainsi −64,3 points de dégât et +60,7 points de compensation, et la configuration de déploiement réordonne les modèles : sur 26 paires comparables, un renversement est net et quatre autres tiennent à une tâche près [181]. La génération brute est presque saturée à la frontière ; ce qui sépare encore les modèles est leur adaptation à cette frontière. Le score n'est donc pas une propriété du modèle mais du montage, et une évaluation qui ne déclare pas sa configuration de modèle, son contrat de génération, son chemin d'exécution, son point de fonctionnement et son validateur d'état final ne dit pas de quoi elle parle. *Prépublication de quatre auteurs.*

Décomposition de variance, cinquième voie, et la plus radicale. Sur trois bancs ouverts de traces d'agents — dont TheAgentCompany [102] —, l'effet propre de l'agent explique moins de 3 % de la variance totale dans chaque jeu et chaque type de contrôle, quand l'interaction agent × tâche en explique de 7 à 23 % ; la fiabilité agrégée s'effondre sur le quartile de tâches le plus dur, un coefficient tombant de 0,752 à 0,000 ; et la fiabilité mesurée en cellule d'entraînement est négativement corrélée à la fiabilité hors échantillon, à r = −0,90 [190]. Sur la taxinomie d'échecs MAST [48], les profils relevés trace par trace sont idiosyncrasiques quand les profils par cellule se généralisent. *Décomposition à quatre facettes, trois estimateurs concordant à trois décimales, artefacts publiés ; auteur unique, prépublication.* La conclusion excède les quatre autres voies : un classement d'agents ne classe pas des capacités, il classe des spécialisations.

Deuxième acquis : le coût et le régime d'exécution sont des dimensions d'évaluation, non des annexes. L'exactitude seule est vide de sens sans axe de coût, et l'absence de jeu de retenue rend les scores irreproductibles [106] ; en exploitation, la dépense varie de trois ordres de grandeur entre modèles de qualité comparable [105] ; le prix de l'auditabilité se chiffre à son tour, **8,3 ms de surcoût médian** pour une médiation pré-exécution à traces infalsifiables, mesurés sur 1 000 interceptions consécutives d'appels d'outil — P95 à 14,7 ms, P99 à 23,1 ms, 1,2 % de faux positifs sur 500 appels bénins [113]. *Ce chiffre et les 617 constats de sécurité relevés par analyse statique dans six projets ouverts sont deux mesures distinctes de la même pièce ; le gel du 9 août les présentait comme une seule.*

Troisième acquis : la trace est devenue l'objet évalué, et les modèles la lisent mal. Sur 148 traces annotées par des humains, collectées au format d'observabilité réellement déployé, le meilleur modèle à long contexte n'atteint que 11 % en localisation d'anomalie [111]. La provenance doit relier l'invite, la décision, l'appel d'outil et le résultat en aval [112] ; l'auditabilité se décompose en cinq dimensions — recouvrabilité de l'action, couverture du cycle de vie, vérifiabilité de la politique, attribution de responsabilité, intégrité de la preuve —, et la pièce désigne l'intégrité de la preuve et la couverture du cycle de vie comme les plus négligées de tous les travaux qu'elle recense [113]. *Le gel du 9 août désignait à cette place l'attribution de responsabilité ; la pièce, v1 comme v2, nomme les deux autres.*

8.2 Où le désaccord est réel

Le litige dur porte sur l'évaluateur automatique. Une pièce conclut qu'un juge agentique, notant les étapes intermédiaires et non le seul résultat, s'approche de la fiabilité humaine à une fraction du coût [110]. Une autre démontre l'inverse au niveau du principe : dès lors que le juge n'est pas plus exact que l'évalué, aucune méthode de débiaisage ne réduit de plus de moitié le besoin d'étiquettes de référence [109]. Le désaccord oppose une mesure empirique à un plafond théorique et n'est pas dissoluble par davantage de données ; la mesure empirique est de surcroît auto-arbitrée, les mêmes auteurs publiant le banc (55 tâches, 365 exigences) et le juge qui y domine [110]. Deux autres conflits d'intérêts sont vérifiés : un banc d'entreprise partage quatre auteurs avec le système de référence qu'il mesure [102], [103] ; un banc d'affaires est publié par le fournisseur du produit agentique concurrent du domaine évalué [104].

Une pièce du 10 août déplace la question en amont du juge. Toute une classe de portes de qualité expédiées dans les cadriciels d'agents — filtres de déduplication, caches sémantiques, gardes de dérive, correcteurs de réponse — décide à un seuil de similarité cosinus, c'est-à-dire mesure de combien la formulation a changé, quand la question posée est si le sens a changé. Les deux divergent précisément sur les cas que ces portes existent pour attraper : la garde de dérive en production auditée n'a détecté aucune des 56 mutations qui rompent le sens, dont « withhold the study drug » devenu « administer the study drug », approuvé à un cosinus de 0,9608 ; sur 90 cellules de configuration, de seuil et de tâche, l'exactitude équilibrée ne dépasse jamais 0,700, pour une médiane de 0,525. Le même biais corrompt l'évaluation censée le détecter : un corpus construit naïvement en hérite et peut rendre un verdict inversé, l'AUROC de décision valant exactement 0,000 dans 13 cellules sur 18 [188]. *Auteur unique ; corpus, harnais et résultats figés publiés — et la pièce rapporte que le biais avait d'abord pris deux fois ses propres conclusions.*

Second désaccord : l'auditabilité s'obtient-elle par lecture a posteriori de la trace ou par médiation à l'exécution ? Le programme dominant instrumente puis analyse [111], [112]. Une pièce le tient pour structurellement borné : deux attributions de mandat incompatibles peuvent produire des traces strictement identiques, la télémétrie usuelle étant sémantiquement insuffisante pour reconstruire la propagation d'autorité [84]. Deux pièces de la mi-août prennent le second parti et le chiffrent. Une couche de mémoire à provenance typée exclut les enregistrements inéligibles, repondère les éligibles par confiance multiplicative de chemin et applique une porte sensible au risque avant exécution : sur 2 700 tâches synthétiques par méthode et trois domaines, 94,96 % de réussite et 72,70 % de décision exacte, d'où la thèse de la provenance comme signal de contrôle opérationnel plutôt que comme métadonnée d'audit a posteriori [189]. *Banc synthétique construit par ses auteurs, conclusion qu'ils bornent au cadre évalué.* L'autre définit l'exécution gouvernée par une provenance inspectable et mesure ce qu'elle coûte [182].

8.3 Ce qui n'est pas traité

La trace comme preuve reste hors banc, mais l'énoncé du gel était trop large. Les bancs d'entreprise notent l'état final [102], [104], [105] ; les corpus de traces notent la localisation d'erreur [111], [48] ; l'auditabilité est proposée comme modèle de données [112], [84]. [113], lui, mesure bel et bien une reconstruction : son expérience de traçage implicite retrouve, sur des sorties dépouillées de leurs métadonnées et sous trois conditions de dégradation — retrait d'identité, corruption de frontière, caviardage —, une attribution de jetons voisine de 0,95, un recouvrement de segments d'environ 0,93 et une similarité d'arêtes approchant 0,96, sur des topologies de quatre à six agents en chaîne, en étoile et en arbre. *Auto-évaluation sur banc maison, sans arbitrage.* Ce qu'il reconstruit est la structure d'interaction, non le mandat.

Il n'existe donc toujours aucun banc dont le critère de réussite soit : à partir de cette trace, un tiers peut-il reconstruire qui a mandaté quoi, et imputer la responsabilité ? Une pièce du 13 août s'en approche par un autre bord : elle définit l'exécution gouvernée comme un travail dont les décisions, l'achèvement et la réaction au changement sont adossés à une provenance inspectable, et ses comparaisons contrôlées montrent que le chemin gouverné et le chemin direct atteignent souvent le même résultat, seul le premier conservant la preuve de l'autorité, refusant la clôture non étayée et bornant la reprise aux seules tâches dépendantes [182]. Elle rapporte aussi son propre échec — une épreuve de transfert entre rôles séparés où le contrat de complétude appliqué de façon déterministe sur-bloque massivement des paquets produits hors de son contexte de rédaction — et refuse de se présenter comme un gain d'exactitude. *Prépublication d'un seul auteur.* Restent non arbitrées les deux propositions qui lient contexte de délégation et exécution : prépublication de deux auteurs [84], auto-évaluation sur banc maison [76].

9 La couche transactionnelle : paiements, marchés, réputation

9.1 Ce que la littérature établit

Le mandat signé n'est pas le point de rupture ; ses deux bords le sont. En amont, l'intention que la signature scelle est déjà falsifiable : deux injections dans le contexte d'un agent d'achat de référence détournent le classement produit et exfiltrent des données utilisateur (90 à 100 % de réussite) [116]. En aval, les garanties de signature tiennent au niveau de la spécification mais pas à l'exécution — reprises, concurrence, orchestration —, défaut qu'une vérification à consommation unique et liaison de contexte corrige en banc de charge (~3,8 ms à 10 000 tr/s) [117]. Les deux systématisations nomment le même défaut autrement : liaison d'intention faible et découplage paiement/service [115] ; autorisation traitée comme une dimension parmi cinq qu'aucun protocole ne couvre entièrement [114]. C'est la seule convergence du front où mesure et systématisation disent la même chose.

Deuxième acquis, non contesté : des agents tarificateurs en langue naturelle atteignent en oligopole des prix supra-concurrentiels sans communication explicite, l'ampleur dépendant de formulations anodines de l'invite [119]. Le phénomène est retrouvé sous auto-optimisation des invites [121] et pris comme point de départ par la pièce qui n'en discute que la stabilité [120].

Troisième acquis : la réputation telle qu'implémentée ne porte aucun signal exploitable. Sur trois chaînes, la plupart des identités enregistrées n'exposent aucun point de service actif, les scores sont Sybil-attaquables par construction et la majorité des avis n'a aucun ancrage vérifiable [118] ; le socle établit par ailleurs que ces agents manquent de l'ancrage identitaire que présuppose tout mécanisme réputationnel [44]. Les marchés agentiques restent manipulables du côté vendeur [122], [124]. Le seul correctif qui déplace l'aiguille est économique — garantie exécutable, séquestre, sanction — et non réputationnel.

9.2 Où le désaccord est réel

La collusion algorithmique est-elle un régime ou un artefact d'homogénéité ? Des stratégies collusoires stables et généralisantes émergent dès que les agents raffinent eux-mêmes leurs invites [121] ; à l'inverse, l'hétérogénéité fait chuter le surprix de 22 % à 10 % par la patience et à 7 % par l'asymétrie d'accès aux données, et aucune collusion soutenue n'est observée sur 1 000 périodes entre Q-learning et LLM [120]. Les deux mesurent des agents simulés en oligopole et divergent sur ce qui constitue le cas de base. L'arbitrage est empirique et personne ne l'a fait : si les marchés réels convergent vers deux ou trois modèles frontière, l'homogénéité est le cas réaliste et l'hétérogénéité le laboratoire. Aucune pièce ne mesure la population effective de modèles tarificateurs.

Second litige : les agents sont-ils des agents économiques compétents ? Quasi optimaux en conditions idéales, dégradés à mesure que le nombre d'options croît [122] ; déficitaires en raisonnement stratégique en négociation libre [123] ; non superposables au comportement humain sous mêmes institutions, dans la seule pièce à se donner un étalon humain [125] ; instables au point qu'un changement de modèle réordonne les préférences d'achat [124]. Le désaccord porte moins sur les agents que sur le protocole : structurés, ils s'en sortent ; en langue libre, ils échouent. Aucune pièce ne teste les deux régimes sur le même marché.

9.3 Régimes de preuve et lacunes

Tableau 5 — Régimes probatoires des douze pièces ; la seule mesure en production porte sur un registre de réputation, non sur un flux de paiement.

Régime probatoire	Pièces	Part
Mesuré sur système déployé	[118], registres sur trois chaînes	1 / 12

Régime probatoire	Pièces	Part
Mesuré sur implémentation de référence ou banc de charge	[116], [117]	2 / 12
Simulé en environnement synthétique	[119], [120], [121], [122], [123], [124], [125]	7 / 12
Systématisé ou argumenté, sans donnée propre	[114], [115]	2 / 12

Aucune pièce ne mesure de transaction réelle à valeur réelle sur une pile de paiement agentique en exploitation : tout énoncé sur le comportement des agents payeurs repose sur de la simulation. Le seul chiffre de volume du corpus est repris d'un texte de spécification et qualifié de non audité par les auteurs eux-mêmes [114].

Première lacune : aucune pièce ne traite la responsabilité d'une transaction non autorisée. Aucun travail ne modélise la répartition entre émetteur, acquéreur, marchand et fournisseur d'agent ; aucun ne confronte un mandat correctement circonscrit au régime de rétrofacturation existant ; aucun ne mesure un taux de contestation. Le contrôle porte sur le domaine entier et ne rend qu'une pièce principal-agent conceptuelle et jamais transactionnelle [142], une cartographie de conformité muette sur le contrat et le paiement [138], et une pile assurantielle qui présuppose résolue l'allocation de responsabilité qu'elle ne traite pas [45].

Seconde lacune, plus dure : la littérature raisonne sur une pile qui n'existe pas, et la fracture est visible dans les bibliographies. La systématisation la plus complète du règlement couvre x402, MPP, ERC-4337, Permit2, EIP-8004, Kite, Skyfire et Tempo, et ne mentionne ni AP2, ni ACP, ni L402 [115] ; symétriquement, les deux pièces AP2 ignorent x402 [116], [117]. Une seule pose les piles côte à côte, conclut à la fragmentation et date l'état de maintenance des spécifications qu'elle traite : AP2 sans implémentation de référence adoptée, ERC-8004 à déploiement limité, MPP le plus mûr [114]. Personne ne propose ni ne mesure un vocabulaire de capacités partagé ; le cadre analytique en quatre étapes fabriqué a posteriori pour comparer des protocoles sans terme commun [115] est le symptôme, non le remède. Les économistes présentent l'angle mort inverse : indifférents au rail de paiement [119], [124], [125], leurs résultats survivront à n'importe quelle obsolescence de spécification, mais restent muets sur l'autorisation et le règlement. Aucune pièce ne tient ensemble la formation du prix et le rail qui l'exécute.

Reprise du 15 août 2026 : aucune des douze notices du front n'a bougé depuis le gel, et la fenêtre du 9 au 15 août n'a rien livré qui touche le rail de paiement, le taux de contestation ou la population de modèles tarificateurs. Le front est inchangé, et ses deux lacunes le sont aussi.

10 Les processus d'affaires et l'exécution durable

10.1 Ce qui est établi

L'installé est enveloppé, pas remplacé. Le mouvement dominant ne substitue pas l'agent au moteur de processus : il l'encercle. Le harnais CUGA FLO place une couche agentique régie par politiques autour d'un moteur de workflow déterministe qui conserve l'autorité d'exécution [132] ; l'agenda neuro-symbolique fait des modèles de processus typés et des contraintes de conformité des composants architecturaux de l'agent, non une surveillance externe [131] ; l'architecture CHAI subordonne le modèle de langue à un graphe DCR qui encode les obligations légales et pilote le dialogue [137]. L'agent n'intervient qu'à des points de contrôle nommés — décider, adapter, formuler — jamais sur la trajectoire entière. La ligne prolonge les travaux d'ouverture sur les modèles de langue en gestion des processus [31], [37] et le relevé des perspectives praticiennes sur la gouvernance des agents en processus [32].

La fiabilité vient d'une couche transactionnelle en aval, pas du modèle. Ce que produit le modèle y est une proposition, jamais un effet. Atomix établit que le retour d'outil est une frontière de règlement fausse et

n'engage les effets externes qu'une fois écartée toute arrivée concurrente antérieure [126]. Mnemosyne soumet toute action produite par un modèle à un contrôle d'admission déterministe et démontre que la correction de l'état engagé devient indépendante de la compétence du proposant, à moins de 6 % de surcoût [127]. La formalisation en TLA+ de quatre anomalies de concurrence des exécutifs multi-agents, avec exécutif Rust prouvé, fournit à cette thèse ses premières garanties mécanisées [128]. La filiation est assumée : le patron Saga [175] plutôt que l'ACID strict, et la sémantique de l'exécution durable [176] pour la persistance de l'état.

La gouvernance passe par la conversion de la trace en journal de processus standardisé. Traduire traces de raisonnement, appels d'outils et coûts en jetons vers un modèle d'événements normalisé est posé comme la précondition de l'audit, et dix-huit praticiens tiennent la transparence comportementale pour un prérequis de la confiance [130]. Les mêmes journaux servent en retour à engendrer les agents : la fouille de processus sur les enregistrements d'un dépôt découvre les rôles propres au projet et en produit les spécifications [135]. La ligne prolonge l'observabilité de la variabilité comportementale [38] et l'évaluation des modèles sur les tâches de fouille [39] ; le programme de la gestion agentique des processus [33], [34] en fait sa condition d'entrée.

10.2 Le désaccord dur : atomicité contre réversibilité

Tableau 6 — Deux ontologies incompatibles de la fiabilité agentique, non deux réglages d'un même paramètre.

	Atomicité [126], [127], [128]	Réversibilité [129]
Unité de fiabilité	la frontière de règlement	la position de l'action sur l'échelle idempotent / réversible /compensable / irréversible
Statut de l'effet	invisible avant engagement	émis, puis révisé
Place de l'humain	hors transaction	concurrente de l'exécution
Borne de l'agent	ce qu'on peut valider	ce qu'on peut défaire

Revisable by Design rejette explicitement le paradigme transactionnel et pose que la flexibilité d'un agent est bornée par sa réversibilité [129]. Sous réversibilité, l'effet est visible et possiblement faux pendant un intervalle borné, et la correction est un flux, non une porte. Adopter l'un rend l'autre inatteignable : on ne peut pas simultanément suspendre l'effet jusqu'à la certitude et l'émettre pour organiser sa révision. Aucune pièce du corpus ne compose les deux régimes ni ne fournit de critère pour choisir entre eux selon la classe d'effet.

Second désaccord, moins tranché mais structurant : le modèle de processus est-il prescriptif *a priori* ou découvert *a posteriori* ? Le métamodèle BPMN étendu de constructions natives d'agent [133], le langage de protocole faisant des portes d'approbation humaine des invariants applicables [134] et le contrôleur DCR [137] écrivent le formalisme d'avance ; la génération de règles par modèle de langue relève du même geste [36]. La fouille inverse la causalité : le modèle est extrait des journaux et sert à produire les agents [135] ou la gouvernance [130]. Même communauté, directions opposées, et aucune des deux ne traite l'autre comme un cas particulier.

10.3 Ce que la littérature ne traite pas

Personne ne mesure la conformité d'exécution d'un agent à un modèle de processus. Le contrôle de conformité au sens de la discipline — aligner une trace réelle contre un modèle de référence, quantifier *fitness* et précision — n'est appliqué à aucune trace d'agent autonome. [130] produit le journal mais s'arrête à la découverte et à la gouvernance ; [131] énonce la conformité par construction comme agenda et non comme résultat mesuré ; [136] évalue le modèle produit, jamais l'exécution. Contrôle vérifiable, refait à l'API du dépôt le 15 août 2026 et de compte inchangé depuis le gel : la requête `"conformance checking"`

`AND "LLM"` rend sept entrées, la plus récente du 8 juin 2026, dont aucune ne porte sur des traces d'agents autonomes — celles qui s'en approchent alignent des plans ou du code, pas l'exécution d'un agent contre un modèle métier.

11 La gouvernance, le risque et la responsabilité

11.1 Ce qui est établi

Aucune pièce ne réclame la personnalité juridique de l'agent. Trois disciplines aboutissent à la même structure. En droit de la responsabilité délictuelle, l'imputation se fait par type d'interaction — dérive autonome, usage-outil, planification collaborative — et les journaux d'interaction deviennent le moyen de preuve situant l'écart à l'action autorisée [140]. En analyse économique du droit, le cadre principal-agent distingue les problèmes inhérents à la délégation de ceux qui émergent de la composition multi-agents [142]. En droit du mandat, les devoirs de divulgation et de loyauté ne sont pas encodés par les architectures d'agents et doivent devenir contrainte de conception [141]. Toutes remontent au mandant humain, et toutes conditionnent cette remontée à un enregistrement d'exécution.

L'auditabilité est posée comme condition préalable de la conformité, non comme son corollaire. L'informatique le pose formellement — pas de responsabilité sans auditabilité — et le mesure : lacunes répandues dans des projets d'agents libres, surcoût faible des enregistrements infalsifiables [113]. *Cette pièce a été étendue le 13 août 2026 : ses mesures ne bougent pas, mais son régime change — elle annonce désormais, au seul champ de commentaire, une version condensée dans les actes d'un sommet ACM, à une piste de « papiers visionnaires ».* Le droit en tire la conséquence la plus dure du corpus : un système à haut risque dont la dérive est intraçable ne peut satisfaire les exigences essentielles du règlement européen [138]. Le relevé documentaire, à cheval sur l'informatique et la politique publique, constate côté offre que la documentation de sûreté est majoritairement absente des systèmes déployés [144]. Le constat rejoint l'inexpressivité relevée des protocoles [21] et les cadres de gestion du risque [20], [174].

Ce que la capacité du modèle n'achète pas, c'est la rejouabilité de sa décision. Une mesure déposée le 11 août 2026 déplace la question d'un cran, de la disponibilité des journaux vers la reproductibilité de l'acte : sur neuf versions de modèles, d'un modèle local de trois milliards de paramètres à un système frontière commercial, les commandes dont dépend le rejeu appartiennent au fournisseur et non au déployeur — le système frontière refuse température, top_p et top_k et n'expose aucune graine. Sous les commandes les plus serrées que chaque point d'accès admet, le modèle local rejoue 320 exécutions sur 320, les modèles hébergés 319 sur 320 et 959 sur 960 ; l'architecture d'orchestration modifie l'action finale et aucun enregistrement d'exécution ne se répète, à aucune configuration ni à aucune échelle ; et deux versions déterministes d'un modèle de crédit rejouent chacune parfaitement leur action courante sans pouvoir retrouver l'action historique [191]. *La reproductibilité n'y est pas un scalaire mais un profil, et l'autorité déléguée n'est défendable que tant que la preuve conservée en soutient l'exercice.* Régime : prépublication non révisée par les pairs, d'un auteur unique, trois études sur ses propres montages, non répliquées ; l'énoncé d'ouverture sur l'ampleur de la délégation en finance y est argumenté, non mesuré.

La supervision humaine n'est démontrée nulle part comme contrôle effectif. Le droit établit que le règlement charge la supervision humaine de corriger le biais d'automatisation sans base empirique attestant qu'elle y parvient, et avec une répartition contestable entre fournisseur et déployeur [143]. L'enquête de terrain en santé, relevant de l'informatique et de l'interaction humain-machine, observe une supervision quasi totale : non un contrôle calibré, mais un frein imposé par la responsabilité [147].

11.2 Deux désaccords, dont un de prémisse

Le premier porte sur le lieu de la défaillance réglementaire. Le droit répond que le règlement est opérationnalisable sous condition, une architecture de conformité étant constructible dans le droit existant, l'obstacle restant technique [138]. La politique publique répond que le déficit est institutionnel — surveillance, mise en application, ressources — et qu'aucune architecture côté fournisseur ne le comble [139]. La revue de gouvernance émergente cartographie ce front sans l'arbitrer, et qualifie elle-même son évaluation de préliminaire [145].

Le second est plus grave : c'est un désaccord de prémisse factuelle. La littérature juridique légifère sur des agents déployés à l'échelle, planifiant et exécutant des chaînes d'actions avec implication humaine réduite [138], [139], [140]. Les pièces empiriques documentent l'inverse : autonomie opérationnelle marginale en santé [147] ; en génie logiciel, une erreur de calibration de 43 points entre vitesse anticipée et ralentissement mesuré, et des gains quasi nuls en documentation clinique [148]. Les deux camps ne se citent pas, et ils ne sont pas arbitrables entre eux : la doctrine établit par interprétation de textes et cohérence, la mesure d'effet par entretiens codés ou observation. Une doctrine n'est pas réfutée par vingt entretiens, ni une mesure par une exégèse. La revue enregistre l'écart plutôt qu'elle ne le tranche.

La pièce sectorielle du corpus, du côté de la finance quantitative, a été révisée le 10 août 2026, et sa révision est instructive au-delà de son contenu : le texte double de volume et sépare désormais explicitement ses deux régimes de preuve — deux illustrations synthétiques calibrées, dont le moniteur de dérive à covariance de regret et la simulation d'encombrement portant le risque de perte conjointe de 39,2 % à 79,3 %, et trois cas réels documentés, dont un jugement de tribunal tenant un transporteur aérien responsable de son agent conversationnel [146]. Ce que la première version présentait comme un instrument détectant la dérive à partir des seules données observées est requalifié par ses auteurs en démonstration de calculabilité. Son chiffre d'accroche, lui, reste nu au résumé des deux versions : 88 % des professionnels de la finance interrogés déclarent n'avoir aucun cadre de gouvernance opérationnel pour l'IA agentique [146]. La qualification de ce chiffre ne se lit qu'au corps de la deuxième version — sondage informel sur un réseau professionnel, mai 2026, échantillon auto-sélectionné dont les auteurs reconnaissent le biais, section 3.1 du rendu HTML consulté le 15 août 2026 — et elle n'est vérifiable ni à la notice ni au résumé. *La mise en garde de cette revue tient donc toujours : un chiffre que son propre auteur qualifie à l'intérieur du texte reste, pour qui ne lit que la notice, un chiffre non qualifié.* Le cas du transporteur aérien est par ailleurs le seul jugement rendu que le corpus rapporte à l'appui de la ligne délictuelle [140], [141], [142] — rapporté de seconde main, dans une pièce d'ingénierie financière, et non analysé par une pièce de droit.

11.3 Ce que la littérature ne traite pas

L'écart entre ce que le droit exige et ce que les protocoles savent exprimer est nommé, jamais instrumenté. Aucune pièce ne confronte les champs d'un message de protocole aux éléments exigés par les articles 12, 14 et 26 du règlement européen. La cartographie juridique raisonne sur des catégories de déploiement et des flux de données, pas sur des schémas de messages [138] ; la mesure d'auditabilité porte sur des dépôts logiciels, pas sur la capacité d'un format d'échange à porter une identité de mandant, une portée d'autorisation ou un point d'intervention [113] ; le relevé recense des systèmes, pas des formats [144] ; le cadre délictuel fait du journal le pivot probatoire sans spécifier ce qu'il doit contenir pour tenir devant un tribunal [140] ; la mesure de rejouabilité porte sur les commandes d'un point d'accès, pas sur les champs d'un message [191]. La proposition « dérive intraçable donc non-conformité » est donc énoncée comme constat normatif alors qu'elle est une hypothèse testable. Lacune connexe : toutes ces pièces supposent un mandant unique identifiable et aucune ne traite l'attribution lorsque la chaîne d'actions traverse plusieurs entités.

12 Le Web agentique et l'horizon

Ce front compte quatre mesures, dont une seule arbitrée, trois propositions d'architecture, trois positions, et aucune simulation. Le registre est indiqué pour chaque énoncé, faute de quoi une proposition y prendrait le ton d'un résultat.

12.1 Ce qui est établi

Position et architectures. Le Web humain est tenu pour une interface inadaptée aux clients agentiques, et le remède est partout le même : un canal déclaratif servi par le site. Une architecture propose un domaine à double couche servant contenu humain et contenu optimisé pour agents, avec un successeur déclaré de `robots.txt` gradué par intention [149] ; une autre expose les capacités du site par des balises `<tool>` et `<context>`, avec pour seule évidence la faisabilité de construction établie sur seize développeurs [150]. Convergence de propositions, non de résultats.

Mesure, des deux côtés. Les mécanismes de consentement hérités ne contraignent pas les clients automatisés : la conformité au protocole d'exclusion décroît à mesure que la directive se durcit, et les moissonneurs de recherche par intelligence artificielle ne le consultent quasiment jamais [151] ; la détection commerciale déployée n'identifie qu'un des sept agents de navigation testés, là où les empreintes comportementales les séparent tous [152]. Deux voies indépendantes — journaux de sites contrôlés, site-appât instrumenté — pour l'énoncé le mieux étayé du front.

Une mesure, deux positions. L'écart entre capacité annoncée et capacité réalisée n'est mesuré qu'une fois : 102 agents commerciaux et 31 participants [158]. Les explications qui en sont données — l'échafaudage externe [157], le déficit d'auto-amélioration [153] — sont des positions.

12.2 Où elle se contredit

L'autonomie est-elle une décision de conception certifiable, ou une propriété qui dérive ? *Position* : le niveau d'autonomie est un choix délibéré, séparable de la capacité et de l'environnement, et certifiable [155] ; *architecture* : il s'opérationnalise par inspection statique du code d'orchestration [156]. Or l'agent y est formalisé, ailleurs, comme un opérateur de mise à jour auto-induit dont les cibles licites sont les invites, la mémoire, les outils et la logique de contrôle — soit l'objet même de cette inspection, *position* [153] ; et un banc d'essai non répliqué mesure que cet échafaudage est la surface où une compromission devient permanente, *mesure* [154]. Un certificat établi au déploiement cesse alors d'être valide. Aucune des deux familles ne cite l'autre.

Corollaire, et point de bascule du front : l'identification coopérative postulée par les architectures [149], [150] — jusqu'à revendiquer une politique appliquée et non honorifique — est démentie par les deux mesures [151], [152] : une propriété d'application affirmée par conception, contredite par observation.

12.3 Ce que la littérature ne traite pas

Aucune pièce ne définit un niveau d'autonomie invariant sous auto-modification, ni ne mesure la dérive d'autonomie après évolution. Les échelles fixent l'autonomie au déploiement [155], [156] ; la littérature auto-évolutive décrit et mesure des systèmes qui réécrivent leur propre échafaudage sans jamais rapporter le niveau d'autonomie résultant [153], [154]. Les deux portent sur le même objet, sans lien établi : la gouvernance par niveaux d'autonomie n'a aujourd'hui aucune garantie de tenir sur les systèmes que ce front annonce [40], [41], [46].

La lacune se creuse plutôt qu'elle ne se comble. Contrôle refait à l'API du dépôt le 15 août 2026, sur le titre ou le résumé : du 9 au 15 août, ***trente-cinq dépôts*** *portent « self-evolving », « self-improving » ou « self-evolution ».*

Quinze emploient les mots « autonome » ou « supervision », tous au sens du domaine — conduite autonome, évolution autonome du dispositif — ou de l'apprentissage — supervision de jetons, ajustement supervisé. Aucun des trente-cinq ne rapporte un niveau d'autonomie, une certification ou une supervision humaine ; le plus proche est un panorama qui pose la sûreté de processus évolutifs de plus en plus autonomes comme problème ouvert, sans en mesurer aucun. Six jours de production sur le sujet, et pas un énoncé raccordable aux échelles d'autonomie.

13 La chorégraphie et l'essaim

Le front des systèmes multi-agents mesurait des assemblages conduits ; celui-ci prend la question par l'autre bout — ce que la coordination achète et coûte quand aucun superviseur ne la tient, l'interaction n'étant réglée que par protocole. Aucune de ses seize pièces n'est publiée en comité de lecture — [162] et [172] annoncent une acceptation au seul champ de commentaire, [163] une simple soumission, et la pièce entrée à la reprise du 15 août ne porte aucun signe de revue [180].

13.1 Ce que la littérature établit

Aucune architecture n'est supérieure ; il y a un alignement architecture-tâche. La seule comparaison contrôlée multi-bancs du front — 260 configurations, six bancs, cinq architectures, outils, invites et calcul normalisés — mesure un écart à l'agent unique de +80,8 % (raisonnement financier décomposable) à −70,0 % (planification séquentielle), et désigne la meilleure architecture dans 87 % des configurations hors ajustement [159].

Ce que la suppression du chef achète est mesuré. Contrôle et données sérialisés sur files distribuées : à matériel identique, sur trois scénarios de synthèse hétérogènes, le débit dépasse de 2 à 15× celui de cadres à orchestrateur central, sans écart de qualité chiffré [162]. Un contexte partagé vérifié plus une file où les agents réclament leurs sous-tâches : +10,5 points sur SWE-bench Verified à coût par tâche réduit de moitié [160] ; la vérification y est déplacée vers le substrat, non supprimée. Au tableau noir, des subordonnés volontaires gagnent 13 à 57 % en relatif sur trois bancs et lèvent l'exigence que le contrôleur connaisse d'avance les compétences de chacun [161] — c'est cette exigence qui interdit le parc d'agents hétérogène.

Le plafond de l'essaim n'est pas topologique. Une loi à deux paramètres, $R^2 > 0{,}99$ sur 44 cellules : trente agents en débat dense n'excèdent pas la diversité d'un seul sur MMLU-Hard, un placebo de bruit aléatoire suivant l'autocorrection à 4× l'échelle [166] — contre la loi logistique jusqu'au millier [96]. Deux mécanismes : par théorème, l'attention étroite borne l'échantillon effectif [167], plafonnant l'optimisation topologique [97] ; le plancher d'erreur tient au modèle interne de l'agent, un essaim plat égalant une hiérarchie à deux boucles à mémoire égale [168]. L'accord échoue d'abord par perte de vivacité, sans aucun agent byzantin [165]. Contrepoids : des milliers d'agents produisent 45 000 déclarations Lean 4 sous arbitre externe dur [169] ; le plafond frappe la délibération, non la décomposition vérifiable.

La redondance d'un collectif est surcréditée dès que ses agents partagent un modèle. Le calcul usuel de fiabilité composée multiplie les fiabilités des composants, geste qu'autorise une hypothèse d'indépendance conditionnelle rarement testée. Elle l'est ici : dans un relais à deux agents, deux instances d'un même modèle échouent ensemble sur 90,0 % des missions où l'une échoue (rapport de cotes logarithmique 6,66 ; $\varphi = 0{,}916$), sur 18 000 missions notées par code déterministe sans juge automatique ; changer de modèle réduit l'association dans six contrastes sur six, changer de fournisseur à modèle déjà différent ne la réduit pas — hypothèse enregistrée d'avance, rapportée comme nulle [180]. L'erreur est signée et joue contre l'exploitant : la dépendance positive gonfle l'échec conjoint au-dessus du produit des fiabilités, de sorte que le certificat crédite la redondance exactement là où elle n'existe pas. Régime : prépublication non révisée par les pairs, banc des auteurs, non répliquée, mais préenregistrée et à notation déterministe. *La pièce propose par ailleurs*

son propre certificat — un programme linéaire dont l'enrichissement de dix à quatorze fonctionnelles de moments resserre l'intervalle identifié de 85,7 % et relève le plancher certifié de 0,2455 à 0,4116 : pour cette moitié-là, elle évalue sa propre construction, et c'est le test de l'hypothèse, non le certificat, qui est repris ici.

La décentralisation ouvre une surface propre : une attaque exploitant la délégation inter-agents, inerte contre l'agent unique, compromet la multi-agents à 80 % en moyenne chez trois modèles sur quatre, à un taux de détection de 0 % [170]. Vérifier le protocole aide sans suffire : en ablation appariée à runtime fixe sur 3 456 essais, les protocoles vérifiés par TLC font tomber le taux d'interblocage et de blocage vivant de 31,1 % à 14,1 %, écart maximal sous injection de fautes [171]. La collusion sort du marché [119], [120], [121] : mesurée en actions par le regret à l'optimum coopératif, elle diverge de la collusion en communication — planifiée en texte, souvent non posée en actes [173].

13.2 Où elle se contredit

Le désaccord dur porte sur le mot « chorégraphie » lui-même. Une preuve de correction par construction pour sagas décentralisées pose ses conditions en résultat : participants **déterministes**, transactions idempotentes, messages en file durable, code compilé en sidecars [163]. Un agent fondé sur un modèle de langue ne satisfait pas la première ; [160], [161] et [162] revendiquent le mot sans discuter la condition. Les deux ne tiennent pas ensemble : ou la correction exige un participant déterministe, et le chorégraphié est le sidecar, l'agent confiné à la proposition — comme à la frontière de règlement [126] et sous contrôleur DCR [137] ; ou elle tolère un participant stochastique, et la preuve tombe. L'arbitre est disponible, non produit : personne ne mesure le taux de reprise sur panne d'une saga à participants agents contre celui d'un orchestrateur dont l'état local est source unique de vérité [163].

Second désaccord : le lieu de la vérification. La régularité de [159] conclut à la vérification centralisée ; une preuve de (F+1)-robustesse sur le graphe établit l'inverse, chef et confiance auto-déclarée étant manipulables par un pair adverse [164]. Le point d'observation est lui-même borné : le rappel d'un moniteur à automate fini tombe de 68-75 % à 6-13 % quand les attaques passent à haute entropie, invariant au réentraînement [172] — mesure d'un auteur unique, sur huit dorsales. Or le moniteur d'exécution de [171], qui rejette les opérations hors topologie, relève exactement de cette classe d'automates finis, dont [172] démontre le plafond. Le compte des fautes tolérées est lui aussi en cause : une borne en F suppose des défaillances qu'on peut compter séparément, et la co-défaillance mesurée entre agents d'un même modèle interdit ce décompte [180].

13.3 Ce qu'elle ne traite pas

Aucune pièce ne mesure un essaim réparti entre organisations distinctes : tout tient sous opérateur unique, la frontière organisationnelle simulée, non franchie. Manquent la comparaison en production, le coût d'exploitation sans orchestrateur — diagnostic, MTTR, débogage —, la conformité d'exécution sur traces déployées et l'imputation d'une défaillance. Performance et coût ne sont jamais croisés au-delà de trente agents : [166] y plafonne, [169] atteint le millier sans courbe de coût, le point de rentabilité restant non mesuré. Aucun comportement byzantin émergent n'est rapporté, la fraction étant injectée par construction et la propension de [173] répondant à la sonde ; la seule défaillance corrélée obtenue sans injection est celle du modèle partagé [180], qui n'est pas un comportement byzantin mais en produit l'effet sur le calcul de robustesse. Aucun protocole déclaratif ne tient de contrat d'exécution entre agents hétérogènes à conformité mesurée : le modèle y est générateur, jamais participant contraint [61].

14 Ce que la littérature établit, et où elle se contredit

14.1 Un défaut de fond unique, décliné en trois matières

Les dix fronts convergent sur un énoncé qu'aucun ne porte seul : rien, dans les piles examinées, ne sépare ce qui est autorisé de ce qui est seulement présent. *Contenu :* rien n'isole donnée de confiance et donnée non fiable [64] [66] [68], rien ne lie une description d'outil à son code — 9,93 % de paires divergentes sur parc réel [55], 97,1 % de descriptions défectueuses [53], 37,2 % d'applications à approbation bloquante [54]. *Autorité :* le jeton porteur transmis intact est le mauvais primitif, elle doit s'atténuer à chaque saut [83], se rétrécir sous vérification mécanique [76], se fermer à l'achèvement de la tâche [87] — or 40,55 % des serveurs MCP distants n'authentifient rien [81], et, dans une famille de scénarios de blanchiment appariés, un garde qui lit l'autorité dans l'état local admet des violations dans 22 épisodes sur 96 là où l'application par provenance n'en admet aucune, ses échecs se concentrant là où une transformation ordinaire change la politique visible alors que l'autorité d'origine, elle, n'a pas bougé [192]. *Effet :* la sortie du modèle vaut fait accompli là où elle n'est qu'une proposition — d'où la frontière de règlement déplacée hors du retour d'outil [126], le contrôle d'admission rendant l'état engagé indépendant du proposant [127].

Le dixième front n'y entre qu'à moitié. Sans chef, rien ne sépare le pair fiable du pair seulement présent : chef et confiance auto-déclarée sont manipulables par un pair adverse, quand la robustesse tient de la seule topologie [164] ; la délégation inter-agents devient la surface, inerte contre l'agent unique, une attaque compromettant la multi-agents à 80 %, détection 0 % [170]. L'autre moitié ne relève pas de l'autorisation : le plafond de l'essaim tient à la vivacité perdue [165], à l'attention qui borne l'échantillon effectif [166] [167], à la mémoire par agent [168], et la fiabilité qu'on croit gagner en dupliquant tient à une hypothèse d'indépendance que la mesure dément [180].

14.2 L'instrument de mesure est le maillon faible

Trois fronts qui ne se citent pas y aboutissent. Les scanners MCP déclarent 96,89 % des serveurs à risque ; moins de la moitié des alertes sont des vrais positifs à la validation manuelle, et les scanners se contredisent [51]. Les bancs les plus employés comptent des réponses vides comme succès [107], la performance sur SWE-bench relève pour partie de la mémorisation [108], le juge automatique bute sur un plafond démontré [109]. L'attribution de défaillance n'identifie l'agent fautif que dans 53,5 % des cas, l'étape décisive dans 14,2 %, certaines méthodes faisant moins bien que le hasard [88] ; l'observabilité des entrées et du contexte améliore l'attribution jusqu'à 76 % contre une observation partielle [89] — gain relatif, sans effectif de banc ni condition nommée, sans dénominateur commun avec le 53,5 % : le plafond d'instrumentation est une hypothèse. Un pourcentage y renseigne sur un dispositif autant que sur le monde.

14.3 Proposer n'est pas prouver

Sur les 123 pièces des dix fronts **[51-173]**, 67 — 54 % — rapportent la performance d'un artefact de leurs propres auteurs. Maximum en sécurité (10/11) et *en multi-agents (11/14, les exceptions étant trois des quatre pièces concluant au* non-avantage) ; minimum en gouvernance (2/11) et en protocoles (4/13). Ce corpus s'auto-arbitre à moitié — l'énoncé porte sur les pièces lues, dont aucune n'a été retenue hors arXiv, et non sur le champ. *Le décompte porte sur cette plage et n'a pas été refait : les pièces entrées à la reprise du 15 août n'y sont pas comptées, et la répartition par front, elle, les compte.*

Tableau 7 — Les dix désaccords réels du champ, un par front, avec ce qui les arbitrerait.

Front	Désaccord	Ce qui l'arbitrerait
Protocoles	MCP suffit-il ? Oui [57] ; non, schéma prouvé à perte [56] ; prémisse récusée [63]	La même tâche, deux protocoles, un tiers

Front	Désaccord	Ce qui l'arbitrerait
Sécurité	Prévention par construction : utilité préservée [74] ou payée cher [72] [70]	[74] sous attaque adaptative [71], coût d'utilité publié
Identité	Ancrage matériel [86] contre opposabilité hors ligne [77] [80]	La part de parcs à racine d'attestation
Multi-agents	Marge réelle [96] [97] contre non-avantage à dix fois le prix [94] [95] [92]	Réglage égalisé sur les deux bras [93]
Évaluation	Juge automatique : quasi humain [110] ou plafond démontré [109]	Un juge indépendant, étiquettes humaines
Transactionnel	Collusion stable sous auto-optimisation [121] ou artefact d'homogénéité [120]	La population de modèles tarificateurs
Processus	Suspendre l'effet jusqu'à certitude [126] [127] ou l'émettre et le réviser [129]	La part d'actions irréversibles en flux réel
Gouvernance	RIA opérationnalisable [138] ou inadéquat [139] ; prémisse d'autonomie contestée [147] [148]	Un message contre les articles 12, 14 et 26
Web agentique	Identification coopérative [149] [150] ou détection imposée [151] [152]	La conformité d'agents non coopératifs
Chorégraphie et essaim	Vérifier au centre [159], ou sans chef, la (F+1)-robustesse tenant du graphe quand chef et confiance auto-déclarée se manipulent [164] ; or la correction chorégraphiée exige un participant déterministe [163], et le décompte des fautes suppose une indépendance démentie [180]	La même saga, participants déterministes puis agents, sous injection de fautes [171]

15 Trois énoncés de la veille mis à l'épreuve

Ces trois énoncés proviennent d'une veille sur sources primaires — brouillons de normalisation, moteurs d'orchestration, conventions d'observabilité — arrêtée au 8 août 2026. La littérature ne peut ni les confirmer ni les infirmer en bloc : elle en éclaire une part et laisse l'autre à la veille. Chaque verdict est donc écrit en deux temps, **ce que la littérature porte seule** et ce qui reste suspendu à l'état du monde déployé, de sorte qu'un mouvement de ce dernier depuis le gel déplace la date d'un fait, jamais la conclusion.

15.1 1. « Au-delà de deux sauts de délégation, aucun mécanisme normalisé ne maintient de traçabilité opposable. »

Proposer est dépassé. Chaîne append-only, *chaque* saut signé, vérifiable hors ligne à la seule clé publique de l'émetteur, sans borne de profondeur [77] ; jetons de capacité liés à l'invocation [16]. « Aucun mécanisme » est faux.

Prouver est partagé. Une vérification en TLA+ sur 2,7 M d'états établit, à profondeur arbitraire, rétrécissement d'autorité, reconstructibilité forensique et confinement de cascade, mais démontre la préservation d'intention *pratiquement infaisable* de façon déterministe [76] ; ni l'atténuation récursive [83] ni la borne de propagation de responsabilité [78] ne déplacent ce partage. On prouve ce qui fut fait sous quelle autorité, non que cela servait le mandat.

Normaliser ne tient pas. La vérification formelle des spécifications relève 35 lacunes et 30 défaillances nées de la seule composition, et qu'*aucun protocole n'assigne l'application inter-protocoles* [85] — or deux sauts en entreprise traversent des protocoles, et le socle à un saut n'est pas tenu [81]. L'obstacle est de normalisation et d'instrumentation, non d'invention.

Ce que la littérature porte seule, et qui ne dépend d'aucun brouillon : les mécanismes existent et sont publiés ; leurs preuves s'arrêtent avant l'intention ; et aucune pièce du corpus ne mesure une chaîne de délégation à plus d'un saut en exploitation — la seule mesure de parc du front porte sur l'authentification d'un saut,

et elle échoue [81]. Le déficit d'adoption est donc établi par l'absence de mesure autant que par les mesures existantes.

Ce qui reste à la veille : le mot « normalisé » lui-même. Qu'un brouillon de délégation ait avancé, stagné ou été adopté depuis le 8 août ne change ni le constat d'invention ni l'absence de mesure de terrain — cela date le franchissement d'une étape de procédure, et cette étape est de la compétence de la veille, non de la littérature. Le verdict tient dans les deux cas ; seul son temps de verbe change.

15.2 2. « L'arrimage entre la couche d'orchestration installée et la pile agentique est unilatéral. »

Exact sur le déploiement, faux sur la littérature. Le mouvement dominant enveloppe le moteur déterministe, qui garde l'autorité d'exécution [132]. Mais quatre formalismes conçus *pour* les agents existent depuis fin 2024 : BPMN à constructions natives d'agent [133], graphe DCR pilotant le dialogue [137], portes d'approbation érigées en invariants applicables [134], modèles de processus typés promus composants de l'agent [131]. Ce qui manque est l'adoption : la dissymétrie est industrielle, pas scientifique.

Ce que la littérature porte seule : l'existence datée des quatre formalismes, et l'absence complète de mesure de leur adoption ou de leur conformité d'exécution — [130] produit le journal et s'arrête à la découverte, [131] pose la conformité par construction comme agenda, [136] évalue le modèle produit et non l'exécution. La littérature ne sait pas si la dissymétrie se referme, et elle ne s'est pas donné les moyens de le savoir.

Ce qui reste à la veille : deux faits, non un. D'abord la négative « aucun protocole déployé ne porte de sémantique de processus » — elle relève du relevé de spécifications de la veille, non de la littérature : [132] décrit un harnais autour d'un moteur, il n'établit aucune négative universelle, et aucune pièce du corpus ne recense les protocoles déployés sous cet angle. Ensuite l'état des moteurs installés : si l'un d'eux a publié depuis le gel des primitives agentiques natives, la dissymétrie se referme du côté industriel, ce qui confirme le verdict au lieu de l'infirmer, puisque le verdict porte précisément sur le fait que le mouvement vient de l'industrie et non de la science. L'énoncé ne serait renversé que par une pièce mesurant l'adoption d'un formalisme agentique par un moteur de production ; le corpus n'en contient aucune au 15 août 2026.

15.3 3. « Aucun attribut du socle d'observabilité agentique ne décrit une chaîne de mandat ou de délégation. »

Confirmé par une seconde voie, plus sévèrement. Journaux d'audit, OCSF et OpenTelemetry sont sémantiquement insuffisants pour reconstruire la propagation d'autorité : des traces identiques admettent plusieurs assignations de mandat incompatibles, donc l'exécution déléguée n'est pas *identifiable* [84]. La seule pièce arbitrée du front étend la provenance W3C aux flux agentiques sans jamais instancier `actedOnBehalfOf` : elle s'en tient à `wasAssociatedWith` et `wasInformedBy` [112]. *Le modèle le plus normatif renonce à la primitive de son standard.*

Ce que la littérature porte seule — et il faut en donner le cadre exact, sans quoi la mesure dirait plus qu'elle n'établit. Une suite gelée de 5 280 épisodes met deux dispositifs à l'épreuve. Sur son expérience de délégation pré-spécifiée, à quatre familles de modèles, une invite constitutionnelle détaillée produit 0 violation réalisée sur 384 — et le garde exécutable à provenance produit lui aussi 0 sur 384, en bloquant au passage 51 tentatives sur 384, dont 44 aboutissent quand même ensuite [192]. Sur le critère de sortie, une invite égale une application par provenance. Les deux ne se séparent que dans une famille de scénarios ciblés : en scénarios de blanchiment appariés, le garde qui lit l'autorité dans l'état local admet des violations dans 22 épisodes sur 96, l'application par provenance dans 0 sur 96 ($p = 4{,}77 \times 10^{-7}$), et ses échecs se concentrent là où une transformation ordinaire change la politique visible alors que l'autorité d'origine reste fixe [192]. Régime : prépublication non révisée par les pairs, auteur unique, dépôt de reproductibilité public, non répliquée.

Ce que cette mesure établit, et ce qu'elle n'établit pas. Elle n'établit pas qu'une chaîne de mandat portée à la trace fasse baisser un taux de violation : sur l'expérience principale, elle ne le fait pas. Elle établit deux choses que cette revue tient pour plus importantes. D'abord que le taux de violation final ne distingue pas les deux mécanismes — la pièce le dit elle-même : un même taux final peut recouvrir des mécanismes très différents —, de sorte qu'un banc qui mesure la sortie ne peut pas dire si le mandat a été suivi ; c'est la non-identifiabilité de [84] déplacée de la trace vers l'évaluation. Ensuite que l'écart apparaît exactement là où l'énoncé le prédit : quand la politique visible change sans que l'autorité d'origine bouge. Le verdict reste donc une position appuyée par une mesure de portée étroite, non un fait mesuré de portée générale — et il faut le dire ainsi, puisque cette revue reproche ailleurs au champ de citer ses pourcentages hors de leur dispositif.

Le déficit est de liaison, non de vocabulaire — et c'est la formulation qui tient quel que soit l'état du socle. La primitive existe déjà dans le standard de provenance et n'est pas instanciée [112] ; là où l'autorité n'est pas liée à son origine, la trace reste non identifiable [84] ; et un garde qui la lit ailleurs qu'à l'origine échoue là où la politique visible se transforme [192]. Qu'un attribut de délégation soit ajouté demain à une convention sémantique ne réfuterait pas cet énoncé : un nom d'attribut que rien n'oblige à émettre, et que rien ne lie à un mandat vérifiable, laisse la trace exactement aussi ambiguë. L'arbitrage porte sur l'émission et la liaison, pas sur la nomenclature.

Ce qui reste à la veille : la liste des attributs effectivement publiés, et leur date. Ce fait est porté par elle seule ; cette revue ne le vérifie pas et ne s'y adosse pas.

16 Lacunes et programme de recherche

Il n'existe aucun taux de base. Aucun front ne compte ses échantillons autrement qu'en serveurs, en outils, en cas de test, en dépôts et en marchés simulés — jamais en organisations, en déploiements ni en incidents observés. Testable : quelle fraction des agents en service subit une tentative d'injection, à quel taux d'aboutissement ? Quel taux de contestation pour une transaction agentique non autorisée, dont le front transactionnel n'offre aucune pièce pour l'établir [114] [115] ?

Personne ne mesure une propriété de bout en bout franchissant une frontière réelle. Ni de protocole à protocole — tout est mesuré sur MCP seul, la seule comparaison implémentée est un scénario unique non généralisable de l'aveu des auteurs [57], les 30 propriétés temporelles unifiant MCP et A2A ne sont vérifiées nulle part [60] — ni d'organisation à organisation. Testable : pour une tâche A2A ⟶ MCP entre deux organisations en exploitation, quels taux d'échec, latence ajoutée et perte sémantique ? Et quels *fitness* et précision pour une trace d'agent alignée contre un modèle de processus [130] [136] ?

17 Limites de cette revue

Aux restrictions de méthode déjà posées — ni protocole PRISMA, ni double codage, ni réplication — s'ajoute celle de la couverture : l'interrogation porte sur arXiv, notices vérifiées une à une, et ACM DL, IEEE Xplore, SpringerLink et la littérature grise restent hors du corpus — à l'exception de la passe de contrôle décrite ci-dessous, qui les interroge pour mesurer ce que cette restriction coûte, sans rien verser au corpus. Le biais anglophone reste entier. Les chiffres rapportés sont ceux des auteurs, y compris là où la revue signale que l'instrument qui les produit est contesté. Le classement d'un artefact comme « construction des auteurs » relève d'un jugement de lecture ; son critère est publié pour être réfutable. La revue hérite enfin de la faiblesse qu'elle mesure : 77 % de son corpus ne présente aucun signe de revue par les pairs et 63 % a été

déposé en 2026 — proportions recomptées sur la bibliographie à la reprise du 15 août 2026 : la première est inchangée au point de pourcentage près, la seconde monte de trois points, les seize pièces versées ce jour-là étant toutes de 2026.

Le biais d'échantillonnage a été mesuré, non déclaré. Mesurer la part de non-arbitré sur un dépôt de prépublications, puis en conclure quelque chose du champ, serait circulaire. Une passe de contrôle a donc été conduite le 15 août 2026 sur DBLP, Crossref et OpenAlex, aux quatre fronts que l'annexe donne pour vides de pièce arbitrée et qui sont les plus réfutables — sécurité, évaluation, couche transactionnelle, chorégraphie et essaim —, avec la consigne inverse de celle du corpus : chercher ce qui réfute le résultat central. **Elle en trouve, sur les quatre.** Sécurité : l'injection d'invite est arbitrée à IEEE S&P 2026 (*PromptLocate*), à ESORICS 2025 (*Prompt Infection*, injection de modèle à modèle en système multi-agents), à CODASPY 2025 (*PromptShield*), dans *IEEE Transactions on Information Forensics and Security* 2026 et dans *ICT Express* 2026, cette dernière sur les exploits de protocole eux-mêmes. Évaluation : ICLR 2025 porte *AgentHarm* et *Agent Security Bench*, NeurIPS 2025 *AgentRecBench*, AIware 2026 un banc de détection de fautes pour l'observabilité d'agents. Couche transactionnelle : la collusion algorithmique est arbitrée à ITCS 2025, à ACM CS&Law 2024 et 2025, dans *Games and Economic Behavior* 157 et dans l'*European Journal of Operational Research* 318. Ce rattachement est le plus faible des quatre, et il faut le dire : ces cinq pièces relèvent de l'économie industrielle et portent toutes sur la tarification collusoire ; *elles n'établissent rien sur les paiements agentiques ni sur la réputation*, qui sont les deux autres tiers de ce front. Le front n'est donc pas couvert par une littérature arbitrée — **un de ses trois objets l'est**. Chorégraphie et essaim : la coordination multi-agents robuste aux fautes byzantines est arbitrée à l'ACM TURC 2024 (*BlockAgents*) et à IEEE CSCWD 2026 (*RoMa*). Aucune de ces pièces n'est au corpus et aucune n'y est versée ici. L'énoncé « aucune publication arbitrée sur ce front » est donc vrai du corpus retenu et faux du champ.

La notice sous-déclare l'arbitrage, et l'écart a été chiffré. Le critère de cette revue — attestation portée au champ `journal_ref` ou DOI — ne relève un arbitrage que si l'auteur a mis sa notice à jour après acceptation. Sept pièces dont DBLP ou Crossref établit la publication en actes ou en revue ont été confrontées à leur notice arXiv : une seule y porte l'attestation, deux ne la déclarent qu'au champ de commentaire, **quatre ne portent rien du tout** et tomberaient donc au régime sans revue. Le même test, refait sur ce corpus-ci — sept entrées classées sans revue dont l'identifiant arXiv est antérieur au gel —, **en donne quatre publiées** : [92] aux actes de l'ACL 2024, [102] et [107] à NeurIPS 2025, [124] aux actes de l'ACM Web Conference 2026 ; les trois autres n'ont pas de version arbitrée trouvable. Le contrôle est un plancher, non une mesure : Crossref n'indexe ni PMLR ni OpenReview, de sorte qu'aucune acceptation à ICML ou à ICLR n'y apparaît, et l'échantillon de quatorze pièces penche vers deux fronts. Conséquence pour le résultat central : 145 est un plafond du non-arbitré et douze un plancher de l'arbitré ; les trois régimes mesurent ce que les notices déclarent, non ce que les comités ont fait. Ce qui reste établi est plus étroit et plus sûr que ce que le chiffre laissait croire : sur les questions d'interopérabilité que cette revue instruit, le régime de chaque pièce citée est nommé une à une, et c'est cette nomination-là, non la proportion, qui porte l'argument.

La date de validité est celle de la reprise, pas celle de la lecture. Les notices ont été reprises à l'API du dépôt le 15 août 2026 : deux avaient été révisées en six jours, aucune publication neuve n'était attestée, et rien ne garantit qu'aucune ne bougera demain. Une révision peut changer un résultat sans changer un titre — la pièce sectorielle de gouvernance en donne l'exemple dans cette même reprise [146]. La notice ne dit pas tout non plus : la qualification du chiffre d'accroche de cette même pièce ne se lit qu'à son corps, et un lecteur qui s'arrêterait au résumé, comme le fait cette revue pour la plupart de ses entrées, ne la verrait pas.

Auto-citation déclarée : la veille dont trois énoncés sont ici mis à l'épreuve est du même auteur. Quatre faits qu'elle porte seule — l'état des brouillons de normalisation de la délégation, l'absence de sémantique de processus dans les protocoles déployés, l'état des moteurs d'orchestration installés, les attributs publiés des

conventions d'observabilité — ne sont pas vérifiés par cette revue. *Ils sont nommés comme siens à l'endroit où ils comptent, et aucun verdict de la section précédente n'y est suspendu.*

18 Conclusion

Le meilleur résultat de cette revue n'est pas un fait du champ, mais une propriété du corpus qu'elle a lu. Un corpus dont les trois quarts ne déclarent aucun comité à leur notice, dont la moitié évalue une construction de ses propres auteurs, et dont trois fronts indépendants concluent que l'instrument de mesure est faux, ne peut pas à lui seul arbitrer une décision d'architecture. La passe de contrôle sur DBLP et Crossref, rapportée aux limites, borne ce constat dans les deux sens : de la littérature arbitrée existe hors arXiv sur quatre des fronts que ce corpus donne pour vides, et des pièces de ce corpus sont publiées sans que leur notice le dise. Les 77 % restent le fait qu'ils mesurent — un corpus de prépublications lu au critère de la notice — et cessent d'être ce qu'on aurait voulu leur faire dire du champ. Ce corpus peut seulement dire où regarder — et sur les trois énoncés soumis, la revue l'a fait : deux déficits d'invention étaient des déficits d'adoption ; le troisième est plus profond qu'annoncé, mais la mesure qui l'appuie ne vaut que pour la famille de scénarios où elle a été prise [192], et la revue le dit plutôt que de l'élargir.

Le corpus a été repris notice par notice le 15 août 2026, six jours après le premier relevé. Deux notices seulement avaient bougé, dont une du front gouvernance, qui requalifie en démonstration de calculabilité ce qu'elle présentait comme un instrument de détection de dérive [146] ; aucune publication neuve n'est attestée ; et les trois pièces que la fenêtre du 9 au 15 août fait entrer aux fronts de la gouvernance et de l'essaim sont toutes des prépublications sans signe de revue [180], [191], [192]. *Une reprise qui change peu est un résultat : elle mesure la vitesse à laquelle ce corpus se périme, et cette vitesse se compte en semaines, pas en jours.* C'est aussi la seule garantie qu'un lecteur peut exiger d'une revue sur un champ pareil — non qu'elle soit complète, mais qu'elle dise à quelle date chacun de ses énoncés a été rouvert, ce qu'elle n'a pas pu rouvrir, et jusqu'où porte chaque chiffre qu'elle cite.

Annexe : le corpus arbitré, et ce qu'il ne couvre pas

Un lecteur qui refuserait de s'appuyer sur autre chose qu'une publication attestée en notice disposerait des douze pièces ci-dessous, et de rien d'autre dans ce corpus, relevé du 15 août 2026. Sept d'entre elles portent une référence de revue ou d'actes au champ `journal_ref` — dont quatre portent aussi un DOI d'éditeur — et cinq ne sont attestées que par un DOI ; le tableau est ordonné par numéro de référence, non par champ. La liste est inchangée depuis le relevé du 9 août : en une semaine, aucune pièce n'y est entrée, aucune n'en est sortie, et les seize arrivées au corpus n'en approchent pas.

Tableau 8 — Les douze pièces du corpus dont la publication est attestée en notice, avec leur apport propre.

Réf.	Publication attestée	Apport
[4]	IEEE Trans. on Cognitive Communications and Networking	Pose l'« Internet des agents » comme objet d'architecture et en énumère les couches manquantes
[15]	ICAART 2026	Applique identifiants décentralisés et justificatifs vérifiables du W3C à des agents
[37]	Künstliche Intelligenz, 2024	Formule la vision des grands modèles de processus, d'où descend le front des processus d'affaires
[38]	Actes PMAI 25 (CEUR, vol. 4087)	Découvre la variabilité comportementale d'agents par fouille de processus sur leurs traces
[44]	Actes FAccT 2026	Établit que les agents de langue n'ont pas l'ancrage requis par un mécanisme de réputation

Réf.	Publication attestée	Apport
[46]	Actes ICML 2024	Propose l'échelle d'autonomie la plus citée du champ, et la seule opérationnalisable
[59]	Actes MSR '26	Constitue le seul jeu de données validé d'implémentations MCP — 2 297 dépôts, précision de 83 %
[136]	Information Systems, vol. 142, art. 102761	Mesure la compétence réelle des modèles à produire des modèles de processus valides
[142]	Actes REALM @ ACL 2025	Instruit la responsabilité par la relation de mandat, et non par l'autonomie du système
[143]	European Journal of Risk Regulation 16	Établit que le règlement européen alloue une responsabilité de supervision sans base empirique
[144]	Actes FAccT 2026	Documente les caractéristiques techniques et de sûreté d'agents effectivement déployés
[158]	Actes ACM, 2026	Mesure l'écart entre capacité annoncée et capacité réalisée — 102 agents, 31 participants

Ce que cette liste montre par ce qui n'y figure pas. Six fronts neufs n'y comptent aucune pièce — la sécurité, l'identité et la délégation, les systèmes multi-agents, l'évaluation, la couche transactionnelle, la chorégraphie et l'essaim. Or ce sont exactement ceux qui portent les énoncés les plus conséquents de cette revue : que les scores de défense ne survivent pas à l'adversaire adaptatif, que l'autorité doive s'atténuer à chaque saut, que le rendement du multi-agent soit non monotone, que le score publié ne soit pas ce qui s'observe, que le mandat signé ne soit pas le point de rupture, que la coordination sans chef échange une surface d'attaque contre une autre. *Aucun de ces six résultats ne repose, dans ce corpus et au seul critère de la notice, sur une pièce dont la publication soit attestée.*

L'énoncé porte sur ce corpus, et une passe de contrôle le réfute au niveau du champ. DBLP et Crossref donnent de la littérature arbitrée sur quatre de ces six fronts — les limites la nomment —, et **quatre** pièces déjà retenues ici sont publiées en actes sans que leur notice le déclare : [92] en multi-agents, [102] et [107] en évaluation, [124] à la couche transactionnelle. Le tableau ci-dessus recense donc ce que les notices attestent, non ce que les comités ont arbitré, et le vide de ces six fronts est un vide de déclaration autant qu'un vide de revue.

Il ne s'ensuit pas que ces résultats soient faux : plusieurs sont adossés à des mesures que rien d'autre ne fournit. Il s'ensuit que ce corpus produit ses résultats les plus décisifs là où son appareil de contrôle déclaré est le plus faible, et qu'un architecte qui s'y appuie le fait sous sa propre responsabilité — constat qui ne se lit ni dans les résumés ni dans les comptes de citations : il fallait ouvrir les cent quatre-vingt-neuf notices pour l'obtenir, deux fois plutôt qu'une, puis sortir d'arXiv pour en connaître la portée.

Références

Chaque entrée porte le régime de publication relevé sur la notice du dépôt le 15 août 2026 : la référence de revue ou d'actes lorsqu'elle y figure, la mention d'une acceptation autodéclarée au seul champ de commentaire lorsqu'il n'y a que cela, et la qualification de prépublication non révisée par les pairs à défaut. Cette dernière mention enregistre le silence de la notice, non l'absence d'arbitrage : les limites de cette revue chiffrent l'écart entre les deux, et nomment quatre entrées ainsi qualifiées dont une base de littérature arbitrée établit la publication.

1. Abul Ehtesham, Aditi Singh *et al.* « A survey of agent interoperability protocols: Model Context Protocol (MCP), Agent Communication Protocol (ACP), Agent-to-Agent Protocol (A2A), and Agent Network Protocol (ANP) ». arXiv:2505.02279v2, déposée le 4 mai 2025, v2 du 23 mai 2025 — prépublication non révisée par les pairs.

2. Yingxuan Yang, Huacan Chai *et al.* « A Survey of AI Agent Protocols ». arXiv:2504.16736v3, déposée le 23 avril 2025, v3 du 21 juin 2025 — prépublication non révisée par les pairs.
3. Dezhang Kong, Shi Lin *et al.* « A Survey of LLM-Driven AI Agent Communication: Protocols, Security Risks, and Defense Countermeasures ». arXiv:2506.19676v4, déposée le 24 juin 2025, v4 du 27 novembre 2025 — prépublication non révisée par les pairs.
4. Yuntao Wang, Shaolong Guo *et al.* « Internet of Agents: Fundamentals, Applications, and Challenges ». arXiv:2505.07176v2, déposée le 12 mai 2025, v2 du 16 octobre 2025 — **publication attestée en notice**, doi:10.1109/TCCN.2025.3623369.
5. Xinyi Hou, Yanjie Zhao *et al.* « Model Context Protocol (MCP): Landscape, Security Threats, and Future Research Directions ». arXiv:2503.23278v3, déposée le 30 mars 2025, v3 du 7 octobre 2025 — prépublication non révisée par les pairs.
6. Mohammed Mehedi Hasan, Hao Li *et al.* « Model Context Protocol (MCP) at First Glance: Studying the Security and Maintainability of MCP Servers ». arXiv:2506.13538v5, déposée le 16 juin 2025, v5 du 13 avril 2026 — prépublication non révisée par les pairs.
7. Xiaofan Li et Xing Gao. « A First Look at the Security Issues in the Model Context Protocol Ecosystem ». arXiv:2510.16558v2, déposée le 18 octobre 2025, v2 du 27 avril 2026 — acceptation annoncée au seul champ *Comments* (« This paper has been accepted to DSN 2026. The title has »), non confirmée en notice.
8. Kehui Chen, Yicheng Sun *et al.* « Understanding How Enterprises Adopt the Model Context Protocol for LLM-Driven Software Engineering ». arXiv:2606.09182v1, déposée le 8 juin 2026 — acceptation annoncée au seul champ *Comments* (« 12pages, preliminary version accepted at the 26th Inter »), non confirmée en notice.
9. Idan Habler, Ken Huang *et al.* « Building A Secure Agentic AI Application Leveraging A2A Protocol ». arXiv:2504.16902v2, déposée le 23 avril 2025, v2 du 2 mai 2025 — prépublication non révisée par les pairs.
10. Gaowei Chang, Eidan Lin *et al.* « Agent Network Protocol Technical White Paper ». arXiv:2508.00007v1, déposée le 18 juillet 2025 — prépublication non révisée par les pairs.
11. Zeynab Anbiaee, Mahdi Rabbani *et al.* « Security Threat Modeling for Emerging AI-Agent Protocols: A Comparative Analysis of MCP, A2A, Agora, and ANP ». arXiv:2602.11327v2, déposée le 11 février 2026, v2 du 17 avril 2026 — prépublication non révisée par les pairs.
12. Ken Huang, Vineeth Sai Narajala *et al.* « A Novel Zero-Trust Identity Framework for Agentic AI: Decentralized Authentication and Fine-Grained Access Control ». arXiv:2505.19301v2, déposée le 25 mai 2025, v2 du 28 mai 2025 — prépublication non révisée par les pairs.
13. Subramanya Nagabhushanaradhya. « OpenID Connect for Agents (OIDC-A) 1.0: A Standard Extension for LLM-Based Agent Identity and Authorization ». arXiv:2509.25974v1, déposée le 30 septembre 2025 — prépublication non révisée par les pairs.
14. Abhishek Goswami. « Agentic JWT: A Secure Delegation Protocol for Autonomous AI Agents ». arXiv:2509.13597v1, déposée le 16 septembre 2025 — prépublication non révisée par les pairs.
15. Sandro Rodriguez Garzon, Awid Vaziry *et al.* « AI Agents with Decentralized Identifiers and Verifiable Credentials ». arXiv:2511.02841v2, déposée le 1 octobre 2025, v2 du 15 décembre 2025 — 18th International Conference on Agents and Artificial Intelligence (ICAART), 2026, volume 1, pp. 252-259, doi:10.5220/0014234400004052.
16. Sunil Prakash. « AIP: Agent Identity Protocol for Verifiable Delegation Across MCP and A2A ». arXiv:2603.24775v1, déposée le 25 mars 2026 — prépublication non révisée par les pairs.

17. Ken Huang, Vineeth Sai Narajala *et al.* « Agent Name Service (ANS): A Universal Directory for Secure AI Agent Discovery and Interoperability ». arXiv:2505.10609v1, déposée le 15 mai 2025 — prépublication non révisée par les pairs.
18. Kunlun Zhu, Hongyi Du *et al.* « MultiAgentBench: Evaluating the Collaboration and Competition of LLM agents ». arXiv:2503.01935v1, déposée le 3 mars 2025 — prépublication non révisée par les pairs.
19. Asaf Yehudai, Lilach Eden *et al.* « Survey on Evaluation of LLM-based Agents ». arXiv:2503.16416v2, déposée le 20 mars 2025, v2 du 23 avril 2026 — acceptation annoncée au seul champ *Comments* (« ACL Findings »), non confirmée en notice.
20. Shaina Raza, Ranjan Sapkota *et al.* « TRiSM for Agentic AI: A Review of Trust, Risk, and Security Management in LLM-based Agentic Multi-Agent Systems ». arXiv:2506.04133v5, déposée le 4 juin 2025, v5 du 18 décembre 2025 — prépublication non révisée par les pairs.
21. Richard Kang et Yudho Diponegoro. « Governance Gaps in Agent Interoperability Protocols: What MCP, A2A, and ACP Cannot Express ». arXiv:2606.31498v1, déposée le 30 juin 2026 — prépublication non révisée par les pairs.
22. Juan A. Wibowo et George C. Polyzos. « Toward a Safe Internet of Agents ». arXiv:2512.00520v2, déposée le 29 novembre 2025, v2 du 27 avril 2026 — prépublication non révisée par les pairs.
23. Grégoire Mialon, Clémentine Fourrier *et al.* « GAIA: a benchmark for General AI Assistants ». arXiv:2311.12983v1, déposée le 21 novembre 2023 — prépublication non révisée par les pairs.
24. Shunyu Yao, Noah Shinn *et al.* « τ-bench: A Benchmark for Tool-Agent-User Interaction in Real-World Domains ». arXiv:2406.12045v1, déposée le 17 juin 2024 — prépublication non révisée par les pairs.
25. Erik Pautsch, Tanmay Singla *et al.* « AgentHub: A Registry for Discoverable, Verifiable, and Reproducible AI Agents ». arXiv:2510.03495v2, déposée le 3 octobre 2025, v2 du 26 février 2026 — prépublication non révisée par les pairs.
26. Georgios Ioannides, Christos Constantinou *et al.* « MOD-X: A Modular Open Decentralized eXchange Framework proposal for Heterogeneous Interoperable Artificial Intelligence Agents ». arXiv:2507.04376v2, déposée le 6 juillet 2025, v2 du 8 juillet 2025 — prépublication non révisée par les pairs.
27. Roland R. Rodriguez. « Agent Identity URI Scheme: Topology-Independent Naming and Capability-Based Discovery for Multi-Agent Systems ». arXiv:2601.14567v2, déposée le 21 janvier 2026, v2 du 13 juillet 2026 — prépublication non révisée par les pairs.
28. Tatiana Petrova, Boris Bliznioukov *et al.* « From Multi-Agent Systems and the Semantic Web to Agentic AI: A Unified Narrative of the Web of Agents ». arXiv:2507.10644v4, déposée le 14 juillet 2025, v4 du 24 mai 2026 — prépublication non révisée par les pairs.
29. Takumi Otsuka, Kentaroh Toyoda *et al.* « AI Identity: Standards, Gaps, and Research Directions for AI Agents ». arXiv:2604.23280v1, déposée le 25 avril 2026 — prépublication non révisée par les pairs.
30. Krti Tallam. « Authorization Propagation in Multi-Agent AI Systems: Identity Governance as Infrastructure ». arXiv:2605.05440v1, déposée le 6 mai 2026 — prépublication non révisée par les pairs.
31. Maxim Vidgof, Stefan Bachhofner *et al.* « Large Language Models for Business Process Management: Opportunities and Challenges ». arXiv:2304.04309v1, déposée le 9 avril 2023 — prépublication non révisée par les pairs.
32. Hoang Vu, Nataliia Klievtsova *et al.* « Agentic Business Process Management: Practitioner Perspectives on Agent Governance in Business Processes ». arXiv:2504.03693v2, déposée le 23 mars 2025, v2 du 3 juillet 2025 — acceptation annoncée au seul champ *Comments* (« Accepted for Responsible BPM 2025, 15 pages including r »), non confirmée en notice.

33. Marlon Dumas, Fredrik Milani *et al.* « Agentic Business Process Management Systems ». arXiv:2601.18833v1, déposée le 25 janvier 2026 — acceptation annoncée au seul champ *Comments* (« Presented at the BPM'2025 conference on Artificial Inte »), non confirmée en notice.
34. Diego Calvanese, Angelo Casciani *et al.* « Agentic Business Process Management: A Research Manifesto ». arXiv:2603.18916v3, déposée le 19 mars 2026, v3 du 12 avril 2026 — prépublication non révisée par les pairs.
35. Tianbao Xie, Danyang Zhang *et al.* « OSWorld: Benchmarking Multimodal Agents for Open-Ended Tasks in Real Computer Environments ». arXiv:2404.07972v2, déposée le 11 avril 2024, v2 du 30 mai 2024 — prépublication non révisée par les pairs.
36. Shangeetha Sivasothy, Scott Barnett *et al.* « Large language models for generating rules, yay or nay? ». arXiv:2406.06835v1, déposée le 10 juin 2024 — prépublication non révisée par les pairs.
37. Timotheus Kampik, Christian Warmuth *et al.* « Large Process Models: A Vision for Business Process Management in the Age of Generative AI ». arXiv:2309.00900v3, déposée le 2 septembre 2023, v3 du 17 janvier 2025 — **Künstl Intell (2024)**, doi:10.1007/s13218-024-00863-8.
38. Fabiana Fournier, Lior Limonad *et al.* « Agentic AI Process Observability: Discovering Behavioral Variability ». arXiv:2505.20127v2, déposée le 26 mai 2025, v2 du 3 juillet 2025 — PMAI 25 (CEUR proceedings); Vol 4087; 2025.
39. Alessandro Berti, Humam Kourani *et al.* « PM-LLM-Benchmark: Evaluating Large Language Models on Process Mining Tasks ». arXiv:2407.13244v1, déposée le 18 juillet 2024 — prépublication non révisée par les pairs.
40. Yingxuan Yang, Mulei Ma *et al.* « Agentic Web: Weaving the Next Web with AI Agents ». arXiv:2507.21206v1, déposée le 28 juillet 2025 — prépublication non révisée par les pairs.
41. Cameron Pattison, Matthew Boulos *et al.* « The Agentic Web Requires New Normative Infrastructure ». arXiv:2606.10711v2, déposée le 9 juin 2026, v2 du 15 juillet 2026 — prépublication non révisée par les pairs.
42. Yuhan Jin, Shuohan Wu *et al.* « The Web4 Agent Economy: A Large-Scale Empirical Study of the Landscape, Challenges, and Opportunities ». arXiv:2606.25876v1, déposée le 24 juin 2026 — prépublication non révisée par les pairs.
43. Shengchen Ling, Yihang Huang *et al.* « Free-Riding the Agentic Web: A Systematic Security Analysis of x402 Payments ». arXiv:2605.30998v2, déposée le 29 mai 2026, v2 du 22 juin 2026 — prépublication non révisée par les pairs.
44. Botao Amber Hu, Helena Rong *et al.* « Dissociative Identity: Language Model Agents Lack Grounding for Reputation Mechanisms ». arXiv:2605.30169v3, déposée le 28 mai 2026, v3 du 2 juillet 2026 — **publication attestée en notice**, doi:10.1145/3805689.3806748.
45. Cristian Trout, Sanmi Koyejo *et al.* « Underwriting the Agent Economy: The Blueprint for an AI Insurance Stack ». arXiv:2607.11999v2, déposée le 13 juillet 2026, v2 du 15 juillet 2026 — prépublication non révisée par les pairs.
46. Meredith Ringel Morris, Jascha Sohl-Dickstein *et al.* « Levels of AGI for Operationalizing Progress on the Path to AGI ». arXiv:2311.02462v5, déposée le 4 novembre 2023, v5 du 24 septembre 2025 — **Proceedings of ICML 2024**.
47. Zelin Li, Qin Wang *et al.* « Five Attacks on x402 Agentic Payment Protocol ». arXiv:2605.11781v1, déposée le 12 mai 2026 — prépublication non révisée par les pairs.
48. Mert Cemri, Melissa Z. Pan *et al.* « Why Do Multi-Agent LLM Systems Fail? ». arXiv:2503.13657v3, déposée le 17 mars 2025, v3 du 26 octobre 2025 — prépublication non révisée par les pairs.

49. Nicolás Padilla. « Exposed by Design: A Dynamic Security Assessment of Internet-Facing MCP Servers at Scale ». arXiv:2608.00150v1, déposée le 31 juillet 2026 — prépublication non révisée par les pairs.
50. Xuanze Chen, Xukang Xie *et al.* « MemSecBench: Tracking Agent Memory Poisoning from Persistence to Consequence and Repair ». arXiv:2607.27080v1, déposée le 29 juillet 2026 — prépublication non révisée par les pairs.
51. Pei Chen, Baichao An *et al.* « Rethinking MCP Security: A Large-Scale Study of Runtime MCP Servers and Security Scanner Reliability ». arXiv:2607.11086v1, déposée le 13 juillet 2026 — prépublication non révisée par les pairs.
52. Mengying Wu, Pei Chen *et al.* « MCPZoo: A Large-Scale Dataset of Runnable Model Context Protocol Servers for AI Agent ». arXiv:2512.15144v3, déposée le 17 décembre 2025, v3 du 26 décembre 2025 — prépublication non révisée par les pairs.
53. Mohammed Mehedi Hasan, Hao Li *et al.* « Model Context Protocol (MCP) Tool Descriptions Are Smelly! Towards Improving AI Agent Efficiency with Augmented MCP Tool Descriptions ». arXiv:2602.14878v3, déposée le 16 février 2026, v3 du 31 mai 2026 — prépublication non révisée par les pairs.
54. Muhammad Hamza Arshad Majeed, May Mahmoud *et al.* « An Empirical Study of Model Context Protocol Applications ». arXiv:2607.25635v2, déposée le 28 juillet 2026, v2 du 29 juillet 2026 — prépublication non révisée par les pairs.
55. Yutao Shi, Xiaohan Zhang *et al.* « Description-Code Inconsistency in Real-world MCP Servers: Measurement, Detection, and Security Implications ». arXiv:2606.04769v1, déposée le 3 juin 2026 — prépublication non révisée par les pairs.
56. Andreas Schlapbach. « Formal Semantics for Agentic Tool Protocols: A Process Calculus Approach ». arXiv:2603.24747v3, déposée le 25 mars 2026, v3 du 2 juillet 2026 — prépublication non révisée par les pairs.
57. Ionut Predoaia, Tuong Manh Vu *et al.* « A Comparative Study of MCP and A2A for Inter-Agent Coordination in LLM-Based Systems ». arXiv:2607.23884v1, déposée le 26 juillet 2026 — prépublication non révisée par les pairs.
58. Gautam Bharti. « Registry Descriptions Go Stale Unevenly: An 89-Day Measurement of Model Context Protocol Drift, and Why Drift-Ranked Re-Auditing Under-Covers It ». arXiv:2608.00997v2, déposée le 2 août 2026, v2 du 4 août 2026 — prépublication non révisée par les pairs.
59. Benny Toeppe, Amine Barrak *et al.* « A Large-Scale Dataset of MCP Implementations on GitHub ». arXiv:2607.10123v1, déposée le 11 juillet 2026 — Proceedings of MSR '26: 23rd International Conference on Mining Software Repositories, April 13-14, 2026, Rio de Janeiro, Brazil. ACM, 2026.
60. Edoardo Allegrini, Ananth Shreekumar *et al.* « Formalizing the Safety, Security, and Functional Properties of Agentic AI Systems ». arXiv:2510.14133v2, déposée le 15 octobre 2025, v2 du 15 avril 2026 — prépublication non révisée par les pairs.
61. Samuel H. Christie, Amit K. Chopra *et al.* « Strabo: Declarative Specification and Implementation of Agentic Interaction Protocols ». arXiv:2606.05043v1, déposée le 3 juin 2026 — acceptation annoncée au seul champ *Comments* (« Presented in the Engineering Multiagent Systems Worksho »), non confirmée en notice.
62. Dun Yuan, Fuyuan Lyu *et al.* « Beyond Message Passing: A Semantic View of Agent Communication Protocols ». arXiv:2604.02369v3, déposée le 30 mars 2026, v3 du 13 avril 2026 — prépublication non révisée par les pairs.

63. Mugeng Liu, Shuoqi Li *et al.* « Beyond Static Endpoints: Tool Programs as an Interface for Flexible Agentic Web Services ». arXiv:2606.19992v1, déposée le 18 juin 2026 — acceptation annoncée au seul champ *Comments* (« Accepted by ICML 2026 »), non confirmée en notice.
64. Woohyuk Choi, Juhee Kim *et al.* « Agent Data Injection Attacks are Realistic Threats to AI Agents ». arXiv:2607.05120v1, déposée le 6 juillet 2026 — prépublication non révisée par les pairs.
65. Ben Nassi, Stav Cohen *et al.* « Invitation Is All You Need! Promptware Attacks Against LLM-Powered Assistants in Production Are Practical and Dangerous ». arXiv:2508.12175v1, déposée le 16 août 2025 — prépublication non révisée par les pairs.
66. Shuli Zhao, Qinsheng Hou *et al.* « Parasites in the Toolchain: A Large-Scale Analysis of Attacks on the MCP Ecosystem ». arXiv:2509.06572v5, déposée le 8 septembre 2025, v5 du 1 mai 2026 — acceptation annoncée au seul champ *Comments* (« Accepted by IEEE Symposium on Security and Privacy, 202 »), non confirmée en notice.
67. Zhiqiang Wang, Yichao Gao *et al.* « MCPTox: A Benchmark for Tool Poisoning Attack on Real-World MCP Servers ». arXiv:2508.14925v1, déposée le 19 août 2025 — prépublication non révisée par les pairs.
68. David Schmotz, Luca Beurer-Kellner *et al.* « Skill-Inject: Measuring Agent Vulnerability to Skill File Attacks ». arXiv:2602.20156v3, déposée le 23 février 2026, v3 du 25 février 2026 — prépublication non révisée par les pairs.
69. Hengyu An, Minxi Li *et al.* « ACIArena: Toward Unified Evaluation for Agent Cascading Injection ». arXiv:2604.07775v1, déposée le 9 avril 2026 — acceptation annoncée au seul champ *Comments* (« ACL 2026 »), non confirmée en notice.
70. Debeshee Das, Julien Piet *et al.* « Trojan Hippo: Weaponizing Agent Memory for Data Exfiltration ». arXiv:2605.01970v3, déposée le 3 mai 2026, v3 du 15 mai 2026 — prépublication non révisée par les pairs.
71. Xinhang Ma, Taoran Li *et al.* « AutoDojo: Adaptive Black-Box Attacks Reveal the Limits of IPI Defenses and Task-Specification Effects in LLM Agents ». arXiv:2606.15057v2, déposée le 13 juin 2026, v2 du 19 juin 2026 — prépublication non révisée par les pairs.
72. Hao Li, Ruoyao Wen *et al.* « AgentDyn: Are Your Agent Security Defenses Deployable in Real-World Dynamic Environments? ». arXiv:2602.03117v3, déposée le 3 février 2026, v3 du 7 mai 2026 — prépublication non révisée par les pairs.
73. Zixin Rao, Wentian Zhu *et al.* « FragFuse: Bypassing Access Control of Large Language Model Agents via Memory-Based Query Fragmentation and Fusion ». arXiv:2606.15609v1, déposée le 14 juin 2026 — acceptation annoncée au seul champ *Comments* (« 33 pages, 4 figures. Accepted by USENIX Security 2026 »), non confirmée en notice.
74. Dennis Jacob, Emad Alghamdi *et al.* « Preventing Prompt Injection with Type-Directed Privilege Separation ». arXiv:2509.25926v2, déposée le 30 septembre 2025, v2 du 8 mai 2026 — prépublication non révisée par les pairs.
75. Vladyslav Parakhin. « The Bureaucracy of Speed: Structural Equivalence Between Memory Consistency Models and Multi-Agent Authorization Revocation ». arXiv:2603.09875v1, déposée le 10 mars 2026 — prépublication non révisée par les pairs.
76. KrishnaSaiReddy Patil. « SentinelAgent: Intent-Verified Delegation Chains for Securing Federal Multi-Agent AI Systems ». arXiv:2604.02767v1, déposée le 3 avril 2026 — prépublication non révisée par les pairs.

77. Asiri Dalugoda. « HDP: A Lightweight Cryptographic Protocol for Human Delegation Provenance in Agentic AI Systems ». arXiv:2604.04522v1, déposée le 6 avril 2026 — prépublication non révisée par les pairs.
78. Yuan Sun. « Safe Bilevel Delegation (SBD): A Formal Framework for Runtime Delegation Safety in Multi-Agent Systems ». arXiv:2604.27358v1, déposée le 30 avril 2026 — prépublication non révisée par les pairs.
79. Mehmet Haklidir. « Consent Chain Degradation in Embodied Multi-Agent Systems: Bridging the Gap Between AI Agent Governance and Robot Ethics ». arXiv:2605.16300v1, déposée le 17 avril 2026 — acceptation annoncée au seul champ *Comments* (« Accepted for oral presentation at the 2nd Workshop on R »), non confirmée en notice.
80. Saurabh Deochake. « Heartbeat-Bound Hierarchical Credentials: Cryptographic Revocation for AI Agent Swarms ». arXiv:2605.20704v1, déposée le 20 mai 2026 — prépublication non révisée par les pairs.
81. Huijun Zhou, Xiaohan Zhang *et al.* « A First Measurement Study on Authentication Security in Real-World Remote MCP Servers ». arXiv:2605.22333v1, déposée le 21 mai 2026 — prépublication non révisée par les pairs.
82. Christophe Parisel. « Privilege Risk Evolution for Non-Human Identities: A Temporal Fiber Model for Cloud IAM ». arXiv:2606.03289v1, déposée le 2 juin 2026 — prépublication non révisée par les pairs.
83. Amjad Ibrahim et Yong Li. « Overlaying Governance: A Compositional Authorization Framework for Delegation and Scope in Agentic AI ». arXiv:2606.03518v1, déposée le 2 juin 2026 — prépublication non révisée par les pairs.
84. Abhinav Mishra et Kumar Sharad. « Observability for Delegated Execution in Agentic AI Systems ». arXiv:2606.09692v1, déposée le 8 juin 2026 — prépublication non révisée par les pairs.
85. Shenghan Zheng, Qifan Zhang *et al.* « Formal Security Analysis of Agent Protocol Composition ». arXiv:2606.28690v1, déposée le 27 juin 2026 — prépublication non révisée par les pairs.
86. Anton Sokolov. « Hardware-rooted attestation for AI-agent evidence: composing IETF RATS with action evidence packages ». arXiv:2608.00801v1, déposée le 1 août 2026 — prépublication non révisée par les pairs.
87. Igor Santos-Grueiro. « Lingering Authority: Revocable Resource-and-Effect Capabilities for Coding Agents ». arXiv:2606.22504v1, déposée le 21 juin 2026 — prépublication non révisée par les pairs.
88. Shaokun Zhang, Ming Yin *et al.* « Which Agent Causes Task Failures and When? On Automated Failure Attribution of LLM Multi-Agent Systems ». arXiv:2505.00212v3, déposée le 30 avril 2025, v3 du 2 juin 2025 — acceptation annoncée au seul champ *Comments* (« camera-ready »), non confirmée en notice.
89. Mengzhuo Chen, Junjie Wang *et al.* « Seeing the Whole Elephant: A Benchmark for Failure Attribution in LLM-based Multi-Agent Systems ». arXiv:2604.22708v1, déposée le 24 avril 2026 — acceptation annoncée au seul champ *Comments* (« Accepted by ACL 2026 »), non confirmée en notice.
90. Yizhe Xie, Congcong Zhu *et al.* « From Spark to Fire: Modeling and Mitigating Error Cascades in LLM-Based Multi-Agent Collaboration ». arXiv:2603.04474v2, déposée le 4 mars 2026, v2 du 11 mai 2026 — prépublication non révisée par les pairs.
91. Maksym Nechepurenko et Pavel Shuvalov. « Coordination as an Architectural Layer for LLM-Based Multi-Agent Systems ». arXiv:2605.03310v1, déposée le 5 mai 2026 — prépublication non révisée par les pairs.
92. Qineng Wang, Zihao Wang *et al.* « Rethinking the Bounds of LLM Reasoning: Are Multi-Agent Discussions the Key? ». arXiv:2402.18272v1, déposée le 28 février 2024 — prépublication non révisée

par les pairs *selon la notice*. **Publication établie hors notice**, recoupement Crossref du 15 août 2026 : actes de l'ACL 2024 (article long), doi:10.18653/v1/2024.acl-long.331 — *la notice ne porte ni `journal_ref` ni DOI.*

93. Andries Smit, Paul Duckworth *et al.* « Should we be going MAD? A Look at Multi-Agent Debate Strategies for LLMs ». arXiv:2311.17371v3, déposée le 29 novembre 2023, v3 du 18 juillet 2024 — prépublication non révisée par les pairs.
94. Prathyusha Jwalapuram, Hehai Lin *et al.* « The Illusion of Multi-Agent Advantage ». arXiv:2606.13003v2, déposée le 11 juin 2026, v2 du 13 juin 2026 — prépublication non révisée par les pairs.
95. Yuxuan Zhao, Sijia Chen *et al.* « When Does Multi-Agent Collaboration Help? An Entropy Perspective ». arXiv:2602.04234v6, déposée le 4 février 2026, v6 du 4 juin 2026 — prépublication non révisée par les pairs.
96. Chen Qian, Zihao Xie *et al.* « Scaling Large Language Model-based Multi-Agent Collaboration ». arXiv:2406.07155v3, déposée le 11 juin 2024, v3 du 17 mars 2025 — acceptation annoncée au seul champ *Comments* (« Accepted to ICLR-2025 »), non confirmée en notice.
97. Han Zhou, Xingchen Wan *et al.* « Multi-Agent Design: Optimizing Agents with Better Prompts and Topologies ». arXiv:2502.02533v2, déposée le 4 février 2025, v2 du 31 janvier 2026 — acceptation annoncée au seul champ *Comments* (« ICLR 2026 »), non confirmée en notice.
98. Siddhant Kulkarni et Yukta Kulkarni. « Benchmarking Multi-Agent LLM Architectures for Financial Document Processing: A Comparative Study of Orchestration Patterns, Cost-Accuracy Tradeoffs and Production Scaling Strategies ». arXiv:2603.22651v1, déposée le 24 mars 2026 — prépublication non révisée par les pairs.
99. Fulin Lin, Shaowen Chen *et al.* « Stop Wasting Your Tokens: Towards Efficient Runtime Multi-Agent Systems ». arXiv:2510.26585v2, déposée le 30 octobre 2025, v2 du 2 mars 2026 — acceptation annoncée au seul champ *Comments* (« Accepted to ICLR 2026. The code is available at https:/ »), non confirmée en notice.
100. Yian Wang, Agam Goyal *et al.* « State Contamination in Memory-Augmented LLM Agents ». arXiv:2605.16746v1, déposée le 16 mai 2026 — prépublication non révisée par les pairs.
101. Emre Turan. « Oversight Has a Capacity: Calibrating Agent Guards to a Subjective, Fatiguing Human ». arXiv:2606.08919v1, déposée le 8 juin 2026 — prépublication non révisée par les pairs.
102. Frank F. Xu, Yufan Song *et al.* « TheAgentCompany: Benchmarking LLM Agents on Consequential Real World Tasks ». arXiv:2412.14161v3, déposée le 18 décembre 2024, v3 du 10 septembre 2025 — prépublication non révisée par les pairs *selon la notice*. **Publication établie hors notice**, recoupement du 15 août 2026 : actes NeurIPS 2025, piste *Datasets and Benchmarks* — *la notice ne porte ni `journal_ref` ni DOI.*
103. Xingyao Wang, Boxuan Li *et al.* « OpenHands: An Open Platform for AI Software Developers as Generalist Agents ». arXiv:2407.16741v3, déposée le 23 juillet 2024, v3 du 18 avril 2025 — acceptation annoncée au seul champ *Comments* (« Accepted by ICLR 2025; Code: https://github.com/All-Han »), non confirmée en notice.
104. Kung-Hsiang Huang, Akshara Prabhakar *et al.* « CRMArena-Pro: Holistic Assessment of LLM Agents Across Diverse Business Scenarios and Interactions ». arXiv:2505.18878v1, déposée le 24 mai 2025 — prépublication non révisée par les pairs.
105. Yipeng Ouyang, Xin Huang *et al.* « Benchmarks are Not Enough: RAMP for Runtime Assessing of Agentic Models in Production Systems ». arXiv:2605.27492v1, déposée le 26 mai 2026 — prépublication non révisée par les pairs.

106. Sayash Kapoor, Benedikt Stroebl *et al.* « AI Agents That Matter ». arXiv:2407.01502v1, déposée le 1 juillet 2024 — prépublication non révisée par les pairs.
107. Yuxuan Zhu, Tengjun Jin *et al.* « Establishing Best Practices for Building Rigorous Agentic Benchmarks ». arXiv:2507.02825v5, déposée le 3 juillet 2025, v5 du 7 août 2025 — prépublication non révisée par les pairs *selon la notice*. **Publication établie hors notice**, recoupement du 15 août 2026 : actes NeurIPS 2025, piste *Datasets and Benchmarks* — *la notice ne porte ni `journal_ref` ni DOI, et cette pièce n'est pas non plus indexée à DBLP sous NeurIPS : le recoupement lui-même décroche.*
108. Shanchao Liang, Spandan Garg *et al.* « The SWE-Bench Illusion: When State-of-the-Art LLMs Remember Instead of Reason ». arXiv:2506.12286v4, déposée le 14 juin 2025, v4 du 1 décembre 2025 — prépublication non révisée par les pairs.
109. Florian E. Dorner, Vivian Y. Nastl *et al.* « Limits to scalable evaluation at the frontier: LLM as Judge won't beat twice the data ». arXiv:2410.13341v3, déposée le 17 octobre 2024, v3 du 6 janvier 2026 — acceptation annoncée au seul champ *Comments* (« ICLR 2025; 28 pages, 8 figures »), non confirmée en notice.
110. Mingchen Zhuge, Changsheng Zhao *et al.* « Agent-as-a-Judge: Evaluate Agents with Agents ». arXiv:2410.10934v2, déposée le 14 octobre 2024, v2 du 16 octobre 2024 — prépublication non révisée par les pairs.
111. Darshan Deshpande, Varun Gangal *et al.* « TRAIL: Trace Reasoning and Agentic Issue Localization ». arXiv:2505.08638v3, déposée le 13 mai 2025, v3 du 23 juin 2025 — prépublication non révisée par les pairs.
112. Renan Souza, Amal Gueroudji *et al.* « PROV-AGENT: Unified Provenance for Tracking AI Agent Interactions in Agentic Workflows ». arXiv:2508.02866v3, déposée le 4 août 2025, v3 du 20 août 2025 — acceptation annoncée au seul champ *Comments* (« Paper accepted for publication in the Proceedings of th »), non confirmée en notice.
113. Yi Nian, Aojie Yuan *et al.* « Auditable Agents ». arXiv:2604.05485v2, déposée le 7 avril 2026, v2 du 13 août 2026 — acceptation annoncée au seul champ *Comments* (« 24 pages, 1 figure. Extended version. A condensed 4-pag »), non confirmée en notice.
114. Qian'ang Mao, Jiaxin Wang *et al.* « SoK: Security of Autonomous LLM Agents in Agentic Commerce ». arXiv:2604.15367v2, déposée le 15 avril 2026, v2 du 1 mai 2026 — prépublication non révisée par les pairs.
115. Yuanzhe Zhang, Yuexin Xiang *et al.* « SoK: Blockchain Agent-to-Agent Payments ». arXiv:2604.03733v1, déposée le 4 avril 2026 — prépublication non révisée par les pairs.
116. Tanusree Debi, Wentian Zhu *et al.* « Whispers of Wealth: Red-Teaming Google's Agent Payments Protocol via Prompt Injection ». arXiv:2601.22569v2, déposée le 30 janvier 2026, v2 du 18 mai 2026 — prépublication non révisée par les pairs.
117. Qianlong Lan, Anuj Kaul *et al.* « Zero-Trust Runtime Verification for Agentic Payment Protocols: Mitigating Replay and Context-Binding Failures in AP2 ». arXiv:2602.06345v1, déposée le 6 février 2026 — prépublication non révisée par les pairs.
118. Xihan Xiong, Zelin Li *et al.* « Can Trustless Agents Be Trusted? An Empirical Study of the ERC-8004 Decentralized AI Agent Ecosystem ». arXiv:2606.26028v2, déposée le 24 juin 2026, v2 du 8 juillet 2026 — prépublication non révisée par les pairs.
119. Sara Fish, Yannai A. Gonczarowski *et al.* « Algorithmic Collusion by Large Language Models ». arXiv:2404.00806v5, déposée le 31 mars 2024, v5 du 5 mars 2026 — prépublication non révisée par les pairs.
120. Jussi Keppo, Yuze Li *et al.* « On the Fragility of AI Agent Collusion ». arXiv:2603.20281v1, déposée le 18 mars 2026 — prépublication non révisée par les pairs.

121. Yingtao Tian. « Prompt Optimization Enables Stable Algorithmic Collusion in LLM Agents ». arXiv:2604.17774v1, déposée le 20 avril 2026 — prépublication non révisée par les pairs.
122. Gagan Bansal, Wenyue Hua *et al.* « Magentic Marketplace: An Open-Source Environment for Studying Agentic Markets ». arXiv:2510.25779v1, déposée le 27 octobre 2025 — prépublication non révisée par les pairs.
123. Xianyang Liu, Shangding Gu *et al.* « AgenticPay: A Multi-Agent LLM Negotiation System for Buyer-Seller Transactions ». arXiv:2602.06008v1, déposée le 5 février 2026 — prépublication non révisée par les pairs.
124. Amine Allouah, Omar Besbes *et al.* « What Is Your AI Agent Buying? Evaluation, Biases, Model Dependence, & Emerging Implications for Agentic E-Commerce ». arXiv:2508.02630v3, déposée le 4 août 2025, v3 du 17 décembre 2025 — prépublication non révisée par les pairs *selon la notice*. **Publication établie hors notice**, recoupement Crossref du 15 août 2026 : *Proceedings of the ACM Web Conference 2026*, doi:10.1145/3774904.3792943 — *la notice ne porte ni `journal_ref` ni DOI ; à ne pas confondre avec la version SSRN de 2025 des mêmes auteurs, au sous-titre différent.*
125. Alexander Erlei et Lukas Meub. « LLM-Agent Interactions on Markets with Information Asymmetries ». arXiv:2603.08853v1, déposée le 9 mars 2026 — prépublication non révisée par les pairs.
126. Bardia Mohammadi, Nearchos Potamitis *et al.* « Atomix: Timely, Transactional Tool Use for Reliable Agentic Workflows ». arXiv:2602.14849v2, déposée le 16 février 2026, v2 du 29 mai 2026 — prépublication non révisée par les pairs.
127. Edward Y. Chang, Longling Geng *et al.* « Mnemosyne: Agentic Transaction Processing for Validating and Repairing AI-generated Workflows ». arXiv:2607.00269v2, déposée le 30 juin 2026, v2 du 5 juillet 2026 — prépublication non révisée par les pairs.
128. Sajjad Khan. « Verified Detection and Prevention of Concurrency Anomalies in Multi-Agent Large Language Model Systems ». arXiv:2606.17182v1, déposée le 15 juin 2026 — prépublication non révisée par les pairs.
129. Zhiyuan Zhai, Ming Li *et al.* « Revisable by Design: A Theory of Streaming LLM Agent Execution ». arXiv:2604.23283v1, déposée le 25 avril 2026 — prépublication non révisée par les pairs.
130. Hoang Vu, Maximilian Körner *et al.* « Agent Behavior Mining: Generative AI Agent Governance in Business Processes ». arXiv:2606.20669v1, déposée le 12 juin 2026 — acceptation annoncée au seul champ *Comments* (« Accepted at BPM conference 2026 management main track »), non confirmée en notice.
131. Alexander Rombach, Chantale Lauer *et al.* « Neuro-Symbolic Agents for Regulated Process Automation: Challenges and Research Agenda ». arXiv:2606.13405v2, déposée le 11 juin 2026, v2 du 22 juin 2026 — acceptation annoncée au seul champ *Comments* (« Accepted as a poster in NILA Workshop @ IJCAI-ECAI 2026 »), non confirmée en notice.
132. Fabiana Fournier et Lior Limonad. « A Process Harness for Uplifting Legacy Workflows to Agentic BPM: Design and Realization in CUGA FLO ». arXiv:2606.27188v1, déposée le 25 juin 2026 — prépublication non révisée par les pairs.
133. Adem Ait, Javier Luis Cánovas Izquierdo *et al.* « Towards Modeling Human-Agentic Collaborative Workflows: A BPMN Extension ». arXiv:2412.05958v3, déposée le 8 décembre 2024, v3 du 27 juin 2025 — acceptation annoncée au seul champ *Comments* (« Accepted in the Euromicro Conference Series on Software »), non confirmée en notice.
134. Ylli Prifti. « Specifying AI-SDLC Processes: A Protocol Language for Human-Agent Boundaries ». arXiv:2606.20615v2, déposée le 24 mai 2026, v2 du 24 juin 2026 — prépublication non révisée par les pairs.

135. Saimir Bala, Fabiana Fournier *et al.* « Using Process Mining to Generate AI Agents from Software Engineering Process Records ». arXiv:2607.04948v1, déposée le 6 juillet 2026 — acceptation annoncée au seul champ *Comments* (« To be published at the 24th International Conference on »), non confirmée en notice.
136. Chantale Lauer, Peter Pfeiffer *et al.* « Assessing the Business Process Modeling Competences of Large Language Models ». arXiv:2601.21787v2, déposée le 29 janvier 2026, v2 du 29 juin 2026 — Information Systems, Vol. 142 (2026), Art. 102761, doi:10.1016/j.is.2026.102761.
137. Ilias Chalkidis, Vlad Paul Cosma *et al.* « Hybrid AI for Explainable and Accurate Conversational Agents in eGovernment ». arXiv:2608.01346v1, déposée le 2 août 2026 — acceptation annoncée au seul champ *Comments* (« Presented at AIDA2J Workshop at ICAIL 2026, SMU, Singap »), non confirmée en notice.
138. Luca Nannini, Adam Leon Smith *et al.* « AI Agents Under EU Law ». arXiv:2604.04604v1, déposée le 6 avril 2026 — prépublication non révisée par les pairs.
139. Kathrin Gardhouse, Amin Oueslati *et al.* « Regulating AI Agents ». arXiv:2603.23471v2, déposée le 24 mars 2026, v2 du 7 juillet 2026 — prépublication non révisée par les pairs.
140. Yiheng Yao. « Acting with AI: An Interaction-Based Framework for Agentic Tort Liability ». arXiv:2606.00518v1, déposée le 30 mai 2026 — prépublication non révisée par les pairs.
141. Mark O. Riedl et Deven R. Desai. « AI Agents and the Law ». arXiv:2508.08544v1, déposée le 12 août 2025 — acceptation annoncée au seul champ *Comments* (« 2025 AAAI Conference on AI, Ethics, and Society »), non confirmée en notice.
142. Garry A. Gabison et R. Patrick Xian. « Inherent and emergent liability issues in LLM-based agentic systems: a principal-agent perspective ». arXiv:2504.03255v2, déposée le 4 avril 2025, v2 du 17 juin 2025 — **publication attestée en notice**, doi:10.18653/v1/2025.realm-1.9.
143. Johann Laux et Hannah Ruschemeier. « Automation Bias in the AI Act: On the Legal Implications of Attempting to De-Bias Human Oversight of AI ». arXiv:2502.10036v2, déposée le 14 février 2025, v2 du 20 juin 2025 — Eur. j. risk regul. 16 (2025) 1519-1534, doi:10.1017/err.2025.10033.
144. Leon Staufer, Kevin Feng *et al.* « The 2025 AI Agent Index: Documenting Technical and Safety Features of Deployed Agentic AI Systems ». arXiv:2602.17753v2, déposée le 19 février 2026, v2 du 6 mai 2026 — **publication attestée en notice**, doi:10.1145/3805689.3806728.
145. Mubarak Raji et Masooda Bashir. « Towards Agentic AI Governance: A Preliminary Assessment ». arXiv:2607.07612v1, déposée le 8 juillet 2026 — acceptation annoncée au seul champ *Comments* (« International Conference on the AI Revolution: Research »), non confirmée en notice.
146. Irene Aldridge et Steve Krawciw. « AI Governance for Institutional Readiness in Finance ». arXiv:2608.02311v2, déposée le 3 août 2026, v2 du 10 août 2026 — prépublication non révisée par les pairs.
147. Gabriela Aránguiz Dias, Kiana Jafari *et al.* « The Doctor Will (Still) See You Now: On the Structural Limits of Agentic AI in Healthcare ». arXiv:2602.18460v1, déposée le 6 février 2026 — prépublication non révisée par les pairs.
148. Sebastian Lobentanzer. « Quantifying the Expectation-Realisation Gap for Agentic AI Systems ». arXiv:2602.20292v2, déposée le 23 février 2026, v2 du 25 février 2026 — prépublication non révisée par les pairs.
149. Eranga Bandara, Ross Gore *et al.* « Towards an Agent-First Web: Redesigning the Web for AI Agents ». arXiv:2606.19116v1, déposée le 17 juin 2026 — prépublication non révisée par les pairs.
150. Sven Schultze, Meike Verena Kietzmann *et al.* « Building the Web for Agents: A Declarative Framework for Agent-Web Interaction ». arXiv:2511.11287v1, déposée le 14 novembre 2025 — prépublication non révisée par les pairs.

151. Taein Kim, Karstan Bock *et al.* « Scrapers selectively respect robots.txt directives: evidence from a large-scale empirical study ». arXiv:2505.21733v2, déposée le 27 mai 2025, v2 du 23 octobre 2025 — prépublication non révisée par les pairs.
152. Ethan Wang, Zubair Shafiq *et al.* « FP-Agent: Fingerprinting AI Browsing Agents ». arXiv:2605.01247v1, déposée le 2 mai 2026 — prépublication non révisée par les pairs.
153. Zhe Ren, Yimeng Chen *et al.* « Self-Improvements in Modern Agentic Systems: A Survey ». arXiv:2607.13104v1, déposée le 14 juillet 2026 — prépublication non révisée par les pairs.
154. Ruixiao Lin, Xinhao Deng *et al.* « Safety in Self-Evolving LLM Agent Systems: Threats, Amplification, and Case Studies ». arXiv:2606.23075v1, déposée le 22 juin 2026 — prépublication non révisée par les pairs.
155. K. J. Kevin Feng, David W. McDonald *et al.* « Levels of Autonomy for AI Agents ». arXiv:2506.12469v2, déposée le 14 juin 2025, v2 du 28 juillet 2025 — acceptation annoncée au seul champ *Comments* (« Published in the Knight 1st Amendment Institute's "AI a »), non confirmée en notice.
156. Peter Cihon, Merlin Stein *et al.* « Measuring AI agent autonomy: Towards a scalable approach with code inspection ». arXiv:2502.15212v1, déposée le 21 février 2025 — acceptation annoncée au seul champ *Comments* (« NeurIPS Socially Responsible Language Modelling Researc »), non confirmée en notice.
157. Eric Xing, Mingkai Deng *et al.* « Critique of Agent Model ». arXiv:2606.23991v1, déposée le 22 juin 2026 — prépublication non révisée par les pairs.
158. Pradyumna Shome, Sashreek Krishnan *et al.* « Why Johnny Can't Use Agents: Industry Aspirations vs. User Realities with AI Agents ». arXiv:2509.14528v2, déposée le 18 septembre 2025, v2 du 3 mai 2026 — **publication attestée en notice**, doi:10.1145/3786335.3813140.
159. Yubin Kim, Ken Gu *et al.* « Towards a Science of Scaling Agent Systems ». arXiv:2512.08296v3, déposée le 9 décembre 2025, v3 du 8 avril 2026 — prépublication non révisée par les pairs.
160. Yuzhen Mao et Azalia Mirhoseini. « Decentralized Multi-Agent Systems with Shared Context ». arXiv:2606.10662v1, déposée le 9 juin 2026 — prépublication non révisée par les pairs.
161. Alireza Salemi, Mihir Parmar *et al.* « LLM-Based Multi-Agent Blackboard System for Information Discovery in Data Science ». arXiv:2510.01285v2, déposée le 30 septembre 2025, v2 du 31 janvier 2026 — prépublication non révisée par les pairs.
162. Dong Wang, Yang Li *et al.* « Matrix: Peer-to-Peer Multi-Agent Synthetic Data Generation Framework ». arXiv:2511.21686v2, déposée le 26 novembre 2025, v2 du 18 avril 2026 — acceptation annoncée au seul champ *Comments* (« MLSys 2026 »), non confirmée en notice.
163. Viktor Strate Kløvedal, Dan Plyukhin *et al.* « Accompanist: A Runtime for Resilient Choreographic Programming ». arXiv:2603.20942v1, déposée le 21 mars 2026 — prépublication non révisée par les pairs — le champ *Comments* annonce une soumission (« 23 pages, 16 figures, submitted to OOPSLA 2026 »), non une acceptation.
164. Haejoon Lee, Vincent-Daniel Yun *et al.* « Robust Multi-Agent LLMs under Byzantine Faults ». arXiv:2605.09076v2, déposée le 9 mai 2026, v2 du 29 juin 2026 — prépublication non révisée par les pairs.
165. Frédéric Berdoz, Leonardo Rugli *et al.* « Can AI Agents Agree? ». arXiv:2603.01213v2, déposée le 1 mars 2026, v2 du 12 mars 2026 — prépublication non révisée par les pairs.
166. Blaž Bertalanič et Carolina Fortuna. « The Ringelmann Effect in Multi-Agent LLM Systems: A Scaling Law for Effective Team Size ». arXiv:2606.02646v1, déposée le 31 mai 2026 — prépublication non révisée par les pairs.
167. Kaixuan Liu, Guojun Xiong *et al.* « Social Networks of LLM Agents ». arXiv:2607.03695v1, déposée le 4 juillet 2026 — prépublication non révisée par les pairs.

168. Oleksandr Kuznetsov et Emanuele Frontoni. « Width, Memory, and Delay: A Resource Accounting for the Limits of Flat Multi-Agent Systems ». arXiv:2608.00028v1, déposée le 14 juillet 2026 — prépublication non révisée par les pairs.
169. Ahmad Rammal, Niket Patel *et al.* « Formalizing Mathematics at Scale ». arXiv:2605.29955v1, déposée le 28 mai 2026 — prépublication non révisée par les pairs.
170. Yashaswi Malla et Sandra Siby. « From Monoliths to Swarms: A Study of Attack Surface Evolution in the Transition to Multi-Agent Web Systems ». arXiv:2608.00202v1, déposée le 31 juillet 2026 — prépublication non révisée par les pairs.
171. Shuren Xia, Qiwei Li *et al.* « TraceFix: Repairing Agent Coordination Protocols with TLA+ Counterexamples ». arXiv:2605.07935v1, déposée le 8 mai 2026 — prépublication non révisée par les pairs.
172. Ruiyang Zhang. « Why Formal Monitors Fail: Attack Distribution Entropy as a Coverage Bound for LTL-Based LLM Agent Safety ». arXiv:2608.01388v1, déposée le 2 août 2026 — acceptation annoncée au seul champ *Comments* (« 6 pages, 1 figure. Accepted at the 13th IEEE Internat »), non confirmée en notice.
173. Mason Nakamura, Abhinav Kumar *et al.* « Colosseum: Auditing Collusion in Cooperative Multi-Agent Systems ». arXiv:2602.15198v2, déposée le 16 février 2026, v2 du 27 mai 2026 — prépublication non révisée par les pairs.
174. Institut national des normes et de la technologie (NIST). « Artificial Intelligence Risk Management Framework (AI RMF 1.0) ». NIST AI 100-1, janvier 2023. https://doi.org/10.6028/NIST.AI.100-1
175. H. Garcia-Molina et K. Salem. « Sagas ». *ACM SIGMOD Record*, vol. 16, n° 3, 1987, p. 249-259 — **actes SIGMOD 1987**. https://doi.org/10.1145/38714.38742
176. S. Burckhardt, C. Gillum, D. Justo *et al.* « Durable Functions: Semantics for Stateful Serverless ». *Proceedings of the ACM on Programming Languages*, vol. 5, OOPSLA, 2021 — **comité de lecture**. https://doi.org/10.1145/3485510
177. Marc Alier Forment, María José Casañ Guerrero *et al.* « The Scaffolding Matters More Than the Interface: A Controlled Comparison of MCP and CLI Tool Use Across Seven Agent Scaffoldings, Five Language Models, and One Software Task ». arXiv:2608.08654v1, déposée le 9 août 2026 — prépublication non révisée par les pairs.
178. Rana Muhammad Ahmed et Sabahat Abbas. « Labels Are Not Endpoints: Treatment Leakage and Construct Validity in MCP Agent Security Evaluation ». arXiv:2608.12880v1, déposée le 13 août 2026 — prépublication non révisée par les pairs.
179. Suraj Kumar, Amy Wang *et al.* « A Gateway Architecture for Enterprise MCP Authentication: Unifying Heterogeneous Auth, Identity Delegation, and the User / Non-User Persona Problem ». arXiv:2608.10760v1, déposée le 11 août 2026 — prépublication non révisée par les pairs.
180. Varun Pratap Bhardwaj, Garima Singh *et al.* « Agent Behavioral Contracts II: Certifying Compositional Reliability Without Assuming Independence ». arXiv:2608.12895v1, déposée le 13 août 2026 — prépublication non révisée par les pairs.
181. Shangao Li, Yao Zhang *et al.* « QuoteBench: How Matched Scores Can Hide Command-Path Failures ». arXiv:2608.13547v1, déposée le 13 août 2026 — prépublication non révisée par les pairs.
182. Jesus Salas. « Correct Is Not Governed: Provenance Integrity in Agentic Workflows ». arXiv:2608.12761v1, déposée le 13 août 2026 — prépublication non révisée par les pairs.
183. Minhan Cho, Soyoung Park *et al.* « LLM within MCP Matters: Measuring Inefficient Resource Utilization Driven by LLMs ». arXiv:2608.08467v1, déposée le 9 août 2026 — acceptation annoncée au seul champ *Comments* (« 4 pages, 1 table. Accepted at the AgentSearch Workshop »), non confirmée en notice.

184. Zixing Chen, Xingyuan Liu *et al.* « REDAgentBench: Executable Red Teaming and Faithful Measurement of LLM Agent Systems ». arXiv:2608.10669v1, déposée le 11 août 2026 — prépublication non révisée par les pairs.
185. Sanjay Kariyappa, Severin Klingler *et al.* « PIPES: Securing Agent Perception with Provenance and Priors ». arXiv:2608.12789v1, déposée le 13 août 2026 — prépublication non révisée par les pairs.
186. Guodong Xu. « Governed Persistent Memory: Source-Bound State Semantics and Fail-Closed Release for Long-Horizon Agents ». arXiv:2608.12476v1, déposée le 12 août 2026 — prépublication non révisée par les pairs.
187. Shuyu Jiang, Yue Ran *et al.* « ASCon: A Direction-Aware Reciprocal Agent–Step Contextualization Model for Failure Attribution in Multi-Agent Systems ». arXiv:2608.10646v1, déposée le 11 août 2026 — prépublication non révisée par les pairs.
188. Scott E. Frias. « Similarity Gates Approve Reversals: A Validity Audit of Embedding-Cosine Thresholds in Agent Systems ». arXiv:2608.10216v1, déposée le 10 août 2026 — prépublication non révisée par les pairs.
189. Yiqi Wang, Zihao Yan *et al.* « MAP-Graph: Provenance-Aware Shared Memory for Multi-Agent Workflows ». arXiv:2608.10509v1, déposée le 11 août 2026 — prépublication non révisée par les pairs.
190. Vasundra Srinivasan. « Deployment Decision Reliability: A Generalizability-Theory Framework for Sizing Long-Horizon Agent Evaluations ». arXiv:2608.11323v1, déposée le 11 août 2026 — prépublication non révisée par les pairs.
191. Henry Han. « Governing Agentic AI in FinTech ». arXiv:2608.11344v2, déposée le 11 août 2026, v2 du 13 août 2026 — prépublication non révisée par les pairs.
192. Abdullah X. « Multi-Agent AI Safety as an Institutional Design Problem ». arXiv:2608.09828v1, déposée le 10 août 2026 — prépublication non révisée par les pairs.

Annexe : reprise du 29 octobre 2026

Les 189 notices arXiv du corpus ont été reprises à l'API d'exportation du dépôt le 29 octobre 2026, soixante-quinze jours après la reprise du 15 août : 189 demandées, 189 obtenues, aucune retirée ni devenue introuvable. Mêmes champs — titre, auteurs, version courante, dates de dépôt et de dernière révision, `journal_ref`, DOI, `comment` —, même règle de partage (2.2). Aucune passe neuve n'a été conduite : aucune pièce n'est versée au corpus, dont le corps reste gelé au 15 août 2026. Cette annexe dit ce qui a bougé dans les notices, ce que cela change aux énoncés de la revue, et corrige quatre erreurs relevées à la relecture. Une vérification de forme la précède : les titres, dates de dépôt, versions et dates de révision portés par la bibliographie concordent tous avec l'historique des notices ; seuls deux titres ont changé depuis, par révision.

Le régime de preuve au 29 octobre

Tableau 9 — Régimes de preuve des 189 pièces déposées sur arXiv, aux reprises du 15 août et du 29 octobre 2026, d'après les notices de l'API du dépôt. Les parts portent sur ce corpus et sur ce que la notice déclare, non sur le champ.

Régime	15 août 2026	Part	29 octobre 2026	Part
Publication attestée en notice (`journal_ref` ou DOI)	12	6 %	16	8 %
Acceptation auto-déclarée (champ de commentaire)	32	17 %	34	18 %
Aucun signe de revue par les pairs	145	77 %	139	74 %
Total	189	100 %	189	100 %

Seize notices ont bougé en soixante-quinze jours : quatorze par une version nouvelle, deux par le seul ajout d'une référence de publication, [11] et [116]. Quatre pièces passent au régime attesté : [11] (*Journal of Information Security and Applications*, 2026, article 104645, au champ `journal_ref` et par DOI), du socle hérité ; [67] (DOI des actes de l'AAAI, 10.1609/aaai.v40i42.40895) et [70] (DOI de l'ACM, 10.1145/3847352.3848090), du front de la sécurité ; [116] (actes d'IMNS 2026, IEEE, au champ `journal_ref` et par DOI), de la couche transactionnelle. Deux passent à l'acceptation auto-déclarée : [119] (« Accepted to EC 2026 ») et [164] (« EMNLP 2026 Main Accepted »). Aucune ne régresse.

La part du non-arbitré baisse de trois points, et elle baisse par la mise à jour des notices, non par l'arrivée de pièces arbitrées. Elle reste un plafond (17) : les quatre pièces dont la passe de contrôle avait trouvé la publication — [92], [102], [107] et [124] — ne la déclarent toujours pas. Quant à la stabilité des textes, 99 pièces sur 189 en sont encore à leur version initiale, soit 52 % contre 54 %, et 137 ont été révisées pour la dernière fois en 2026. Quatorze révisions en dix semaines : 7 % du corpus, au rythme que mesurait la section 3.1.

Ce que le corpus arbitré en retient. Le tableau 8 compterait désormais seize pièces. Deux des six fronts qu'il donnait pour vides en sortent — la sécurité, par [67] et [70], et la couche transactionnelle, par [116] —, et l'un des six résultats qu'il disait sans appui attesté en reçoit un : que le mandat signé ne soit pas le point de rupture repose en partie sur [116], désormais publié. Au front de la chorégraphie et de l'essaim, [164] rejoint [162] et [172] parmi les acceptations annoncées au seul champ de commentaire (13). Restent sans pièce attestée l'identité et la délégation, les systèmes multi-agents, l'évaluation, la chorégraphie et l'essaim ; et le résultat le plus décisif du front de la sécurité, que les scores de défense ne survivent pas à l'adversaire adaptatif [71], n'en a toujours aucune.

Les révisions qui touchent un chiffre cité

Tableau 10 — Les sept révisions du 15 août au 29 octobre 2026 dont le résumé a changé, avec ce que la revue en cite et ce que porte le résumé courant.

Réf. (section)	Version	Cité par la revue (15 août)	Résumé courant (29 octobre)
[67] (5.1, 5.3)	v1 → v2, 29 sept.	1 312 cas de test ; 72,8 % de succès sur o1-mini ; refus inférieur à 3 %	1 348 cas de test ; 72,8 % et moins de 3 % inchangés
[70] (5.2)	v3 → v4, 28 sept.	« Trojan Hippo: Weaponizing Agent Memory for Data Exfiltration » ; de 85-100 % à 0-5 %	titre devenu « Trojan Hippo Bench: A Dynamic Benchmark for Persistent Memory Attacks and Defenses in LLM Agents » ; chiffres inchangés
[71] (5.1, tableau 7)	v2 → v3, 28 sept.	trois suites, cinq modèles ; une défense à 0 % remonte à 28 % au global et à 64 % sur les tâches à action déléguée	titre devenu « AutoDojo: A Generative Benchmark for Evaluating Prompt Injection Defenses in LLM Agents » ; dix défenses, cinq modèles, six suites sur AgentDojo et AgentDyn ; « static benchmarks often significantly overestimate defense efficacy » ; les chiffres 0 %, 28 % et 64 % ne figurent plus au résumé
[127] (10.1)	v2 → v3, 31 août	moins de 6 % de surcoût	de 5,2 à 6,6 % de coût de débit incrémental, sur une mesure refaite ; comparaison avec le SDK de Temporal ajoutée
[134] (10.2, 15.2)	v2 → v3, 16 août	langage de protocole ; « empirical evaluation is future work »	théorème de correction mécanisé en Lean 4 ; gain de 14 à 22 points sur SWE-bench Verified, évalué par les auteurs ; soumission annoncée à ACM TOSEM, qui ne compte pas
[160] (13.1)	v1 → v3, 4 oct.	+10,5 points sur SWE-bench Verified, coût par tâche réduit de moitié	jusqu'à 17,5 points et 2,49 fois plus rapide, sur Terminal-Bench 4.0, DeepSWE et SWE-bench Verified ; le coût par tâche ne figure plus au résumé
[164] (13.2)	v2 → v3, 30 août	(F+1)-robustesse sur le graphe	résumé inchangé quant au fond ; acceptation à EMNLP 2026 annoncée

La mise en garde de la section 3.1 se vérifie une seconde fois : une pièce citée peut changer de chiffre sans changer de numéro. Deux cas pèsent. [71] porte, au corps de cette revue et à son tableau 7, le résultat décisif du front de la sécurité ; sa version courante ne l'énonce plus au résumé et en élargit le dispositif. La conclusion qualitative — les bancs statiques surestiment les défenses — tient et s'étend ; le chiffre, lui, ne vaut plus que pour la v2. [127] franchit la borne que la section 10.1 lui prêtait : « moins de 6 % » devient « 5,2 à 6,6 % ». Les sept autres révisions laissent leur résumé inchangé — [42], [109], [113], [118], [119], [186] et [191] —, [113] n'ajustant que son commentaire : la version condensée y fait désormais cinq pages, acceptée à l'ACM AI Summit 2026.

Le contrôle refait

La requête « conformance checking » AND « LLM » de la section 10.3 rend huit entrées au lieu de sept. L'entrée supplémentaire, arXiv:2606.18425, déposée le 16 juin 2026, y entre par sa v2 du 8 septembre : elle confronte un flot de travail généré à sa propre spécification, non une trace d'agent autonome à un modèle de processus. Aucun dépôt n'est postérieur au 15 août. La lacune tient.

Les trois énoncés de la veille au 29 octobre

La revue a laissé à la veille quatre faits qu'elle porte seule (17). La reprise du 29 octobre de la même veille — auto-citation déclarée — les rouvre ; aucun verdict de la section 15 n'en est déplacé.

Délégation (15.1). Le groupe WIMSE de l'IETF a adopté le 15 septembre 2026 un premier document agentique, AIMS, informationnel, sans protocole neuf ni chaîne à N sauts ; des douze brouillons de délégation que relève la veille, aucun n'est adopté et deux ont expiré. « Normalisé » reste faux. Le déficit d'adoption a cessé d'être total ; il n'a pas cessé d'être un déficit d'adoption.

Orchestration (15.2). Camunda 8.10 expose les processus BPMN déployés comme outils MCP, et aucun protocole n'a adopté de formalisme de processus. Le mouvement vient encore de l'industrie, côté moteur : la section 15.2 avait prévu ce cas, qui confirme le verdict au lieu de l'infirmer. Aucune pièce du corpus ne mesure l'adoption d'un formalisme agentique par un moteur.

Observabilité (15.3). Le registre GenAI d'OpenTelemetry compte 85 attributs au 29 octobre, contre 63 au 15 août, tous en développement ; aucun ne décrit de chaîne de mandat, et les propositions d'identité et d'autorisation d'agent restent ouvertes. L'énoncé tient, et l'arbitrage porte toujours, comme l'écrivait la section 15.3, sur l'émission et la liaison, non sur la nomenclature.

Errata de la relecture du 29 octobre

Tableau 11 — Errata de l'édition du 15 août 2026. « Corps » : corrigé à sa place ; « annexe » : corrigé ici seulement.

N°	Où	Erreur	Correction	Traitement
1	12, introduction	« quatre mesures, dont deux arbitrées »	une seule pièce attestée sur ce front, [158] (tableau 8) ; [155] et [156], acceptations autodéclarées, sont une position et une architecture, non des mesures : « dont une arbitrée »	corps
2	tableau 8 et réf. [59]	« MSR ‘26 »	« MSR ’26 » — le champ `journal_ref` porte « MSR ‘26 »	corps
3	7.2 (tableau 4), 14.3	onze constructions d'auteurs et quatre évaluations indépendantes font quinze pièces sur quatorze ; « les exceptions étant exactement les pièces concluant au non-avantage »	[92], qui propose son propre cadre de discussion (résumé de sa notice) et conclut au non-avantage, est compté des deux côtés ; les exceptions sont trois des quatre pièces concluant au non-avantage	corps (14.3) ; annexe (tableau 4)

N°	Où	Erreur	Correction	Traitement
4	18	« Ce corpus peut seulement dire où regarder — et sur les trois énoncés soumis, elle l'a fait »	le sujet est la revue : « la revue l'a fait »	corps

Ce que cette reprise n'a pas fait

Aucune passe neuve sur les dix fronts : les dépôts du 15 août au 29 octobre 2026 ne sont ni lus ni versés, et la passe de contrôle sur DBLP, Crossref et OpenAlex n'a pas été refaite. Le corpus a donc soixante-quinze jours de retard sur le dépôt ; cette annexe en date les notices, non le champ.

Annexe : actualisation de novembre 2026

Cette annexe date l'actualisation de l'édition du 15 août 2026 au 1er novembre 2026. Elle ne réécrit ni le corps, gelé au 15 août, ni l'annexe du 29 octobre, qui reste en place et fait foi pour sa date. Elle fait ce que cette dernière déclarait n'avoir pas fait : les 189 notices arXiv du corpus sont reprises une troisième fois, la passe de contrôle de publication est refaite, et une passe neuve est conduite sur les dix fronts pour les dépôts postérieurs au 13 août 2026. Aucune pièce nouvelle n'est versée au corpus : la passe de novembre dit ce que les pièces retenues changent aux énoncés de la revue, non ce que serait la revue si elle les avait lues. Les références [193] et suivantes sont propres à cette annexe.

Régime déclaré : celui des passes d'origine (2.1, 2.2) — notices lues à l'API d'exportation d'arXiv, partage des régimes à la seule notice, rétention au critère de la mesure produite, sur un seul jugement —, conduit par des agents LLM (Claude, Anthropic) à consigne de source primaire exclusive. Les quarante pièces de la passe de novembre ont été contre-vérifiées à l'API, titre et version, par l'agent qui a assemblé l'annexe. Seuls les résumés et les métadonnées ont été lus, non le texte des pièces. L'annexe n'a pas été relue par l'auteur avant sa composition.

Le régime de preuve au 1er novembre

Les 189 notices arXiv du corpus ont été reprises à l'API d'exportation du dépôt le 1er novembre 2026, trois jours après la reprise du 29 octobre [193] : quatre lots de 50, 50, 50 et 39 identifiants, 189 notices demandées, 189 obtenues, aucune retirée ni devenue introuvable. Mêmes champs — titre, auteurs, version courante, dates de dépôt et de dernière révision, `journal_ref`, DOI, `comment` —, même règle de partage (2.2). La correspondance des numéros de la bibliographie aux identifiants a été refaite sur le texte de la revue avant la requête : 192 entrées, 189 identifiants arXiv distincts, trois pièces à DOI seul, [174] à [176].

Tableau 12 — Régimes de preuve des 189 pièces déposées sur arXiv, aux reprises du 15 août, du 29 octobre et du 1er novembre 2026, d'après les notices de l'API du dépôt. Les parts portent sur ce corpus et sur ce que la notice déclare, non sur le champ.

Régime	15 août 2026	Part	29 octobre 2026	Part	1er novembre 2026	Part
Publication attestée en notice (`journal_ref` ou DOI)	12	6 %	16	8 %	16	8 %
Acceptation auto-déclarée (champ de commentaire)	32	17 %	34	18 %	34	18 %
Aucun signe de revue par les pairs	145	77 %	139	74 %	139	74 %
Total	189	100 %	189	100 %	189	100 %

Rien n'a bougé dans les notices. Aucune notice n'a été révisée depuis le 29 octobre : la révision la plus récente du corpus reste la v3 de [118], du 18 octobre 2026. Les versions courantes sont celles de la bibliographie, augmentées des quatorze révisions que relevait l'annexe du 29 octobre et d'aucune autre. Les seize attestations portent les mêmes champs — [11] et [116] au champ `journal_ref` et par DOI, [67] et [70] par DOI seul —, et les trente-quatre annonces le même texte, celles de [119] (« Accepted to EC 2026 ») et de [164] (« EMNLP 2026 Main Accepted ») comprises. Le partage refait notice par notice retrouve les comptes du 29 octobre pièce pour pièce : 16, 34 et 139 (12). La stabilité des textes est celle du 29 octobre : 99 pièces sur 189 en sont à leur version initiale, 137 ont été révisées pour la dernière fois en 2026, et la répartition des dépôts initiaux par année n'a pas changé. Les sept résumés du tableau 10 portent toujours ce que ce tableau en rapporte — 1 348 cas de test pour [67], « standard static benchmarks often significantly overestimate defense efficacy » sans les chiffres de la v2 pour [71], 5,2 à 6,6 % de coût de débit pour [127], jusqu'à 17,5 points et 2,49 fois plus rapide pour [160] —, et aucune autre notice n'a changé de version depuis

le 29 octobre. Faute de relevé brut de cette date, les autres résumés n'ont pas été recomparés mot à mot : une retouche de résumé sans version nouvelle échapperait à ce contrôle.

Le partage ne se fait pas seul. Un tri automatique du champ de commentaire ne retrouve pas d'emblée les trente-quatre annonces. Il manque les quatre notices qui ne portent qu'un nom de conférence — [69] « ACL 2026 », [97] « ICLR 2026 », [109] « ICLR 2025; 27 pages, 8 figures », [162] « MLSys 2026 » —, et il compte à tort [58], dont le commentaire dit « The concentration, survival and targeting-coverage findings are unchanged ». La correction suit la règle du 15 août, qui compte la forme nue d'un nom de conférence (3.1); [134] (« Under review at ACM TOSEM ») et [163] (« submitted to OOPSLA 2026 ») restent hors du compte. L'écart est rapporté parce que le partage tient à ce jugement de lecture, non à l'outil qui le prépare.

Un champ changé avant le 29 octobre, que l'annexe de ce jour ne relevait pas. La bibliographie donne [160] à deux auteurs, Yuzhen Mao et Azalia Mirhoseini, comme sa v1 du 9 juin 2026; sa v3 du 4 octobre en porte six, quatre noms s'insérant entre les deux premiers [194]. La vérification de forme du 29 octobre portait sur les titres, les dates et les versions, non sur les auteurs. Confrontées aux premiers auteurs que la bibliographie nomme, les 188 autres notices concordent. Le régime de [160] n'en change pas; sa ligne de bibliographie, elle, ne décrit plus que la v1.

Ce que la comparaison ne peut pas établir. L'état du 29 octobre n'est conservé que par l'annexe qui le décrit : aucun relevé brut n'est versé au dépôt. La comparaison porte donc sur ce que la bibliographie et l'annexe énoncent — titres, premiers auteurs, dates, versions, attestations, extraits de commentaire des pièces comptées. Une édition de commentaire qui n'introduirait ni lieu ni acceptation passerait inaperçue; une qui en introduirait un se verrait, et il n'y en a aucune. Trois jours sans mouvement ne mesurent pas une vitesse : ils établissent seulement que les énoncés de l'annexe du 29 octobre, et le tableau 8 tel qu'elle le recomptait, valent encore au 1er novembre au critère de la notice. La section suivante sort de ce critère.

La passe de contrôle refaite

L'annexe du 29 octobre n'avait pas refait la passe de contrôle; celle du 15 août l'avait conduite sur quatre fronts et sur un échantillon de sept pièces sans signe, dont quatre se révélaient publiées (17). Elle est refaite ici sur l'ensemble des 173 pièces sans attestation en notice — 139 sans signe, 34 auto-déclarées —, et sur Crossref seul [195] : une requête par titre, puis, pour les 136 pièces restées sans résultat, une seconde par titre et premier auteur. DBLP n'a pas pu être interrogé : ses trois adresses renvoient à un client scripté une page de vérification anti-robot au lieu de la réponse [196], et ce contrôle n'a pas été contourné. Le critère est strict : titre normalisé identique ou quasi identique, à un mot près au plus ([9], [19], [107]), et auteurs communs, vérifiés sur la liste entière. Les copies déposées sur des serveurs de prépublication sont écartées — SSRN pour [77], [91], [139] et [146], Preprints.org pour [153], Research Square pour [159] —, car elles ne valent pas publication. Chaque DOI retenu a été relu à sa notice Crossref et résolu jusqu'au site de l'éditeur [197].

Trente-six pièces passent le critère (14) : vingt-deux des 139 sans signe, quatorze des 34 auto-déclarées. Comme celles de [92], [102], [107] et [124] le 15 août, ces trouvailles ne changent pas le régime en notice; elles se comptent à part (13).

Tableau 13 — Les 189 pièces déposées sur arXiv selon le régime en notice (règle 2.2) et la passe de contrôle sur Crossref du 1er novembre 2026. La passe se compte à part : elle ne modifie pas le régime en notice.

Régime en notice et résultat de la passe	Pièces	Part
Publication attestée en notice (`journal_ref` ou DOI)	16	8,5 %
Acceptation auto-déclarée, publication établie sur Crossref	14	7,4 %
Aucun signe en notice, publication établie sur Crossref	22	11,6 %
Acceptation auto-déclarée, aucune publication trouvée	20	10,6 %

Régime en notice et résultat de la passe	Pièces	Part
Aucun signe en notice, aucune publication trouvée	117	61,9 %
Total	189	100 %

Tableau 14 — Les trente-six pièces sans attestation en notice dont Crossref établit au 1er novembre 2026 une publication en actes ou en revue (titre identique ou quasi identique, auteurs communs), par numéro de référence. Date : publication selon Crossref.

Réf. (front)	En notice	Publication établie (Crossref)	DOI	Date
[5] (socle)	aucun signe	ACM Transactions on Software Engineering and Methodology, vol. 35, n° 10, p. 1-37	10.1145/3796519	16 sept. 2026 (en ligne)
[6] (socle)	aucun signe	ACM Transactions on Software Engineering and Methodology	10.1145/3814959	12 mai 2026
[7] (socle)	auto-déclarée	Actes d'IEEE DSN 2026, p. 379-392	10.1109/dsn69566.2026.00046	22 juin 2026
[9] (socle)	aucun signe	Actes des ateliers d'ACSAC 2025 (IEEE), p. 332-340; titre augmenté de « Google's »	10.1109/acsacw69556.2025.00043	3 déc. 2025
[12] (socle)	aucun signe	Actes d'AIxDKE 2026 (IEEE), p. 98-101	10.1109/aixdke67294.2026.00024	2 févr. 2026
[17] (socle)	aucun signe	Actes d'IEEE ICAIC 2026, p. 1-9	10.1109/icaic67076.2026.11365757	13 févr. 2026
[18] (socle)	aucun signe	Actes du 63e congrès annuel de l'ACL (2025), vol. 1, p. 8580-8622	10.18653/v1/2025.acl-long.421	2025
[19] (socle)	auto-déclarée	Findings of the ACL: ACL 2026, p. 26690-26714; titre précédé de « A »	10.18653/v1/2026.findings-acl.1330	2026
[20] (socle)	aucun signe	AI Open (Elsevier), vol. 7, p. 71-95	10.1016/j.aiopen.2026.02.006	2026
[26] (socle)	aucun signe	CCIS (Springer), AI Agent for Information Retrieval, p. 69-89	10.1007/978-3-032-11477-1_7	15 juill. 2026 (en ligne)
[31] (socle)	aucun signe	LNBIP (Springer), Business Process Management Forum, p. 107-123	10.1007/978-3-031-41623-1_7	1er sept. 2023 (en ligne)
[32] (socle)	auto-déclarée	LNBIP, volume des forums de BPM (Responsible BPM Forum), p. 29-43	10.1007/978-3-032-02936-3_3	30 août 2025
[33] (socle)	auto-déclarée	LNBIP, Business Process Management Workshops, p. 3-14	10.1007/978-3-032-13426-1_1	1er avril 2026 (en ligne)
[34] (socle)	aucun signe	Information Systems (Elsevier), vol. 140, art. 102738	10.1016/j.is.2026.102738	août 2026
[35] (socle)	aucun signe	Advances in Neural Information Processing Systems 37 (NeurIPS 2024), p. 52040-52094	10.52202/079017-1650	2024
[39] (socle)	aucun signe	LNBIP, Process Mining Workshops, p. 610-623	10.1007/978-3-031-82225-4_45	28 mars 2025 (en ligne)
[48] (socle)	aucun signe	Advances in Neural Information Processing Systems 38 (NeurIPS 2025), p. 135676-135729	10.52202/085713-4082	2025
[53] (protocoles)	aucun signe	ACM Transactions on Software Engineering and Methodology	10.1145/3858625	15 oct. 2026
[66] (sécurité)	auto-déclarée	Actes d'IEEE S&P 2026, p. 138-155	10.1109/sp63933.2026.00154	18 mai 2026

Réf. (front)	En notice	Publication établie (Crossref)	DOI	Date
[69] (sécurité)	auto-déclarée	Actes du 64e congrès annuel de l'ACL (2026), vol. 1, p. 10049-10066	10.18653/v1/2026.acl-long.457	2026
[89] (multi-agents)	auto-déclarée	Actes du 64e congrès annuel de l'ACL (2026), vol. 1, p. 19888-19905	10.18653/v1/2026.acl-long.912	2026
[92] (multi-agents)	aucun signe	Actes du 62e congrès annuel de l'ACL (2024), vol. 1, p. 6106-6131	10.18653/v1/2024.acl-long.331	2024
[102] (évaluation)	aucun signe	Advances in Neural Information Processing Systems 38 (NeurIPS 2025), p. 10291-10321	10.52202/085713-0315	2025
[107] (évaluation)	aucun signe	Advances in Neural Information Processing Systems 38 (NeurIPS 2025), p. 184435-184475; « in Building » pour « for Building »	10.52202/085713-5547	2025
[108] (évaluation)	aucun signe	Actes d'ICSE-SEIP 2026 (ACM), p. 395-405	10.1145/3786583.3786882	12 avril 2026
[112] (évaluation)	auto-déclarée	Actes d'IEEE eScience 2025, p. 467-473	10.1109/escience65000.2025.00093	15 sept. 2025
[124] (transactionnel)	aucun signe	Actes de l'ACM Web Conference 2026, p. 8697-8700	10.1145/3774904.3792943	12 avril 2026
[130] (processus)	auto-déclarée	LNCS (Springer), Business Process Management, p. 755-772	10.1007/978-3-032-37777-7_44	27 sept. 2026
[133] (processus)	auto-déclarée	LNCS, Software Engineering and Advanced Applications, p. 367-382	10.1007/978-3-032-04190-8_22	8 sept. 2025
[135] (processus)	auto-déclarée	LNBIP, volume des forums de BPM (Process Technology Forum), p. 146-162	10.1007/978-3-032-36710-2_10	27 sept. 2026
[141] (gouvernance)	auto-déclarée	Actes de la conférence AAAI/ACM AI, Ethics, and Society, vol. 8, n° 3, p. 2189-2198	10.1609/aies.v8i3.36705	15 oct. 2025
[147] (gouvernance)	aucun signe	Actes d'ACM FAccT 2026, p. 7916-7935	10.1145/3805689.3812224	25 juin 2026
[151] (Web agentique)	aucun signe	Actes d'ACM IMC 2025, p. 541-557	10.1145/3730567.3764471	28 oct. 2025
[164] (chorégraphie)	auto-déclarée	Actes d'EMNLP 2026, p. 44639-44657	10.18653/2026.emnlp-main.1960	2026; notice créée le 29 oct. 2026
[171] (chorégraphie)	aucun signe	Actes d'ACM CAIS 2026, p. 181-196	10.1145/3786335.3813159	26 mai 2026
[172] (chorégraphie)	auto-déclarée	Actes d'IEEE IS 2026, p. 1-6	10.1109/is71416.2026.11372778	sept. 2026

Le plafond, chiffré. La revue tenait 145 pour un plafond du non-arbitré sur la foi d'un échantillon (17). La passe exhaustive le chiffre : 22 des 139 pièces sans signe au 1er novembre, soit 16 %, sont publiées en actes ou en revue sans que leur notice le dise, dont les quatre déjà nommées, qui ne le déclarent toujours pas. Dix-huit sont neuves pour la revue, et treize d'entre elles viennent du socle hérité, repris en bloc (2.1). Lue avec Crossref, la part des pièces sans signe ni publication trouvée tombe de 74 à 62 %; celle des pièces publiées, en notice ou hors notice, monte de 8 à 28 %. Ce second chiffre reste un plancher. La revue notait que Crossref n'indexe ni PMLR ni OpenReview (17), et aucune des six annonces d'ICLR ou d'ICML — [63], [96], [97], [99], [103], [109] — n'y est trouvée, pas plus que [73] à USENIX Security 2026, [119] à EC 2026 ou [162] à MLSys 2026. Une recherche par titre manque en outre ce qui paraît sous un autre titre (cas de [150], plus bas). Les actes de NeurIPS, eux, y sont : [35], [48], [102] et [107].

Les annonces vérifiées. Quatorze des trente-quatre acceptations auto-déclarées sont confirmées par une notice que l'éditeur a déposée à Crossref, aux actes ou dans la série qu'annonce leur commentaire; aucune n'est démentie par une publication ailleurs, sinon le cas ambigu de [156]. Les vingt autres ne sont pas trouvées, ce qui n'établit pas qu'elles soient fausses. La distinction de la section 3.1 tient : aucune annonce n'est démentie, vingt restent invérifiées, et c'est la vérification, non la déclaration, qui fait la différence.

Ce que cela change aux énoncés de la revue. Des quatre fronts que l'annexe du 29 octobre laissait sans pièce attestée, trois reçoivent des pièces publiées par cette voie : les systèmes multi-agents avec [89] (ACL 2026), à côté de [92]; l'évaluation avec [108] (ICSE-SEIP 2026) et [112] (eScience 2025), à côté de [102] et [107]; la chorégraphie et l'essaim avec [164] (EMNLP 2026), [171] (CAIS 2026) et [172] (IEEE IS 2026). L'identité et la délégation restent sans publication trouvée, en notice comme hors notice. L'énoncé liminaire de la section 13, « Aucune de ses seize pièces n'est publiée en comité de lecture », était vrai des notices; elle ne l'était déjà plus du champ au 15 août, puisque [171] avait paru aux actes de CAIS le 26 mai 2026 [198], et [172] et [164] l'ont rejointe depuis — la notice Crossref de la seconde a été créée le 29 octobre à 16 h 16 UTC [199], le jour même de la reprise précédente, qui n'interrogeait pas Crossref. Des six résultats que l'annexe du corpus arbitré disait sans appui attesté, celui selon lequel le score publié n'est pas ce qui s'observe, que [102] et [107] appuyaient déjà hors notice, s'appuie aussi sur [108], publiée, qui mesure la part de mémorisation dans la performance sur SWE-bench Verified [200]; celui selon lequel la coordination sans chef échange une surface d'attaque contre une autre reçoit son premier appui publié avec [164]. Le plafond du moniteur à automate fini, que la section 13.2 applique au moniteur de [171], repose lui aussi désormais sur une pièce publiée, [172] [201]. Le résultat le plus décisif du front de la sécurité, que les scores de défense ne survivent pas à l'adversaire adaptatif [71], n'a toujours aucune version publiée trouvée, pas plus que celui du front de l'identité. Quant à [107], dont la bibliographie notait que « le recoupement lui-même décroche » à DBLP, Crossref la porte aux actes de NeurIPS 2025 sous un titre qui diffère d'un mot, dans une notice créée le 6 août 2026 [202].

L'écart était lisible au gel. Trente et une des trente-six notices Crossref existaient avant le 15 août 2026 : l'écart mesuré ici tient pour l'essentiel à l'échantillon de la passe d'origine, non au mouvement du champ. Cinq ont été créées depuis — [130] et [135] le 26 septembre, [53] le 15 octobre, [172] le 21 octobre, [164] le 29 octobre —, aucune après le 29 octobre. [5] avait sa notice dès le 16 février 2026, mais l'article n'a paru en ligne que le 16 septembre.

Cas ambigus, non retenus. [150] : les quatre mêmes auteurs publient aux LNCS en 2026 « VOIX: A Web-Native Interface for Agents » (`10.1007/978-3-032-29372-5_15`), titre sans rapport avec celui de la notice (« Building the Web for Agents: A Declarative Framework for Agent-Web Interaction »), dont le commentaire renvoie pourtant à la documentation de VOIX; le critère de titre n'est pas satisfait. [152] : les trois mêmes auteurs signent aux actes d'IMC 2026 « Poster: FP-Agent: Towards Fingerprinting AI Browsing Agents » (`10.1145/3777912.3847600`), deux pages publiées comme affiche, sous un titre qui n'est pas celui de la notice (« FP-Agent: Fingerprinting AI Browsing Agents »). [156] : titre et cinq auteurs identiques dans *SuperIntelligence - Robotics - Safety & Alignment* (Carlson Research LLC, 25 juillet 2025, `10.70777/si.v2i3.15295`), lieu autre que l'atelier SoLaR de NeurIPS 2024 que déclare la notice, et dont Crossref n'établit pas le régime d'arbitrage.

Ce que cette passe n'a pas fait. DBLP n'a pas répondu et OpenAlex n'a pas été interrogé; les pages d'éditeur n'ont été lues qu'à travers la résolution du DOI; les trois pièces à DOI seul ne sont pas rouvertes. Aucune pièce n'est versée au corpus, dont le corps reste gelé au 15 août 2026; les trouvailles de cette passe ne modifient ni le tableau 1 ni le régime que la bibliographie attache à chaque entrée.

La passe de novembre sur les cinq premiers fronts

L'annexe du 29 octobre laissait le corpus avec « soixante-quinze jours de retard sur le dépôt ». Une passe neuve a été conduite le 1er novembre 2026 sur les cinq premiers fronts, à la méthode de la section 2.1 : dépôts sur arXiv du 14 août 2026, 0 h, au 31 octobre 2026, 23 h 59, au champ `submittedDate` de l'API d'exportation; trente-six requêtes, de six à dix par front, sur les termes propres à chacun, cinq d'entre elles restreintes aux catégories cs.CR, cs.SE, cs.NI, cs.DC ou cs.MA, les autres ouvertes à toutes; trois secondes au moins entre deux appels. Elles rendent 2 525 notices distinctes dans la fenêtre, toutes lues au titre, 84 au résumé; aucune n'appartient au corpus, dont les 189 identifiants arXiv ont été exclus. Vingt pièces sont retenues, quatre par front, au critère de la conséquence — la mesure produite, non la citation ni le titre —, et rattachées chacune au front où leur mesure porte; chaque notice a été rouverte le même jour à l'API, par identifiant, et son résumé lu. Elles ne sont pas versées au corpus, dont le corps reste gelé au 15 août 2026 : ce qui suit les présente comme passe de novembre, au régime que déclare leur notice (2.2), et dit ce qu'elles changent aux énoncés de la revue — lacune comblée ou resserrée, désaccord départagé, énoncé contredit ou confirmé —, en séparant ce qui est mesuré de ce qui est avancé. Le tableau 15 les récapitule.

Un régime plus sévère que celui du corpus. Sur vingt pièces, une seule porte une attestation de publication à sa notice, par DOI d'actes [203]; une annonce une acceptation au seul champ de commentaire [204]; dix-huit ne présentent aucun signe de revue par les pairs. Dix-neuf en sont à leur version initiale, cinq sont d'un auteur unique. Le régime n'a pas été un critère de rétention, conformément à la section 2.1 : il est rapporté, non choisi.

Les protocoles d'interopérabilité

La lacune des deux protocoles est entamée, en laboratoire. La section 4.3 tenait pour vérifiable qu'aucune publication ne rapporte un taux d'échec, une latence ou une perte sémantique pour une tâche traversant deux protocoles dans un système déployé, toutes les mesures d'écosystème portant sur MCP seul. Deux pièces de la fenêtre franchissent la première moitié de l'énoncé sans atteindre la seconde. L'une compare NLIP et A2A sur trois environnements matériels, en décomposant la latence en création du message, connexion et envoi : en coordination légère, NLIP est de 8,4 à 9,6 fois plus rapide que l'implémentation de référence du SDK A2A sur deux environnements, environ 4 fois sur le troisième; sur la chaîne de bout en bout, où l'inférence domine, les deux protocoles sont « near parity », l'écart venant « almost entirely from connection setup », et un SDK A2A à connexions en cache rejoint NLIP sur le matériel le plus rapide [205]. L'autre fait traverser à un même hôte une jambe MCP et une jambe A2A locales, sous notation déterministe et sans juge modèle : 480 essais, dix scénarios, quatre modèles; l'étiquette « PUBLIC - OK TO SHARE » s'associe à davantage de fuite verbatim, nettement pour un modèle (+0,800 en moyenne, dix scénarios sur dix), faiblement ou pas du tout pour les trois autres, et l'auteur la donne pour « an association in one configuration, not a causal or general effect » [206]. La première mesure une latence entre deux protocoles, non une tâche qui les traverse; la seconde mesure une tâche qui les traverse, mais une fuite de données, non un échec, une latence ou une perte sémantique. Aucune ne porte sur un système déployé, et la notice de [205] ne dit pas si ses auteurs sont étrangers à l'un des protocoles comparés : l'arbitrage du tableau 7 — la même tâche, deux protocoles, un tiers — n'est rempli que sur ses deux premiers termes. Le résultat rejoint celui de [177] : l'écart mesuré tient à l'implémentation de la connexion plus qu'au protocole.

Le désaccord sur la prévalence se déplace vers l'instrument. La section 4.2 opposait des prévalences alarmantes à un travail montrant les scanners faux à plus de moitié [51], et relevait deux vices : l'audit d'un registre à un instant unique, et le chiffre hérité. Un recensement du registre public complet — 21 643 serveurs, 72 606 enregistrements de version, instantané d'août 2026, code source de 14 353 serveurs — mesure la précision de son propre scanner contre 414 constats étiquetés à la main et corrige chaque classe d'alerte de cette précision : la prévalence observée de gravité haute, 11,14 %, se ramène à environ 7,6 % [207]. Son constat central est l'instabilité : 51,1 % des serveurs à plusieurs versions changent d'une version à l'autre

ce qu'ils annoncent, 40,6 % en silence, et 4,2 % redirigent leur point d'accès distant vers un autre hôte en gardant leur identité de registre, changement que le protocole ne signale jamais aux clients installés; la dérive silencieuse s'associe à une cote presque triple de constat grave (rapport de cotes de 2,96, IC à 95 % : 2,56-3,42). Un tirage probabiliste de 400 serveurs npm/stdio, à graine publiée, dans un recensement de 24 135, mesure à son tour ce que l'échantillonnage fait aux chiffres : 48,8 % seulement achèvent la poignée de main d'initialisation, contre 66,7 % sur un cadre trié à la main sondé au même instrument; parmi les 195 qui tournent, aucune violation fatale de schéma JSON sur 2 766 outils annoncés, mais 58,8 % d'omission des annotations de sécurité facultatives contre 41,5 % sur le cadre trié — « curation flatters this figure too » [208]. Ni l'une ni l'autre ne reproduit [51] ou [66]. Elles appliquent ce que [51] exigeait — valider l'instrument, déclarer le cadre d'échantillonnage —, et leurs chiffres vont dans le sens de l'artefact plutôt que de la sévérité; la première joint de plus l'audit de sécurité à l'historique des versions, ce que la monoculture relevée par [58] ne faisait pas. La seconde rejoint [59] par une autre voie : le cadre d'échantillonnage fabrique une part du résultat, dans un sens ou dans l'autre. La lacune longitudinale pour A2A, ACP et ANP reste entière : aucun des quinze titres que rend la requête sur A2A n'en annonce. Les quatre pièces du front sont sans signe de revue, trois d'un auteur unique.

La sécurité des agents et de leurs protocoles

La critique de l'instrument passe d'une campagne à la littérature. La revue tenait la lacune de second rang pour comblée — un audit de campagne [178], un cadre qui sépare taux rapporté et violation vérifiée [184] — et laissait ouverte leur réplication. Une méta-analyse en texte intégral de 259 pièces de sécurité agentique déposées sur arXiv de février 2025 à septembre 2026 mesure le défaut à l'échelle du champ : la plupart ne rapportent ni estimation de variance ni exécutions répétées pour leur métrique d'attaque principale — 58 % (IC à 95 % : 44-71) sur un échantillon aléatoire de 50 codé à la main, 65,3 % au codage automatique des 259 —; 30,9 % seulement en disent assez du décodage pour établir si l'évaluation était stochastique; des 64 qui emploient un juge modèle, 29,7 % rapportent un contrôle d'accord avec des étiquettes humaines [209]. Le volet analytique chiffre la conséquence : sur un banc de 100 instances, la plus petite différence de taux de succès d'attaque détectable à puissance conventionnelle est de 18,2 points, et deux défenses dont les taux vrais diffèrent de 5 points sont mal ordonnées par une évaluation à exécution unique environ une fois sur cinq. La conclusion — « cross-paper ASR comparison is currently unsupported » — porte sur une population dont la période de dépôt couvre celle de toutes les pièces de ce front, sans que la notice dise lesquelles elle code. Ce n'est pas la réplication qui manquait à [178] et [184]; c'est le dénominateur qui leur manquait. Le second désaccord de la section 5.2 n'est plus seulement instruit pièce à pièce : la comparaison des taux d'une pièce à l'autre y est déclarée sans fondement, et les pourcentages du front, ceux de ce fragment compris, se lisent sous cette réserve.

L'adaptatif confirme, sur le banc d'AgentDyn. Le troisième acquis de la section 5.1 — les scores obtenus en statique ne survivent pas à l'adaptatif — reposait sur [71], dont la version courante n'énonce plus au résumé les chiffres que citait la revue (annexe du 29 octobre). Un attaquant entraîné par renforcement sur un curriculum de cibles de plus en plus robustes atteint sur AgentDyn [72] un taux de succès ASR@10 de 93,8 % et de 45,0 % contre deux modèles de pointe, quand les méthodes par renforcement de l'état de l'art, RL-Hammer et PISmith, y obtiennent 0 % dans le même cadre; l'attaquant se transfère à six autres modèles qu'il n'a jamais visés [210]. Le zéro était une propriété de l'attaquant, non de la cible : c'est la forme exacte de l'acquis. La pièce porte toutefois sur la robustesse native de modèles, non sur une défense ajoutée; elle ne met pas [74] sous attaque adaptative, ce qu'exige l'arbitrage du premier désaccord (tableau 7), qui reste ouvert.

Un parc mesuré dont les positifs sont confirmés. Sur 21 097 serveurs MCP de neuf registres, 787 des 4 806 serveurs triés (16,4 %) exposent des capacités de système de fichiers malgré une classification fonctionnelle qui n'en annonce pas; une validation dynamique en trois cas confirme 150 instances vulnérables sous

les politiques de bac à sable testées, et la divulgation coordonnée a produit 13 avis de sécurité, dont deux CVE dans le serveur Git MCP d'Anthropic [211]. La cause posée est celle de [66] et de [54] : dans les déploiements locaux typiques, l'approbation côté client d'un appel d'outil accorde au processus serveur des droits étendus sur le système de fichiers de l'hôte au lieu de le borner à l'opération déclarée. Le chiffre se lit à deux étages — une part au tri statique, un compte confirmé par exécution —, ce qui répond au grief de [51] contre les prévalences de scanner non validées; et les avis de sécurité rattachent la mesure à des corrections chez les mainteneurs, comme [65] le faisait pour des assistants déployés.

Une télémétrie d'attaquants réels, pas un parc. La section 5.3 relevait que rien ne se comptait en organisations, en déploiements ni en incidents observés, sans aucune télémétrie de production. Un pot de miel de faible et moyenne interaction, qui émule l'API d'Ollama sans modèle derrière, a tourné 84 jours sur quatre déploiements en nuage et en réseau universitaire et enregistré 290 887 interactions de 2 793 adresses source distinctes; l'essentiel est découverte, prise d'empreinte et énumération de modèles, mais des tentatives concrètes d'exploitation y figurent, dont l'injection d'invite, l'extraction d'information et l'« agent-oriented tool use » [212]. C'est la seule mesure de la passe prise sur des attaquants réels et sur une durée réelle. Ce n'est pas un parc d'entreprise, la cible est une infrastructure d'inférence exposée et non un agent en service, et l'absence de modèle interdit tout taux d'aboutissement : la question de la section 16 — quelle fraction des agents en service subit une tentative d'injection, à quel taux d'aboutissement — reste sans réponse, et le résumé ne chiffre pas la part des tentatives d'injection. La lacune inter-organisationnelle est inchangée. Les quatre pièces sont sans signe de revue; le front garde ses deux pièces attestées du 29 octobre, [67] et [70], et son résultat décisif reste sans appui attesté.

L'identité, la délégation et la révocation

Le mauvais primitif, désormais mesuré. La première convergence de la section 6.1 — le jeton porteur relayé tel quel est le mauvais primitif — reposait sur des propositions et des preuves, non par une mesure qui compare les primitifs. Un banc à rejeu apparié soumet la même requête du modèle, échantillonnée une fois — même action, même ressource, mêmes arguments —, à quatre régimes : porteur étendu, JWT à portée de tâche, jeton lié à l'émetteur (« sender-constrained ») et Open Policy Agent. Sur 128 scénarios, quatre domaines d'outils et cinq configurations de modèles locaux, l'exécution nuisible sous porteur étendu va de 8,9 % à 37,8 % des décisions attaquées valides; les trois régimes à portée enregistrent zéro [213]. « The policy changes execution, not the frozen model decision » : l'auteur borne lui-même la portée au confinement des conséquences testées, sous une autorité de tâche fournie par le chercheur, et non à la prévention de l'injection. La convergence passe d'une position à une mesure — à un saut, sur modèles locaux, d'un auteur unique, sans réplication.

Révoquer n'est pas avoir révoqué. Les trois voies du tableau 3 bornent la fenêtre pendant laquelle un agent révoqué agit encore, à supposer que la révocation atteigne le vérificateur. Une pièce mesure ce qui sépare la révocation signalée de la révocation appliquée, sur une infrastructure réelle : un contrat de résultat en six états, de la validation chez l'émetteur à la prévention de l'effet, éprouvé avec le serveur d'identité Keycloak 26.7, deux récepteurs durables, huit passerelles physiques agent-outil, des effets sur système de fichiers et sur PostgreSQL et 16 hôtes AWS répartis sur trois zones de disponibilité. Livraison normale et reprise ne valident aucun effet; sous non-livraison sélective provoquée côté récepteur, l'accusé de transport et la persistance chez le récepteur réussissent, mais 112 appels sur 225 (49,78 %) sont admis et les 112 effets validés dans chaque bloc de traitement. Un agent MCPMark non modifié, sur 60 bras de tâche, voit refusés ses 31 appels postérieurs à la barrière en régime normal, quand le régime sélectif en admet 344 et valide 145 effets [214]. « Transport success is therefore evidence of progress, not a revocation-completion verdict. » La pièce ne tranche pas l'arbitrage de type CAP de la section 6.2; elle en déplace l'objet, de la fenêtre pendant laquelle un agent révoqué peut agir vers la preuve que chaque passerelle qui a mis l'autorité en cache a cessé de l'admettre — objet qu'aucune pièce du tableau 3 ne mesure.

La lacune de la compensation se resserre de moitié. La section 6.3 relevait qu'aucune pièce ne dit ce qu'il advient des effets et des sous-délégations déjà émis quand un saut amont est invalidé. Une pièce de la fenêtre en traite la part qui n'a pas encore produit d'effet. Les agents de longue durée survivent à leur processus initiateur par des justificatifs, des tâches déléguées, des files, des rappels, des réservations et des opérations côté fournisseur, que ni l'annulation, ni la fin du processus, ni la révocation du justificatif ne ferment toutes; la quiescence d'autorisation à portée de racine linéarise une coupure, clôt l'expansion de l'ancienne racine et les puits protégés, et préserve le travail partagé qu'une autorité indépendante suffit à couvrir. Sous les hypothèses posées, six propriétés sont prouvées, dont la non-expansion de l'émetteur après la coupure et la stabilité aux pannes et au rejeu [215]. Sur une suite de 17 effets tardifs, deux exécutions par annulation seule et une par coupure seule acceptent l'effet déjà programmé, quand les deux exécutions par coupure et clôture, la reprise et le processus périmé le rejettent; un vérificateur implémenté à part valide les 17 traces et rejette les 44 régressions sémantiques qui lui sont soumises. Les auteurs bornent eux-mêmes le résultat : « not global idleness, rollback, or business completion ». Les sous-délégations et effets émis mais non encore acceptés ont donc une sémantique prouvée; les effets déjà produits n'en ont toujours aucune, et le critère qui déciderait quels effets aval sont annulables manque encore. La pièce [214] dénombre précisément cet objet résiduel : des effets validés après une révocation tenue pour acquise.

La moitié informationnelle, constatée hors banc. [186] définissait sur son propre banc la non-résurrection d'un enregistrement rétracté. Cinq systèmes de mémoire d'agent à révocation douce — le fait contredit marqué invalide et conservé plutôt que supprimé —, chargés d'une politique révoquée et de sa remplaçante, sur neuf scénarios, neuf modèles et six conditions de défense : aucun n'applique la révocation par défaut, « the revoked fact is returned wherever the revocation label is visible to the retrieval layer, outranks its replacement, and leads agents to the unsafe action » [216]. Le résumé ne nomme pas les cinq systèmes. L'énoncé de la section 6.3 tient — gouverner les faits ne dit rien du chaînage des conséquences —; ce qui change est que le défaut que [186] corrige est désormais constaté sur des logiciels existants. Les deux désaccords de la section 6.2 restent entiers, et la part de parcs à racine d'attestation, critère d'arbitrage du tableau 7, n'est mesurée nulle part. Aucune des quatre pièces ne mesure une chaîne de plus d'un saut en exploitation (15.1). Toutes sont sans signe de revue : le front reste sans pièce attestée.

Les systèmes multi-agents : orchestration et défaillance

Le non-avantage, préenregistré, quand l'agent sert un usager. Sur τ^2-bench, banc à double contrôle où l'agent converse avec un usager sous une politique écrite, une étude préenregistrée, à journal de modifications public, compare l'agent unique standard du banc à un système multi-agents centralisé bâti sur le même modèle, pour six modèles de trois familles, sur les domaines aérien, commerce de détail et télécommunications, soit environ 7 950 conversations simulées, avec un registre de jetons par épisode et par système. Sous un usager simulé fixe, aucune cellule ne montre d'avantage : le multi-agents est inférieur dans 12 des 13 cellules valides et à égalité dans la treizième, le gain ajusté est négatif sur toute la plage de capacité observée (moyenne pondérée de −28 points, IC à 95 % : −44 à −12), et sur les deux cellules où la règle de saturation de capacité qu'elle met à l'épreuve prédit un gain, il perd de 13 et de 22 points; sans plafond de budget, il rejoint au mieux l'agent unique à 5,5 fois sa dépense de jetons, sans réduire de façon détectable les écritures erronées en base [217]. La pièce sort du partage du tableau 4 : architecture construite par ses auteurs, elle conclut au non-avantage. Mais elle déclare une barre de validité non atteinte — « its planner never saw the tool schemas » —, qui handicape le bras multi-agents sur l'axe même où [93] situe le désaccord, l'effort consenti à chaque bras. Le réglage égalisé, critère d'arbitrage du tableau 7, n'est donc pas rempli.

Le chiffre d'attribution, propriété du banc : le mécanisme. La section 7.1 concluait que, sur ce front, le chiffre d'attribution est d'abord une propriété du banc. Quatre épreuves, conçues pour distinguer le juge qui confronte l'étape fautive au reste de l'exécution de celui qui suit des indices de surface, en donnent le

mécanisme : sur trois bancs, des prédicteurs simples égalent ou dépassent GPT-4.1; dans deux systèmes de Who&When Pro, un classifieur qui lit le raisonnement d'une seule étape retrouve 95 à 100 % des étapes fautives; dans l'un d'eux, l'injection d'erreur ne laisse aucun raisonnement après l'étape fautive, et des juges affinés sur ses étiquettes battent GPT-4.1 de 41 points, puis en perdent de 31 à 99 quand on rajoute du raisonnement après cette étape, contre 9 au plus pour des juges sans affinage; sur Aegis, accuser tous les agents égale GPT-4.1 en micro-F1, tout en lui cédant 19 points en exactitude d'ensemble [218]. Le plafond de 53,5 % et 14,2 % de [88] n'est pas remesuré, et la notice ne rattache pas son Aegis à l'Aegis-Bench de [187]; mais une part des scores d'attribution publiés peut provenir de la construction du banc plutôt que de la vérification, et c'est la forme que la revue prêtait au problème sans en avoir le mécanisme.

Trois topologies comparées sous faute, sur cinq domaines. La section 7.3 relevait l'absence de toute comparaison contrôlée des patrons d'orchestration sur plusieurs domaines. Une étude de plus de 29 000 exécutions — 100 tâches, cinq domaines, trois topologies de flux, trois configurations de modèles —, avec injection de fautes de communication et traçage, trouve que l'organisation à plat garde 53,0 % de réussite sous faute, contre 3,3 % pour la séquentielle et 3,2 % pour la hiérarchique, l'avantage tenant à l'existence d'un chemin d'information de rechange qui préserve la preuve dont l'aval a besoin; 20,7 % des défaillances à détection complète surviennent sans signal immédiat, 76,2 % pour les fautes à contenu partiel [219]. La lacune se resserre sans se fermer : les topologies comparées ne sont pas les patrons que nommait la revue — superviseur, transfert, graphe, marché —, la variable est la résilience à une faute injectée et non la performance nominale, et le résumé ne dit pas si le budget est figé. Une défaillance sur cinq sans signal immédiat est une donnée pour le second désaccord de la section 7.2, sur ce que résout la traçabilité, sans le trancher.

Un assemblage en production, en quatre pages. La première lacune de la section 7.3 — aucun assemblage mesuré en exploitation d'entreprise, sur durée et volume réels — reçoit une pièce de trois phrases : un système multi-agents fondé sur des modèles de langue gère de façon autonome les pannes de millions de liens optiques dans des centres de données d'IA en production, affiné par apprentissage supervisé et par évolution continue de sa mémoire, et atteint 97,7 % de F1 et plus de 60 % de réduction des incidents de panne, en dépassant des modèles de pointe, « on a ten-week field data evaluation » [220]. C'est le premier assemblage de la passe évalué sur des données de terrain d'une durée nommée. Le résumé ne donne ni le taux de défaillance de l'assemblage lui-même, ni le volume de ses décisions, ni la nature de la comparaison, et ne dit pas si la réduction d'incidents est observée en exploitation ou estimée sur les données de terrain. La lacune se resserre en forme, non en substance. Les quatre pièces sont sans signe de revue : le front reste sans pièce attestée.

L'évaluation, les bancs d'essai et l'observabilité

La cinquième voie, reprise sur vingt-deux bancs. La décomposition de variance qui fondait la voie « la plus radicale » de la section 8.1 était d'un auteur unique, sur trois bancs [190]. Un cadre bayésien de décomposition de variance pour classements clairsemés et déséquilibrés, appliqué à 22 bancs du Holistic Agent Leaderboard et du Harbor Index, sépare le signal utile à l'énoncé visé du bruit qui peut encore changer un classement : les systèmes modèle-échafaudage figés se classent de façon fiable (0,935 à 0,994), les modèles sous-jacents beaucoup moins (0,148 à 0,841); l'effet de l'échafaudage varie fortement d'une évaluation à l'autre; une infinité de tâches de même facture n'améliore la fiabilité du classement des modèles que de 0,097 au plus quand l'incertitude tient à la couverture d'échafaudages; mettre en commun des bancs divers porte la fiabilité projetée de 0,44 à 0,75 à budget de tâches égal [221]. Ni mêmes bancs que [190] — la notice ne dit pas s'ils recouvrent ses trois —, ni même estimateur : ce n'est pas une réplication. C'est une seconde mesure, par une équipe distincte, de la même conclusion qualitative — un classement d'agents ne dit pas ce qu'il prétend dire du modèle —, et elle la précise : ce qu'un classement ordonne de façon fiable, c'est le montage, ce qui rejoint [181] et [177].

Le juge : un plafond empirique, mesuré par des tiers aux juges. Le litige dur de la section 8.2 opposait un juge agentique quasi humain, mesuré par ses propres auteurs sur leur banc [110], à un plafond théorique [109]; le tableau 7 en remettait l'arbitrage à « un juge indépendant, étiquettes humaines ». Un banc de 3 808 instances, sur six topologies de graphes de flux et trois niveaux de difficulté, évalue six juges, de 20 milliards de paramètres à la frontière, sur les appels d'outils de cinq générateurs, avec et sans vérité de référence : l'alignement se dégrade de façon monotone avec la difficulté, 1,5 fois plus vite sans vérité de référence, et sur les requêtes difficiles sans vérité de référence les six juges convergent dans une bande de 77 à 82 % quelle que soit leur taille, « a structural ceiling driven primarily by task difficulty », dont la hauteur dépend en partie de l'invite pour les générateurs faibles; les rubriques structurées gagnent jusqu'à 6,5 points sans se généraliser, la chaîne de pensée et la température n'ont qu'un effet négligeable; une étude de validation humaine désigne le juge le plus proche de l'humain [204]. Le résumé ne fait état d'aucun juge proposé par les auteurs, et le banc porte des références programmatiques et une validation humaine : il a la forme d'arbitrage que demandait le tableau 7, sur un autre objet que [110] — l'appel d'outil sur graphe de flux, non les étapes intermédiaires de son banc de 55 tâches —, et il penche du côté du plafond sans réfuter [110], dont le banc n'est pas repris. Acceptation à la conférence principale d'EMNLP 2026 annoncée au seul champ de commentaire.

Imputer une faute à partir des rapports : la lacune se resserre. La section 8.3 constatait l'absence de tout banc dont le critère serait qu'un tiers reconstruise, à partir de la trace, qui a mandaté quoi, et impute la responsabilité. Une pièce préenregistrée en fait l'épreuve sur l'imputation d'une faute : chaîne de six agents cloisonnée par institution, frontières d'information au niveau des processus, injection équilibrée de défauts et jumeaux sains appariés — 345 600 requêtes par modèle de chaîne, deux modèles [222]. L'hypothèse préenregistrée n'est pas soutenue, mais la couche de responsabilité échoue de façon asymétrique. Elle n'accuse presque jamais d'elle-même — aucune allégation sur 7 996 épisodes sains où tous les agents se taisaient — et filtre mal l'erreur amont, nommant un innocent dans 34,4 % et 62,6 % des épisodes sains où un agent avait donné une fausse alerte; quand aucun agent ne propose la vraie origine (59,5 % des épisodes sur l'un des modèles), un auditeur qui lit les rapports la retrouve dans 4,1 % des cas, sous le tirage uniforme (20 %), contre 60,3 % à partir de la documentation brute des mêmes épisodes. Retirer le seul champ qui porte la conclusion des agents fait monter l'exactitude à 45,2 % (+41,2 points) et coûte à l'inverse là où la suggestion était juste, de 70,5 % à 55,7 %; l'effet se reproduit sur deux auditeurs de pointe et dans un second domaine. « An accountability layer needs evidence sufficiently independent of the conclusions it verifies. » Le banc existe donc pour l'imputation de l'origine d'une faute, non pour la reconstruction d'un mandat. Il précise aussi, sur son objet, le second désaccord de la section 8.2 : la lecture a posteriori vaut ce que vaut l'indépendance de la preuve à l'égard des conclusions qu'elle transporte. Auteur unique, prépublication.

La liaison, chiffrée — et attestée. La section 15.3 concluait que le déficit d'observabilité est de liaison, non de vocabulaire. Une étude rejoue hors ligne, dans le moniteur MonPoly non modifié, les trajectoires que livrent AgentDojo, STAC et R-Judge, sous cinq obligations génériques en logique temporelle métrique du premier ordre : elles signalent 71,8 % des chaînes d'attaque de STAC et 70,1 % des attaques réussies d'AgentDojo, mais se déclenchent aussi sur 29,3 % des exécutions bénignes [203]. L'imprécision tient aux corpus, non à la logique : ils enregistrent rarement les approbations et jamais d'horodatage, si bien que les obligations qui dépendent de l'historique se réduisent à détecter des types d'action risqués. Là où la trace porte un contexte relationnel, les politiques sensibles à la provenance discriminent mieux; mais ce contexte est attaquable — une seule ligne plantée défait une vérification naïve de provenance sur 94 à 99 % des exécutions qu'elle aurait signalées —, et lier la provenance à la consultation qui l'a produite ferme cette évasion sans coût en détection ni en déclenchement bénin. C'est l'énoncé de la section 15.3 sous forme mesurée, sur ce banc : une provenance que rien ne lie à son origine laisse la trace attaquable, et la liaison la referme. C'est aussi un constat sur les bancs eux-mêmes, qui prolonge la section 8.3 : les traces qu'ils

livrent ne portent pas l'historique qu'exigerait une obligation de mandat. La pièce est la seule de la passe attestée en notice, par le DOI 10.1145/3847353.3847499, que Crossref donne, au 1er novembre 2026, pour un article des actes du 8e atelier conjoint CPS&IoT Security and Privacy, tenu avec CCS 2026, pages 129 à 142, publication en ligne datée du 14 novembre 2026. Le front de l'évaluation, que l'annexe du 29 octobre donnait sans pièce attestée au corpus, en reçoit une à la passe de novembre — hors corpus, puisqu'elle n'y est pas versée.

Tableau 15 — Pièces retenues à la passe de novembre sur les cinq premiers fronts (dépôts sur arXiv du 14 août au 31 octobre 2026), avec la mesure qui motive leur rétention et le régime que déclare leur notice au 1er novembre 2026 selon la règle de la section 2.2. Aucune n'est versée au corpus.

Front	Pièce	Mesure	Régime
Protocoles	[207] recensement du registre MCP	21 643 serveurs, 72 606 versions; prévalence grave corrigée de la précision mesurée du scanner (414 constats) : 11,14 % ramenés à environ 7,6 %; changement silencieux d'annonce chez 40,6 % des serveurs à plusieurs versions	aucun signe
Protocoles	[208] tirage probabiliste du registre	400 serveurs à graine publiée : 48,8 % achèvent l'initialisation, contre 66,7 % sur un cadre trié	aucun signe
Protocoles	[205] NLIP et A2A	latence décomposée sur trois environnements : 8,4 à 9,6 fois en coordination légère, quasi-parité de bout en bout	aucun signe
Protocoles	[206] configuration MCP vers A2A	480 essais à notation déterministe : fuite verbatim selon l'étiquette, une seule configuration	aucun signe
Sécurité	[209] validité du taux de succès d'attaque	259 pièces : 58 % (échantillon codé) à 65,3 % sans variance ni répétition; écart minimal détectable de 18,2 points sur 100 instances	aucun signe
Sécurité	[210] attaque adaptative par curriculum	AgentDyn : 93,8 % et 45,0 % contre 0 % pour deux méthodes de l'état de l'art	aucun signe
Sécurité	[211] blanchiment de capacités de fichiers	21 097 serveurs; 16,4 % des 4 806 triés; 150 instances confirmées par exécution; 13 avis, dont deux CVE	aucun signe
Sécurité	[212] pot de miel d'API d'inférence	84 jours, quatre déploiements, 290 887 interactions de 2 793 adresses	aucun signe
Identité	[213] porteur contre portée	128 scénarios, cinq configurations : 8,9 à 37,8 % d'exécution nuisible sous porteur étendu, zéro sous les trois régimes à portée	aucun signe
Identité	[214] révocation aux passerelles	Keycloak 26.7, huit passerelles, 16 hôtes AWS : 112 appels sur 225 admis, et leurs effets validés, après une révocation accusée et persistée	aucun signe
Identité	[215] quiescence à portée de racine	six propriétés prouvées; 17 effets tardifs; 44 régressions sur 44 rejetées	aucun signe
Identité	[216] révocation en mémoire d'agent	cinq systèmes, neuf modèles, neuf scénarios : aucune révocation appliquée par défaut	aucun signe
Multi-agents	[217] double contrôle	préenregistrée, environ 7 950 conversations : inférieur dans 12 cellules sur 13, −28 points en moyenne pondérée	aucun signe
Multi-agents	[218] audit de l'attribution de défaillance	des prédicteurs simples égalent GPT-4.1 sur trois bancs; 95 à 100 % des étapes fautives retrouvées par indice	aucun signe
Multi-agents	[219] fautes de communication	plus de 29 000 exécutions, cinq domaines, trois topologies : 53,0 % de réussite à plat contre 3,3 % et 3,2 %	aucun signe
Multi-agents	[220] liens optiques en production	dix semaines de données de terrain : F1 de 97,7 %, plus de 60 % d'incidents en moins	aucun signe
Évaluation	[221] fiabilité des classements	22 bancs : systèmes figés 0,935 à 0,994, modèles sous-jacents 0,148 à 0,841	aucun signe
Évaluation	[204] juges d'appels d'outils	3 808 instances, six juges : bande de 77 à 82 % sur les requêtes difficiles sans vérité de référence	acceptation auto-déclarée (EMNLP 2026)

Front	Pièce	Mesure	Régime
Évaluation	[222] imputation à partir des rapports	345 600 requêtes par modèle : 4,1 % d'origines retrouvées depuis les rapports, 60,3 % depuis la documentation brute	aucun signe
Évaluation	[203] surveillance temporelle des traces	71,8 % et 70,1 % des attaques signalées, 29,3 % de déclenchements bénins; évasion de 94 à 99 % fermée par liaison de la provenance	attestée en notice (DOI)

Ce que cette passe n'a pas fait. Elle s'en tient aux résumés et aux métadonnées des notices : aucun corps de pièce n'a été lu, aucune expérience refaite, aucun artefact exécuté. Quatre requêtes larges ont été tronquées aux 300 premières notices par pertinence. L'API ne rend aucun dépôt postérieur au 29 octobre 2026, 17 h 47 UTC : les deux derniers jours de la fenêtre ne sont pas couverts, et l'on ne peut dire s'ils sont vides ou pas encore indexés. La passe de contrôle sur DBLP, Crossref et OpenAlex n'a pas été refaite, hors la seule vérification du DOI de [203] à Crossref. La rétention est d'un seul jugement, comme celle de la passe d'origine (2.3), et le régime n'en a pas été un critère : 63 des 2 525 notices vues portent un `journal_ref` ou un DOI au relevé automatique, champ non qualifié, et une seule des pièces retenues est de celles-là. Les cinq autres fronts ne relèvent pas de ce fragment.

La passe de novembre sur les cinq derniers fronts

Méthode et fenêtre. La méthode est celle de la passe d'origine (2.1) : dépôts arXiv du 14 août au 31 octobre 2026 au champ `submittedDate` de l'API d'exportation, soixante-deux requêtes — de onze à quatorze par front, termes au résumé croisés au besoin de catégories (cs.GT, q-fin et econ au front transactionnel, cs.CY à la gouvernance) —, trois secondes entre requêtes, journal des requêtes et de leurs comptes tenu avec les notes de travail. Elles rendent 3 673 résultats au compte de l'API ; 1 414 notices distinctes ont été rapatriées et lues au titre, aucune déjà au corpus, et 79 résumés lus. Cinq requêtes n'ont rendu que leurs 200 premiers résultats, ou 50 pour une requête de comptage ; trois ont été resserrées, la racinisation de l'API élargissant certains termes. La fenêtre est plus courte qu'annoncé : au 1er novembre, l'API ne sert aucun dépôt cs.AI daté des 30 et 31 octobre, et la dernière notice rapatriée est du 29 octobre. Vingt pièces sont retenues, quatre par front, au critère de la mesure produite, et leurs notices, rouvertes à l'API par identifiant le 1er novembre, lues une à une (16). Aucune n'est versée au corpus, dont le corps reste gelé au 15 août 2026 : la passe dit ce que ces pièces changent aux énoncés des sections 9 à 13, non ce que serait la revue si elle les avait lues.

Régimes. Le régime des vingt se lit d'un trait. Aucune n'est attestée en notice ; trois annoncent une acceptation au seul champ de commentaire — une conférence, ICML 2026, et deux ateliers AgenticOS, à SOSP et à NeurIPS 2026 ; dix-sept ne portent aucun signe de revue, dont deux qui renvoient à un dépôt Zenodo et une à SSRN, qui ne comptent pas plus que le Zenodo de [86] ; six sont d'un auteur unique, quatre ont déjà été révisées. Le corpus arbitré des cinq fronts n'en reçoit donc aucune pièce. Comme à la section 2.3, les chiffres rapportés sont ceux des résumés, rien n'a été refait, et ce qui est mesuré est distingué de ce qui est avancé.

Tableau 16 — Les vingt pièces de la passe de novembre aux fronts six à dix, déposées du 14 août au 29 octobre 2026, avec la mesure que porte leur résumé et leur régime selon la règle 2.2, d'après les notices de l'API du dépôt consultées le 1er novembre 2026. Aucune n'est versée au corpus.

Front	Pièce	Mesure portée au résumé	Régime
Couche transactionnelle	Analyse formelle de x402, MPP, ACP et AP2 [223]	Tamarin : 86 cas de vérification, 40 écarts non documentés, dix validés sur implémentation	Aucun signe
Couche transactionnelle	Attaques par description de produit contre AP2 [224]	Réussite de 90 %, 56 % et 73,3 % ; dix-sept modèles ; 1 544 scénarios	Aucun signe

Front	Pièce	Mesure portée au résumé	Régime
Couche transactionnelle	Collusion entre modèles hétérogènes [225]	Marché de Bertrand à quatre firmes : 11 compositions, 20 exécutions, 200 périodes (simulation)	Aucun signe ; auteur unique
Couche transactionnelle	Préparation des marchands au commerce agentique [226]	555 sites et 330 marchands réels ; pilote dont les mesures ne sont pas validées	Aucun signe
Processus d'affaires	Budget d'irréversibilité [227]	Étude contrôlée : dépassements jusqu'à 48 fois la limite de risque sous portes par effet	Acceptation auto-déclarée (atelier)
Processus d'affaires	FinalityBench [228]	321 tâches, 14 445 épisodes notés par l'effet monétaire ; porte de finalité à 85,4 %	Aucun signe ; auteur unique
Processus d'affaires	Janus, sagas à preuve avant effet [229]	Injection de pannes ; flux de prêt à modèle réel : six prêts hors mandat payés sans garde, aucun avec	Aucun signe ; auteur unique
Processus d'affaires	Automates tirés de traces d'agents [230]	Douze jeux de données publics ; fitness d'au moins 0,997 ; AUROC jusqu'à 0,94	Aucun signe
Gouvernance	Directives d'assouplissement de la supervision [231]	1,53 million de paquets d'instructions ; un sur dix-sept en porte ; scanners à 46 % au plus	Aucun signe
Gouvernance	Le droit de l'arrêt [232]	1 213 incidents codés par deux modèles de langue ; quarante instruments relevés	Aucun signe ; auteur unique
Gouvernance	Le paradoxe de la supervision réduite [233]	Audit de 63 artefacts publics	Aucun signe
Gouvernance	Allégations vérifiables sur les agents [234]	Preuve sous modèle explicite ; six allégations courantes instruites	Aucun signe
Web agentique et horizon	Lisibilité du site par l'agent [235]	37 927 parcours, 1 056 entreprises réelles, quatre harnais	Aucun signe
Web agentique et horizon	Récupérabilité et force du vérificateur [236]	Juge constant dans 9 réglages sur 37 ; 17 % d'issues modifiées par un changement en service	Acceptation auto-déclarée (atelier)
Web agentique et horizon	Succession d'autorisation sous auto-modification [237]	Preuves sous hypothèses ; 64 rejeux sur 64 ; 28 mutants rejetés sur 28	Aucun signe
Web agentique et horizon	Bancs empoisonnés et agents auto-modifiants [238]	Preuves de concept sur trois agents	Aucun signe
Chorégraphie et essaim	Défaillances corrélées des moniteurs d'approbation [239]	Douze moniteurs, deux protocoles préenregistrés ; 0,9 % contre 7,4 % de paiements corrects bloqués	Aucun signe ; auteur unique
Chorégraphie et essaim	Évaluer la pile, non la couche [240]	1 119 actions étiquetées ; φ médian de +0,430 entre juges	Aucun signe ; auteur unique
Chorégraphie et essaim	La taxe d'interaction [241]	Onze tâches à budgets égaux	Acceptation auto-déclarée (ICML 2026)
Chorégraphie et essaim	Influence adverse et taille du groupe [242]	Défection linéaire en la proportion de trompeurs	Aucun signe

La couche transactionnelle : paiements, marchés, réputation

Le mandat signé, toujours pas le point de rupture. Deux pièces reprennent le premier acquis de la section 9.1 par deux voies que le front n'avait pas. La première est une mesure d'attaque : sur AP2, un texte ordinaire de description de produit conduit l'agent d'achat à former un panier qui passe tous les contrôles du protocole sans plus répondre à la demande de l'utilisateur ; avec les modèles Gemini Flash-Lite que désignent par défaut les agents d'exemple d'AP2, trois attaques réussissent à 90 %, 56 % et 73,3 %, et la même vulnérabilité se retrouve sur dix-sept modèles de Google, trois cadres d'agents sans lien entre eux et l'assistant grand public de Google [224]. La défense que proposent les auteurs, A-VIP, traite l'intention signée comme une capacité au lieu de juger la description du marchand : elle bloque sans faux positif

les deux attaques qui laissent une trace structurelle et ne peut que soumettre la troisième à confirmation, faute de trace. La seconde est une preuve : x402, MPP, ACP et AP2 sont modélisés dans Tamarin sous une abstraction commune du cycle de paiement ; sur 86 cas de vérification, 46 reproduisent des constats connus ou d'étalonnage et 40 sont des écarts de cohérence formelle non documentés, consolidés en dix-huit principes de sécurité communs ; dix constats représentatifs sont validés par preuves de concept sur implémentation, témoins de SDK ou de schéma et traces exécutables [223]. Les deux concluent dans les termes de [116] et [117] : la signature scelle la transaction, non la décision, et l'autorisation déléguée doit rester cohérente avec ses effets économiques et de service d'un acteur, d'un état et d'une étape à l'autre. La convergence que la section 9.1 tenait pour la seule du front gagne une troisième voix, formelle ; elle reste sans mesure en exploitation.

La fracture des bibliographies, réduite d'un côté. La seconde lacune de la section 9.3 tenait à des piles qui s'ignorent : [115] sans AP2 ni ACP, les pièces AP2 sans x402. [223] est la première pièce lue qui pose quatre de ces piles sous une même abstraction et en tire des principes partagés. Elle réduit la lacune pour la sécurité, non pour l'interopérabilité : un modèle commun de vérification n'est pas un vocabulaire de capacités partagé, que personne ne propose ni ne mesure encore. La première lacune — la responsabilité d'une transaction non autorisée — reçoit une mesure de bord, prise côté marchand et sur des sites réels [226] : chaque terme observé est rapporté à la classe d'admissibilité de la preuve qui pourrait le soutenir dans un litige ; chez quatre grands marchands évalués en entier, aucun mandat n'a pu être confirmé comme satisfait, chacun laissant indéterminé le total ou une condition de remboursement ; dans l'évaluation déclarée de 330 marchands, le total tout compris n'était décidable que chez 18. Les auteurs présentent un pilote qui établit que ces mesures peuvent être prises, non qu'elles sont valides. Le tableau 5 compterait ainsi une seconde pièce mesurée sur système déployé, la première côté marchand. Aucune ne mesure un taux de contestation, ni une transaction réelle à valeur réelle sur une pile de paiement agentique : les deux lacunes tiennent, la première un peu moins nue.

La collusion, propriété du modèle. Le litige de la section 9.2 opposait la collusion stable sous auto-optimisation [121] à l'artefact d'homogénéité [120], et le tableau 7 en remettait l'arbitrage à la population effective de modèles tarificateurs. Une pièce teste la variable qui manquait : quatre modèles de quatre fournisseurs, chacun à son palier le moins cher, fixent leurs prix dans un marché de Bertrand logit à quatre firmes, sans communication, dans toutes les compositions homogènes, deux à deux et entièrement mixtes [225]. Les marchés Claude et Gemini atteignent 72 à 79 % de la rente de monopole, les marchés DeepSeek 24 %, les marchés GPT aucune ; le mélange ne réduit pas la collusion par lui-même, seul le marché entièrement mixte étant significativement moins collusif que la moyenne des marchés homogènes ; et la stabilité dépend du participant le moins stable, deux firmes GPT suffisant à empêcher tout marché de converger. Les deux pôles du litige en sortent déplacés : l'hétérogénéité ne protège pas comme telle, l'homogénéité ne produit pas seule le phénomène, et c'est la composition qui décide. L'arbitre désigné n'est toujours pas mesuré — la pièce simule les compositions, elle ne dit pas lesquelles existent —, mais il sait désormais quoi compter : non le nombre de modèles en présence, mais lesquels. Régime : simulation d'un auteur unique, sans signe de revue. Le second litige, agents structurés contre langue libre sur un même marché, ne reçoit aucune pièce.

Les processus d'affaires et l'exécution durable

Atomicité contre réversibilité : un critère par classe d'effet. La section 10.2 tenait les deux régimes pour deux ontologies incompatibles, notait qu'aucune pièce ne les composait ni ne donnait de critère pour choisir selon la classe d'effet, et le tableau 7 remettait l'arbitrage à la part d'actions irréversibles en flux réel. Deux pièces fournissent le critère sans fournir l'arbitre. La première fait de l'irréversibilité une ressource : un environnement d'exécution de confiance tient, pour chaque mandant, un compte cumulé de la valeur à risque résiduelle à travers agents, flux et locataires, impute à chaque effet sa perte résiduelle et refuse l'effet marginal qui ferait dépasser le budget [227]. En étude contrôlée, des portes appliquées effet par effet laissent

passer au niveau du parc des dépassements allant jusqu'à 48 fois la limite de risque du locataire, alors que le budget maintient sous cette limite toute exécution correctement imputée ; la tarification prudente et sensible aux dépendances reste, de l'aveu des auteurs, le problème ouvert. La seconde est un banc où le processeur de paiement, le grand livre, l'ERP et le relevé bancaire se contredisent pendant des minutes et où certaines décisions — expédier, relancer une capture, rembourser — ne se défont pas [228] : sur 14 445 épisodes notés par l'effet monétaire exécuté, une politique qui ne laisse passer l'action irréversible qu'après une sonde de finalité faisant autorité atteint 85,4 % et ne perd rien à pass^5, quand la politique qui expédie au premier signe, deuxième à l'exactitude (65,7 %), est la pire en perte appariée ; les modèles de langue égalent le taux exact de la porte écrite à la main sur un sous-ensemble stratifié, perdent environ deux fois plus d'argent, et découvrent la porte de finalité sans qu'on la leur indique. Lues ensemble, et c'est une lecture de cette annexe, non une thèse des auteurs, les deux pièces composent les régimes par classe sans lever l'incompatibilité que la section 10.2 énonçait pour un même effet : la porte de l'atomicité [126], [127] est réservée aux effets que l'échelle de [129] range du côté irréversible, les autres passent. Le désaccord n'est pas départagé : l'une est une étude contrôlée, l'autre un banc synthétique d'auteur unique, et la part d'effets irréversibles dans un flux réel reste non mesurée.

La proposition, jamais un effet, sur un flux de crédit. Le second acquis de la section 10.1 — la fiabilité vient d'une couche transactionnelle en aval, la sortie du modèle n'étant qu'une proposition — reçoit une mesure à modèle réel [229]. Janus inscrit la proposition d'une étape, le verdict et toute réponse d'un validateur ou d'une personne dans un journal signé et chaîné par hachage avant que l'étape puisse s'exécuter ou son effet être libéré, et un auditeur re-dérive chaque verdict hors ligne avec une seule clé publique. Évalué sous injection de pannes (144 interruptions en processus, 81 par le démon) et par la vérification hors ligne d'un journal de cent millions d'événements (254,5 s), il est surtout confronté, sur un flux de prêt, à un modèle réel rejoué sur les mêmes sorties enregistrées : mandat de prêt dans l'invite, 0 contre 0 ; mandat dans la seule politique, le modèle approuve six prêts déclarés au-delà du mandat, dont trois sans injection, que l'agent sans garde paie tous et Janus aucun, chacun refusé par un validateur déterministe. La pièce rapporte aussi ce qui la dessert : face à un oracle qui approuve tout, Janus a payé quatre et trois prêts dont le montant déclaré sous-estimait la demande, et la conception de l'expérience a révélé, dans un système qui avait passé son propre audit, une substitution après approbation faisant passer l'approbation d'une personne de 100 à 1 000 000. C'est la troisième matière de la section 14.1 — la sortie du modèle prise pour un fait accompli — fermée à l'entrée du chemin d'effet. Régime : auteur unique, sans signe de revue.

Prescrit ou découvert : une mesure de conformité, contre son propre modèle. Le second désaccord de la section 10.2 opposait le modèle écrit d'avance à celui qu'on extrait des journaux. Une pièce mesure le second sur des traces d'agents : un corpus entier de traces est réduit à un automate fini unique et compact (7 à 43 états sur douze jeux de données publics), qui rejoue les traces tenues à l'écart avec une fitness d'au moins 0,997 et une topologie quasi identique d'une partition à l'autre ; des caractéristiques par état prédisent l'échec jusqu'à une AUROC de 0,94, et un moniteur en ligne classe les exécutions vouées à l'échec avant leur terme [230]. Les auteurs en tirent que la topologie comportementale tient davantage au harnais de déploiement qu'au modèle de langue. La pièce s'approche de la lacune de la section 10.3 par le côté de la découverte ; le contrôle refait plus bas dit jusqu'où. Aucune des quatre pièces ne mesure l'adoption d'un formalisme agentique par un moteur de production : le verdict de la section 15.2 n'est pas déplacé.

La gouvernance, le risque et la responsabilité

La supervision retirée en amont, mesurée sur parc. La section 11.1 posait que la supervision humaine n'est démontrée nulle part comme contrôle effectif. Une pièce mesure, sur 1,53 million de paquets d'instructions d'agents (*skills*) en anglais, la présence de directives qui l'assouplissent — procéder sans approbation, contourner les contrôles par `--no-verify`, continuer sans rendre compte [231]. Environ un paquet sur dix-sept, soit quelque 88 000, en contient une ; la plupart passent par des options de permission,

et 70,1 % s'appliquent sans condition plutôt que dans un contexte borné comme l'intégration continue. À quantité égale de langage de supervision, les paquets qui exécutent du code shell, installent des paquets ou usent de `sudo` ont 1,7 à 1,8 fois plus de chances d'en porter, sans compenser par des directives de resserrement ; l'assouplissement se propage par quelques sources amont, 2,4 % des familles qui en portent faisant la moitié des copies ; et les scanners libres en détectent au plus 46 %, à une précision inférieure à 0,4. La mesure ne porte pas sur l'efficacité d'une supervision exercée, mais sur son retrait inscrit dans la configuration, à l'échelle d'un écosystème. Elle confirme la section 11.1 et la déplace d'un cran : la supervision n'est pas seulement indémontrée, elle est retirée par défaut, et plus souvent dans les paquets aux actions les plus privilégiées. Elle confirme aussi, sur un second objet, ce que la section 14.2 disait des scanners [51].

Le droit qui mesure. La section 11.2 constatait que doctrine et mesure ne se citent pas et ne sont pas arbitrables entre elles ; la section 16, qu'aucun front ne compte ses échantillons en incidents observés. Une pièce de droit, révisée le 4 octobre, adjoint à l'exégèse deux relevés [232] : un codage d'environ 1 400 incidents de l'AI Incident Database, instantané de mai 2026, par deux modèles de langue de laboratoires différents sous protocole préétabli, qui ne trouve aucun arrêt dans environ 80 % des 1 213 retenus ; et un relevé de quarante instruments de gouvernance de l'IA jusqu'en septembre 2026, dont sept seulement portent une obligation d'arrêt contraignante. Là où un arrêt était possible mais absent, l'élément manquant est surtout juridique pour les préjudices informationnels, économiques et sociétaux, surtout technique pour les préjudices physiques et les systèmes agentiques. Ce partage par type de préjudice départage en partie le premier désaccord de la section 11.2 — obstacle technique [138] ou déficit institutionnel [139] — : pour les systèmes agentiques, la mesure penche du côté technique. La portée en est bornée par l'instrument, le codage étant fait par des modèles, dont la section 14.2 a dit ce que vaut le jugement automatique [109]. La pièce énonce aussi, sans le mesurer, que dans l'agentivité distribuée le contrôle est divisé et qu'un arrêt en un point peut laisser l'activité se poursuivre ailleurs : c'est la lacune connexe de la section 11.3, l'attribution à travers plusieurs entités, nommée encore, non traitée.

Ce que le journal doit contenir, et ce que les documents publics en montrent. La section 11.3 relevait que l'écart entre ce que le droit exige et ce que les protocoles expriment est nommé, jamais instrumenté, et que le cadre délictuel fait du journal le pivot probatoire sans dire ce qu'il doit contenir [140]. Deux pièces s'en approchent sans le combler. L'une part de l'article 12 du règlement européen, qui exige l'enregistrement automatique des événements sans dire quels enregistrements règlent une allégation donnée : une allégation sur un agent n'est vérifiable que si sa politique, sa portée, les enregistrements qui la trancheraient et qui les écrit sont fixés avant tout verdict ; trois conditions propres aux agents s'y ajoutent — couverture par un enregistrement indépendant, autorisation liée aux arguments de chaque action, complétude au-delà de l'intégrité —, dont la pièce prouve, sous un modèle explicite, que l'appui est impossible sans chacune là où ses hypothèses tiennent, puis instruit six allégations courantes en s'ancrant dans des brouillons du NIST, de l'IETF et de l'OWASP [234]. L'autre mesure la visibilité publique des mécanismes de reddition de comptes sur 63 artefacts — 46 articles de recherche, 17 sources d'ingénierie, de documentation, de sécurité et de gouvernance : la médiation des outils et les traces de surveillance y sont clairement visibles dans 40 et 37 artefacts, l'emplacement des points de contrôle dans 6, l'indépendance du validateur dans 4, la reprise dans 2, la contestabilité dans 1 [233]. La première dit ce qu'un enregistrement doit porter, en position appuyée d'une preuve ; la seconde instrumente l'écart, mais sur la documentation publique, non sur des schémas de messages, et ses auteurs bornent l'énoncé à la visibilité. Aucune ne confronte les champs d'un message de protocole aux articles 12, 14 et 26 : la lacune tient, et « dérive intraçable donc non-conformité » reste une hypothèse non testée.

Le Web agentique et l'horizon

Le site lisible par l'agent, mesuré du côté du bénéfice. La section 12.1 ne trouvait, pour le remède partout proposé — un canal servi par le site à l'intention des agents —, qu'une convergence de propositions

[149], [150]. Une pièce mesure ce que rapporte la lisibilité du site par l'agent : 37 927 parcours d'agents, chacun une question d'acheteur sur une entreprise, à travers quatre harnais indépendants et 1 056 entreprises réelles appariées sur la notoriété, la connaissance préalable des modèles et deux indicateurs d'optimisation pour moteurs de réponse, puis réparties selon leur niveau d'« expérience agent » [235]. Seuls 7 à 10 % de la réponse finale viennent de la connaissance d'entraînement ; les entreprises prêtes pour les agents voient leurs réponses construites à partir de leurs propres pages dans 78 % des cas contre 56 %, sont clairement recommandées 1,9 fois plus souvent, et une réponse fondée sur une entreprise non prête coûte à l'agent 64 % de plus ; à entreprise, harnais et question fixés, les réponses construites depuis le site sont plus exactes de 41 % en moyenne, et l'écart de recommandation tient dans les quatre harnais, dont les taux de base varient du simple au septuple. La pièce mesure la lisibilité du site, non un canal déclaratif au sens de [149] et [150], et son titre, « AX is the New AEO », est une thèse. Elle donne néanmoins au front un résultat là où il n'avait que des architectures.

L'identification coopérative, refusée côté serveur. Le point de bascule de la section 12.2 était que l'identification coopérative postulée par les architectures [149], [150] est démentie par l'observation des clients [151], [152]. La pièce du côté marchand retenue au front transactionnel prend la question par l'autre bout [226] : trois des quatre grands marchands évalués en entier refusent, à leurs pages d'offre, les profils déclarés — robot déclaré, navigateur sans tête déclaré —, et sur 555 sites de marchands que deux processeurs de paiement nomment publiquement comme clients, la page d'accueil est illisible pour les deux profils déclarés dans 105 cas (18,9 %). L'agent qui se déclare est refusé : l'incitation joue contre l'identification que les architectures supposent. C'est une lecture de cette annexe sur un pilote qui ne valide pas ses mesures ; la conformité d'agents non coopératifs, arbitre désigné au tableau 7, reste non mesurée.

Certifier au déploiement, et après. Le désaccord de la section 12.2 opposait l'autonomie décision de conception certifiable [155], [156] à l'autonomie propriété qui dérive [153], [154]. Une pièce mesure, sur une plateforme qui améliore ses propres agents — lecture des traces, dérivation d'un changement, approbation par un vérificateur automatique, mise en service sans auteur humain —, deux conditions de l'exécution sans surveillance [236] : la force du vérificateur, son accord avec un vérificateur de référence, et la récupérabilité, le coût de défaire un mauvais changement. Le juge automatique de la plateforme a rendu le même score quoi qu'on lui montre dans 9 réglages sur 37, sans signaler d'erreur ; restaurer une copie sauvegardée a rendu à l'agent son comportement d'origine, une annulation régénérée non ; et pendant qu'il était en service, un changement a modifié l'issue de 17 % des tâches au-delà de la variation normale, ce qu'aucune annulation ne répare. La règle qui en sort — exécution sans surveillance seulement si l'ancienne version est conservée et la force du vérificateur mesurée, d'où les modifications d'invite, d'outil et de compétence laissées libres et les mises à jour de poids soumises à signature humaine — est une proposition ; les défaillances sont des mesures. Elles donnent raison à [153] et [154] sur le fait : un certificat établi au déploiement ne survit pas au changement que le système s'applique. Elles ne donnent pas tort à [155] sur le principe, la décision d'autonomie redevenant, dans cette lecture, une décision prise changement par changement sous deux conditions mesurables. Régime : acceptation à un atelier annoncée au seul champ de commentaire.

Un invariant sous auto-modification, pour l'autorité sinon pour l'autonomie. La section 12.3 notait qu'aucune pièce ne définit de niveau d'autonomie invariant sous auto-modification. Une pièce définit et prouve un invariant voisin, celui de l'autorité : la succession d'autorisation conserve l'autorité à travers le remplacement, la duplication et le retour arrière d'agents qui réécrivent leur propre logiciel, là où une autorisation accordée successeur par successeur laisse des descendants dupliquer des quotas, cumuler des permissions ou survivre à la coupure d'un ancêtre [237]. Sous médiation complète, enregistrements authentifiés, abstraction d'effets saine, état durable monotone et comptabilité complète de lignée, les auteurs prouvent la sûreté de la succession, la conservation à la duplication, la fermeture de la révocation, la passation atomique, l'impossibilité de recréer de l'autorité au retour arrière et l'exclusion de l'auto-certification ;

l'évaluation exécutable rejoue 64 traces sur 64, un vérificateur indépendant rejette 28 mutants sémantiques sur 28, et deux adaptateurs externes reproduisent les 32 décisions autour de mutations mesurées d'OurArk et de la Darwin Gödel Machine. La moitié de la lacune qui porte sur ce que l'agent peut faire est comblée, formellement et pour les seuls effets protégés enregistrés ; celle qui porte sur ce qu'il décide sans humain ne l'est pas.

La compromission permanente, mesurée une seconde fois. La mesure non répliquée sur laquelle la section 12.2 appuyait que l'échafaudage est la surface où une compromission devient permanente [154] reçoit une seconde voie, d'une autre équipe et sur d'autres systèmes : des bancs empoisonnés fournis à l'auto-évaluation de trois agents de code auto-modifiants — la Darwin Gödel Machine modifiée par les auteurs, le Self-Improving Coding Agent et Hyperagents — conduisent leurs versions futures à écrire du code vulnérable sur des tâches propres tenues à l'écart ; avec Hyperagents sur Sonnet 4.5, l'agent se donne des instructions qui désactivent la validation des certificats HTTPS, et la contamination persiste souvent quand l'agent empoisonné est ensuite réévolué sur des bancs propres [238]. Ce sont des preuves de concept, non des taux : elles confirment la direction de [154], non son ampleur.

Le contrôle de la section 12.3, refait. Sur le titre ou le résumé, du 14 août au 29 octobre, 662 dépôts portent « self-evolving », « self-improving » ou « self-evolution », contre trente-cinq du 9 au 15 août : environ 8,6 par jour au lieu de 5,8, comparaison indicative, la formulation exacte de la requête d'origine n'étant pas publiée. Dix-huit d'entre eux emploient aussi « level of autonomy », « autonomy level », « human oversight » ou « certification » et ses dérivés ; aucun ne rapporte un niveau d'autonomie, « certificat » y désignant l'admission d'une mise à jour ou une garantie statistique d'amélioration, et la supervision humaine n'y paraissant qu'en vœu ou en mise en garde. La lacune se creuse toujours ; la succession d'autorisation montre par où elle peut se réduire, par l'invariant d'une enveloppe plutôt que par la mesure d'un niveau.

La chorégraphie et l'essaim

La redondance surcréditée, des agents aux portes. La section 13.1 établissait, sur un relais à deux agents, que deux instances d'un même modèle échouent ensemble et que le calcul usuel de fiabilité crédite la redondance là où elle n'existe pas [180]. Deux pièces portent la mesure de l'agent à la porte d'action, là où l'empilement de contrôles suppose que leurs erreurs se multiplient. Sur 1 119 actions d'agents étiquetées, issues de trois corpus et sans adversaire adaptatif, deux juges fondés sur des modèles de langue ne composent, sous la définition stricte de l'échec, qu'environ 1,2 à 1,4 couche à équivalent multiplicatif (φ médian de +0,430, six paires significatives sur six), quand une couche de règles déterministes et un juge en composent 1,86 à 2,09 (φ médian de +0,014, aucune paire significative sur quatre) ; un juge d'un troisième fournisseur tombe dans la bande des juges, et l'exactitude isolée d'une couche ne prédit pas ce qu'elle ajoute [240]. Sur l'approbation de paiements, douze petits moniteurs à poids ouverts mesurés sous deux protocoles préenregistrés montrent que toute tromperie fiable d'un moniteur, pour lui faire approuver une fraude, passe par une source de preuve et n'atteint que les lecteurs de cette source ; une règle qui compte les sources plutôt que les votes bloque 0,9 % des paiements corrects contre 7,4 % pour la meilleure règle de décompte, à sûreté égale ; mais le test du pire cas préenregistré échoue, une attaque laissant les approbateurs sur une seule source, si bien qu'aucune règle sur les douze moniteurs ne survit à toutes les attaques mesurées, et seul l'ajout d'un moteur de règles, qu'on ne peut persuader, rétablit la condition d'une règle à la fois sûre et vivante [239]. Les deux mesures, indépendantes, confirment [180] et en étendent la portée : la co-défaillance franchit le fournisseur, comme [180] l'avait trouvé, et passe aussi par l'entrée partagée ; dans les deux, ce qui décorrèle est la couche qui n'est pas un modèle. [240] rapporte en outre qu'un palier de juges a été servi par une version de modèle non demandée dans 50 lots sur 112, incident qui a renversé une règle d'analyse déclarée d'avance : sur un autre objet, c'est la commande que la section 11.1 disait appartenir au fournisseur et non au déployeur [191].

Compter les fautes autrement. La section 13.2 objectait au décompte des fautes tolérées qu'une borne en F suppose des défaillances comptables séparément, ce que la co-défaillance interdit [180]. La pièce sur les moniteurs de paiement remplace le compte par les systèmes sujets aux défaillances de l'informatique répartie — des listes d'ensembles de moniteurs susceptibles de tomber ensemble — et y définit la sûreté et la vivacité d'une règle de décision [239] : c'est l'instrument que l'objection appelait, et sa mesure confirme l'objection, puisque seule une composante non persuadable rend la condition atteignable. Une autre pièce mesure ce que la taille du groupe achète en délibération : le taux de défection — la part d'agents d'abord justes qui finissent sur une réponse fausse — croît linéairement avec la proportion de trompeurs, non avec le nombre d'agents ; les agents fondés sur des modèles de langue cèdent régulièrement même quand les trompeurs restent minoritaires, là où les humains d'études de conformité comparables ne cèdent qu'à une majorité ; et laisser les trompeurs se coordonner en privé peut les rendre moins efficaces [242]. Ajouter des agents n'est pas une défense, l'adversaire croissant avec le groupe. La mesure ne teste pas le protocole de [164] et ne départage pas la vérification centrale de [159] et la robustesse tenue du graphe ; elle confirme que la robustesse, là où elle existe, tient au protocole et non à la taille.

Le plafond de la délibération, par l'information échangée. La section 13.1 tenait que le plafond de l'essaim n'est pas topologique [166], [167], [168]. Une pièce en mesure un mécanisme sur onze tâches d'optimisation notées par vérificateur, à budgets égaux : des familles de modèles différentes trouvent des solutions structurellement différentes, mais dès que les agents lisent leurs sorties complètes, leurs propositions convergent en un tour et la diversité qui motivait l'emploi de plusieurs modèles s'efface ; la génération indépendante des propositions évite cet effondrement, et la critique n'aide que si la règle violée est facile à trouver et à corriger [241]. La performance dépend moins du nombre d'agents que de l'information qu'ils échangent : l'énoncé de la section 13.1 est confirmé, et le contrepoids de [169] — le plafond frappe la délibération, non la décomposition vérifiable — est compatible avec ce mécanisme. Régime : acceptation à ICML 2026 annoncée au seul champ de commentaire.

Ce qui reste non traité. Le désaccord dur de la section 13.2, sur le mot « chorégraphie », n'a pas reçu son arbitre — la même saga, à participants déterministes puis agents, sous injection de fautes. La requête sur « choreography » et ses dérivés rend douze dépôts dans la fenêtre : quatre relèvent de la théorie de la programmation chorégraphique, sans participant fondé sur un modèle de langue au résumé, le seul dépôt agentique emploie le mot au sens de la mise en scène d'une simulation, et les autres ne l'emploient pas au sens des systèmes répartis. La seule saga mesurée de la passe confine l'agent à la proposition [229] : elle illustre le premier membre de l'alternative sans le comparer au second. L'essaim réparti entre organisations distinctes n'est pas davantage mesuré : la requête dédiée rend quatre dépôts — un apprentissage fédéré de garde-fous sur bancs publics, un cadre, un protocole éprouvé sur un flux inter-organisationnel contrôlé, un vérificateur de preuves A2A évalué sur un dossier canonique et treize mutations —, dont aucun ne franchit une frontière organisationnelle réelle. Le coût d'exploitation sans orchestrateur, la conformité d'exécution sur traces déployées et l'imputation d'une défaillance restent sans pièce.

Le contrôle de la section 10.3

La requête « conformance checking » AND « LLM » de la section 10.3, refaite à l'API du dépôt le 1er novembre 2026 sur le résumé comme sur tous les champs, rend huit entrées, les mêmes qu'au 29 octobre : les sept du 15 août, la plus récente déposée le 8 juin 2026, et arXiv:2606.18425, déposée le 16 juin et entrée par sa v2 du 8 septembre. Aucune n'est déposée après le 15 août ni révisée après le 8 septembre, et le compte ne bouge pas quand « LLM » est élargi à ses variantes. Croisée avec « agent » plutôt qu'avec « LLM », la même expression rend quatre entrées, dont une seule de la fenêtre : un banc de production robotique multi-agents dont les contrôles de conformité vérifient l'exécution du banc, non la trace d'un agent contre un modèle de processus. Aucune entrée nouvelle ne confronte une trace d'agent autonome à un modèle de processus.

Hors de la requête, la passe trouve la pièce qui s'en approche le plus [230] : elle rejoue des traces d'agents tenues à l'écart contre un automate et en mesure la fitness, d'au moins 0,997 sur douze jeux de données publics. Mais l'automate y est découvert sur une partie du corpus de traces qu'il rejoue ensuite, la précision ne figure pas au résumé, et aucun modèle de référence — un processus métier prescrit — n'est en cause. C'est la fouille de [135] et [130] dotée d'une mesure de conformité contre son propre produit, non le contrôle de conformité au sens de la discipline. La lacune tient, et sa formulation se resserre : ce qui manque n'est plus toute mesure de fitness sur des traces d'agents, mais l'alignement de ces traces contre un modèle qu'elles n'ont pas produit.

Les trois énoncés de la veille au 1er novembre

L'annexe de novembre de la même veille — auto-citation déclarée — rouvre les faits que la revue lui laisse (17). Aucun verdict de la section 15 n'en est déplacé; deux s'en précisent.

Délégation (15.1). Le 30 octobre, draft-chen-oauth-agent-revocation, expiré la veille, est relancé en –01 : les trois modèles de révocation en cascade que la veille oppose sont de nouveau actifs, et aucun n'est adopté. Les pratiques d'identité de charge de travail du groupe WIMSE sont en dernier appel jusqu'au 13 novembre 2026, au statut informationnel; OAuth 2.1 passe en –17. Aucun de ces textes ne spécifie de chaîne à N sauts (veille, annexe de novembre, tableau 27). Du côté de la littérature, la passe de novembre mesure le mauvais primitif et prouve des sous-délégations non encore exécutées, mais aucune pièce ne mesure une chaîne de plus d'un saut en exploitation. « Normalisé » reste faux; le déficit reste d'adoption.

Orchestration (15.2). Le 29 octobre, AWS offre les workflows Step Functions comme outils d'agent par une passerelle MCP, après Camunda 8.10 : deux moteurs se publient désormais comme outils, et aucun protocole n'adopte de formalisme de processus (veille, annexe de novembre, tableau 29). Le mouvement vient encore de l'industrie, côté moteur, comme la section 15.2 l'avait prévu; les deux pièces de la passe qui portent un critère par classe d'effet ne mesurent pas l'adoption d'un formalisme agentique par un moteur.

Observabilité (15.3). Le registre GenAI d'OpenTelemetry compte les mêmes 85 attributs qu'au 29 octobre, tous en développement, sans attribut de mandat; les propositions d'identité et d'autorisation d'agent restent ouvertes. L'énoncé tient. La passe de novembre en donne une troisième route : le déficit de liaison que concluait la section 15.3 est désormais chiffré sur trois bancs, ce qui confirme que l'arbitrage porte sur l'émission et la liaison, non sur la nomenclature.

Errata

Quatre erreurs relevées le 1er novembre : une du corps, que la passe de contrôle met au jour, deux de l'annexe du 29 octobre, une introduite par la recomposition du 31 octobre (17). Le corps n'est pas réécrit; la dernière est corrigée par la recomposition de la présente édition.

Tableau 17 — Errata relevés le 1er novembre 2026. « Recomposition » : corrigé par la composition de cette édition; « annexe » : corrigé ici seulement.

No	Où	Erreur	Correction	Traitement
1	13, première phrase	« Aucune de ses seize pièces n'est publiée en comité de lecture »	vrai des notices seulement : [171] avait paru aux actes de CAIS le 26 mai 2026 (tableau 14); lire « aucune ne l'atteste en notice »	annexe
2	annexe du 29 octobre, tableau 11, ligne 2	la valeur du champ `journal_ref` y est imprimée « MSR ”26 », la faute même que l'erratum corrige	le champ porte `MSR '26`, apostrophe droite; la correction se lit « MSR ’26 »	annexe
3	annexe du 29 octobre, tableau 10, [160]	la révision v1 → v3 est rapportée par son seul résumé	la v3 du 4 octobre 2026 porte six auteurs, contre deux à la v1 que cite la bibliographie (Yuzhen Mao et Azalia Mirhoseini)	annexe

No	Où	Erreur	Correction	Traitement
4	tableau 8 et réf. [59] de l'édition recomposée le 31 octobre	« MSR "26 » : la chaîne de composition rendait en guillemet ouvrant l'apostrophe initiale d'une année élidée, défaisant l'erratum 2 du 29 octobre	« MSR '26 »; chaîne corrigée le 1er novembre	recomposition

Ce que cette actualisation n'a pas fait

La passe neuve porte sur arXiv seul et sur les résumés seuls : aucune pièce n'a été lue en texte intégral, aucune expérience refaite, et la rétention repose sur un seul jugement, comme en 2.3. Sa fenêtre est plus courte qu'annoncé : au 1er novembre, l'API d'exportation ne sert aucun dépôt postérieur au 29 octobre 2026 en fin de journée, si bien que les dépôts des 30 et 31 octobre ne sont ni vus ni exclus. Plusieurs requêtes larges ont été tronquées à leurs premiers résultats par pertinence. Les quarante pièces retenues ne sont pas versées au corpus et n'entrent dans aucun décompte des sections 3 à 16. Le corpus a donc deux jours de retard sur le dépôt, et quarante pièces lues au résumé d'avance sur son corps.

Références de l'actualisation

193. arXiv. « arXiv API : requêtes `id_list`, quatre lots de 50, 50, 50 et 39 identifiants, `max_results=50` ». Requêtes du 1er novembre 2026, 10 h 20 UTC. Consulté le 1er novembre 2026. http://export.arxiv.org/api/query
194. arXiv. « Decentralized Multi-Agent Systems with Shared Context », arXiv:2606.10662, pages de la v1 (9 juin 2026) et de la v3 (4 octobre 2026), auteurs et historique des versions. Consulté le 1er novembre 2026. https://arxiv.org/abs/2606.10662v3
195. Crossref. « REST API, `/works?query.bibliographic=` (173 requêtes par titre, 136 par titre et premier auteur) et `/works/` suivi du DOI ». Consulté le 1er novembre 2026. https://api.crossref.org/works
196. dblp. « Search API (`/search/publ/api`) », sur dblp.org, dblp.uni-trier.de et dblp.dagstuhl.de : page « Making sure you're not a bot! » au lieu de la réponse JSON. Consulté le 1er novembre 2026. https://dblp.org/search/publ/api
197. International DOI Foundation. « Résolveur doi.org », résolution des trente-neuf DOI retenus ou examinés (réponse HTTP 302 vers la page de l'éditeur). Consulté le 1er novembre 2026. https://doi.org/
198. Crossref. « TraceFix: Repairing Agent Coordination Protocols with TLA+ Counterexamples », actes de CAIS '26 (ACM), p. 181-196, publié le 26 mai 2026. Consulté le 1er novembre 2026. https://api.crossref.org/works/10.1145/3786335.3813159
199. Crossref. « Robust Multi-Agent LLMs under Byzantine Faults », *Proceedings of the 2026 Conference on Empirical Methods in Natural Language Processing*, p. 44639-44657, notice créée le 29 octobre 2026 à 16 h 16 UTC. Consulté le 1er novembre 2026. https://api.crossref.org/works/10.18653/2026.emnlp-main.1960
200. Crossref. « The SWE-Bench Illusion: When State-of-the-Art LLMs Remember Instead of Reason », actes d'ICSE-SEIP '26, p. 395-405. Consulté le 1er novembre 2026. https://api.crossref.org/works/10.1145/3786583.3786882
201. Crossref. « Why Formal Monitors Fail: Attack Distribution Entropy as a Coverage Bound for LTL-Based LLM Agent Safety », actes d'IEEE IS 2026, p. 1-6, notice créée le 21 octobre 2026. Consulté le 1er novembre 2026. https://api.crossref.org/works/10.1109/is71416.2026.11727278

202. Crossref. « Establishing Best Practices in Building Rigorous Agentic Benchmarks », *Advances in Neural Information Processing Systems 38*, p. 184435-184475, notice créée le 6 août 2026. Consulté le 1er novembre 2026. https://api.crossref.org/works/10.52202/085713-5547
203. Nikolaos Kekatos, Stylianos Basagiannis, Marinelio Chintri et al. « Formal Runtime Verification for Tool-Using LLM Agents: An Offline Same-Benchmark Study on AgentDojo and STAC ». arXiv:2610.09793v1, déposé le 7 octobre 2026 — publication attestée en notice, doi:10.1145/3847353.3847499 (actes du 8e atelier conjoint CPS&IoT Security and Privacy, CCS 2026, p. 129-142, d'après Crossref). Notice consultée le 1er novembre 2026. https://arxiv.org/abs/2610.09793
204. Abhigya Verma, Amit Kumar Saha, Seganrasan Subramanian et al. « AgentJudgeBench: A Multi-Difficulty Benchmark for Evaluating LLM Judges on Agentic Tool-Calling ». arXiv:2608.26623v1, déposé le 27 août 2026 — acceptation annoncée au seul champ Comments (« Accepted as a main conference paper at EMNLP 2026 »), non confirmée en notice. Notice consultée le 1er novembre 2026. https://arxiv.org/abs/2608.26623
205. Ranjan Sinha, Anindita Das, Ashika Anand Babu et al. « The Cost of a Hop: Benchmarking NLIP and A2A ». arXiv:2610.04053v1, déposé le 2 octobre 2026 — prépublication sans signe de revue par les pairs à la notice. Notice consultée le 1er novembre 2026. https://arxiv.org/abs/2610.04053
206. Arpan Kumar Mahapatra. « Public-Sharing Labels and Verbatim Field Egress in an MCP-to-A2A Agent Configuration: A Controlled Multi-Model Study ». arXiv:2609.01693v1, déposé le 1er septembre 2026 — prépublication sans signe de revue par les pairs à la notice. Notice consultée le 1er novembre 2026. https://arxiv.org/abs/2609.01693
207. Obada Kraishan. « Same Name, Different Server: A Security Census of Silent Drift in the Model Context Protocol Ecosystem ». arXiv:2609.14119v1, déposé le 12 septembre 2026 — prépublication sans signe de revue par les pairs à la notice. Notice consultée le 1er novembre 2026. https://arxiv.org/abs/2609.14119
208. Haseeb Mohammed Afsar. « What a Random Draw from the MCP Registry Contains, and What Tool-Use Benchmarks Contain Instead ». arXiv:2609.10962v1, déposé le 10 septembre 2026 — prépublication sans signe de revue par les pairs à la notice (archive Zenodo au champ Comments, sans arbitrage). Notice consultée le 1er novembre 2026. https://arxiv.org/abs/2609.10962
209. Chetan Pathade, Prathamesh Pawar et Shubham Patil. « Attack Success Rate Is Not a Number: On Measurement Validity in Agentic AI Security Evaluation ». arXiv:2609.25173v1, déposé le 21 septembre 2026 — prépublication sans signe de revue par les pairs à la notice. Notice consultée le 1er novembre 2026. https://arxiv.org/abs/2609.25173
210. Chenlong Yin, Xiaolong Jin, Wei Zou et al. « Climbing the Hill: Prompt Injection Red-Teaming Against Frontier Models with Curriculum Reinforcement Learning ». arXiv:2609.33628v2, déposé le 27 septembre 2026, v2 du 29 septembre 2026 — prépublication sans signe de revue par les pairs à la notice. Notice consultée le 1er novembre 2026. https://arxiv.org/abs/2609.33628
211. Zeqian Huang, Mingyue Tang, Aonan Guan et al. « My Credentials, Please: Detecting Filesystem Capability Laundering in MCP Servers at Scale ». arXiv:2610.22301v1, déposé le 15 octobre 2026 — prépublication sans signe de revue par les pairs à la notice. Notice consultée le 1er novembre 2026. https://arxiv.org/abs/2610.22301
212. Karina Elzer, Niklas Netterstrøm Johansen et Emmanouil Vasilomanolakis. « OllamaDrama: Designing and Deploying a Honeypot to Measure Attacks on Exposed LLM Infrastructure ». arXiv:2609.29757v1, déposé le 24 septembre 2026 — prépublication sans signe de revue par les pairs à la notice. Notice consultée le 1er novembre 2026. https://arxiv.org/abs/2609.29757

213. Tural Hagverdiyev. « Compromise Is Not Consequence: Evaluating Task-Scoped Authorization in LLM Agents with Paired Replay ». arXiv:2610.05840v1, déposé le 5 octobre 2026 — prépublication sans signe de revue par les pairs à la notice. Notice consultée le 1er novembre 2026. https://arxiv.org/abs/2610.05840
214. Lifei Liu, Haoran Yu et Danping Zhang. « Revocation Is Not Complete at Receipt: An Executable Outcome Contract for Distributed Agent-Tool Gateways ». arXiv:2610.15991v1, déposé le 11 octobre 2026 — prépublication sans signe de revue par les pairs à la notice. Notice consultée le 1er novembre 2026. https://arxiv.org/abs/2610.15991
215. Genliang Zhu et Chu Wang. « Authorization Revocation for Long-Running AI Agents: Root-Scoped Quiescence under Delegation and Asynchronous Execution ». arXiv:2609.21284v1, déposé le 18 septembre 2026 — prépublication sans signe de revue par les pairs à la notice. Notice consultée le 1er novembre 2026. https://arxiv.org/abs/2609.21284
216. Yi Ting Shen, Kentaroh Toyoda et Alex Leung. « Revoked but Still Authoritative: An Empirical Study of Revocation Enforcement in Agent-Memory Systems ». arXiv:2609.08258v1, déposé le 8 septembre 2026 — prépublication sans signe de revue par les pairs à la notice. Notice consultée le 1er novembre 2026. https://arxiv.org/abs/2609.08258
217. Ethan Yang et Xiangcheng Shi. « Does Multi-Agent Collaboration Pay When Agents Serve Users? Testing Agent Scaling in Dual-Control Settings ». arXiv:2610.27655v1, déposé le 20 octobre 2026 — prépublication sans signe de revue par les pairs à la notice. Notice consultée le 1er novembre 2026. https://arxiv.org/abs/2610.27655
218. Tianyang Xu et Jing Gao. « Auditing Failure Attribution: Label Predictability and Judge Behavior ». arXiv:2610.17747v1, déposé le 13 octobre 2026 — prépublication sans signe de revue par les pairs à la notice. Notice consultée le 1er novembre 2026. https://arxiv.org/abs/2610.17747
219. Jinhao Zhou, Xiaoyu Zhang, Jiongchi Yu et al. « When Messages Go Wrong: Understanding Communication Faults in LLM-Based Multi-Agent Systems ». arXiv:2610.15459v1, déposé le 11 octobre 2026 — prépublication sans signe de revue par les pairs à la notice. Notice consultée le 1er novembre 2026. https://arxiv.org/abs/2610.15459
220. Jingyi Su, Yihao Zhang, Dianxuan Fu et al. « First Demonstration of Multi-Agent LLM System for Million-Scale Optical Link Management in Global Production AIDCs ». arXiv:2608.23145v1, déposé le 24 août 2026 — prépublication sans signe de revue par les pairs à la notice. Notice consultée le 1er novembre 2026. https://arxiv.org/abs/2608.23145
221. Michael Hardy, Ruhana Azam, Anka Reuel et al. « Agent Evaluation Reliability: More Tasks Won't (Always) Fix An Agent Leaderboard ». arXiv:2610.00651v1, déposé le 30 septembre 2026 — prépublication sans signe de revue par les pairs à la notice. Notice consultée le 1er novembre 2026. https://arxiv.org/abs/2610.00651
222. Paul-Peter Arslan. « Audit Without Verification: When LLM Accountability Layers Relay Rather Than Check ». arXiv:2609.07680v1, déposé le 7 septembre 2026 — prépublication sans signe de revue par les pairs à la notice (préenregistrement OSF au champ Comments). Notice consultée le 1er novembre 2026. https://arxiv.org/abs/2609.07680
223. Ke Jiang, Mohan Yu, Yuan Chang et al. « A Formal Analysis of Agent Payment Protocols ». arXiv:2609.00060v1, déposé le 30 août 2026 ; aucun signe de revue par les pairs. Notice consultée le 1er novembre 2026. https://arxiv.org/abs/2609.00060v1
224. Yedidel Louck, Amit Dvir et Ariel Stulman. « Signing the Transaction but Not the Decision: Whisper Attacks and a Binding Defense for AP2 ». arXiv:2609.11757v1, déposé le 10 septembre 2026 ; au-

cun signe de revue par les pairs. Notice consultée le 1er novembre 2026. https://arxiv.org/abs/2609.11757v1

225. Jun Yeong Lee. « Who Leads and Who Collects:Algorithmic Collusion in Markets of Heterogeneous Language Models ». arXiv:2610.11256v1, déposé le 8 octobre 2026 ; aucun signe de revue par les pairs. Notice consultée le 1er novembre 2026. https://arxiv.org/abs/2610.11256v1
226. Adrian de Valois-Franklin, Alex Bogdan, Anas Ibrahim et al. « Get In, Decide, Prove: A Merchant-Side Readiness Benchmark for Agentic Commerce ». arXiv:2610.17378v1, déposé le 12 octobre 2026 ; aucun signe de revue par les pairs (jeu de données sur Zenodo au seul champ de commentaire). Notice consultée le 1er novembre 2026. https://arxiv.org/abs/2610.17378v1
227. Bardia Mohammadi et Laurent Bindschaedler. « The Irreversibility Budget: Fleet-Level Risk Accounting and Admission Control for Agent Operating Systems ». arXiv:2609.00275v1, déposé le 31 août 2026 ; acceptation annoncée au seul champ de commentaire (« Accepted at 2nd AgenticOS Workshop @ SOSP »), non confirmée en notice. Notice consultée le 1er novembre 2026. https://arxiv.org/abs/2609.00275v1
228. Abhishek Sharma. « FinalityBench: An Effect-Level Benchmark for Agent Decisions Under Delayed and Conflicting Financial Finality ». arXiv:2609.04706v1, déposé le 4 septembre 2026 ; aucun signe de revue par les pairs (archive Zenodo au seul champ de commentaire). Notice consultée le 1er novembre 2026. https://arxiv.org/abs/2609.04706v1
229. Mustafa Arslan. « Janus: Evidence-Before-Effect Sagas and Offline-Verifiable Provenance for Agentic LLMs ». arXiv:2609.38266v1, déposé le 29 septembre 2026 ; aucun signe de revue par les pairs. Notice consultée le 1er novembre 2026. https://arxiv.org/abs/2609.38266v1
230. Seonglae Cho, Franklin Cardenoso Fernandez, Umar Mohammed et al. « Automata from Agent Traces: Failure and Next-Step Prediction ». arXiv:2608.23670v1, déposé le 24 août 2026 ; aucun signe de revue par les pairs. Notice consultée le 1er novembre 2026. https://arxiv.org/abs/2608.23670v1
231. Timofey Sanko et Yuan Tian. « When Skills Tell Agents Not to Ask: A Large-Scale Study of Oversight Directives in Agent Skills ». arXiv:2610.37734v1, déposé le 27 octobre 2026 ; aucun signe de revue par les pairs. Notice consultée le 1er novembre 2026. https://arxiv.org/abs/2610.37734v1
232. Oren Perez. « The Law of Stop: Interruptibility, Injunctions, and the Governance of Agentic AI ». arXiv:2609.22882v2, déposé le 19 septembre 2026, v2 du 4 octobre 2026 ; aucun signe de revue par les pairs (également sur SSRN). Notice consultée le 1er novembre 2026. https://arxiv.org/abs/2609.22882v2
233. Hanjing Shi et Dominic DiFranzo. « When Agents Act Unwatched: The Reduced-Supervision Paradox in Agentic AI ». arXiv:2609.29547v1, déposé le 28 août 2026 ; aucun signe de revue par les pairs. Notice consultée le 1er novembre 2026. https://arxiv.org/abs/2609.29547v1
234. Yue Zhao, Jiate Li, Li Li et al. « Auditable Claims about AI Agents ». arXiv:2610.07459v1, déposé le 5 octobre 2026 ; aucun signe de revue par les pairs. Notice consultée le 1er novembre 2026. https://arxiv.org/abs/2610.07459v1
235. Ido Finder, Assaf Elovic, Gad Shalev et al. « AX is the New AEO ». arXiv:2609.34951v3, déposé le 28 septembre 2026, v3 du 6 octobre 2026 ; aucun signe de revue par les pairs. Notice consultée le 1er novembre 2026. https://arxiv.org/abs/2609.34951v3
236. De Wang et Peng Qi. « Recoverability and Verifier Strength: Two Measured Preconditions for Unattended Agent Self-Improvement ». arXiv:2610.27465v1, déposé le 20 octobre 2026 ; acceptation annoncée au seul champ de commentaire (« Accepted at the NeurIPS 2026 Workshop on Agenti-

cOS »), non confirmée en notice. Notice consultée le 1er novembre 2026. https://arxiv.org/abs/2610.27465v1

237. Genliang Zhu et Chu Wang. « Authorization for Self-Modifying AI Agent Populations: Conserving Authority across Replacement, Forking, and Rollback ». arXiv:2610.00347v1, déposé le 29 septembre 2026 ; aucun signe de revue par les pairs. Notice consultée le 1er novembre 2026. https://arxiv.org/abs/2610.00347v1
238. Franziska Roesner et Tadayoshi Kohno. « Reflections on Trusting Trust, Revisited: Contaminating Self-Modifying AI Coding Agents with Poisoned Benchmarks ». arXiv:2609.17817v1, déposé le 15 septembre 2026 ; aucun signe de revue par les pairs. Notice consultée le 1er novembre 2026. https://arxiv.org/abs/2609.17817v1
239. Luca Zanolini. « Correlated Failures of AI Approval Monitors ». arXiv:2610.29178v1, déposé le 21 octobre 2026 ; aucun signe de revue par les pairs. Notice consultée le 1er novembre 2026. https://arxiv.org/abs/2610.29178v1
240. Chenglin Yang. « Evaluate the Stack, Not the Layer: Do Deterministic and LLM Gates for Agent Actions Fail Independently? ». arXiv:2610.07359v2, déposé le 5 octobre 2026, v2 du 26 octobre 2026 ; aucun signe de revue par les pairs. Notice consultée le 1er novembre 2026. https://arxiv.org/abs/2610.07359v2
241. Summer Eunhyung Ann, Haokun Liu et Chenhao Tan. « The Interaction Tax: When Communication Erases Diversity in Multi-Agent Teams ». arXiv:2608.23541v1, déposé le 24 août 2026 ; acceptation annoncée au seul champ de commentaire (« Accepted at ICML 2026 (PMLR 306) »), non confirmée en notice. Notice consultée le 1er novembre 2026. https://arxiv.org/abs/2608.23541v1
242. Addison J. Wu, Jasin Cekinmez, Michel Liao et al. « How does Adversarial Influence Scale in Multi-Agent Systems? ». arXiv:2609.30028v2, déposé le 24 septembre 2026, v2 du 29 septembre 2026 ; aucun signe de revue par les pairs. Notice consultée le 1er novembre 2026. https://arxiv.org/abs/2609.30028v2